# ELSD 1

2026-09-18

## Tabella Notazioni e Convenzioni del Corso

| Simbolo / Notazione | Significato Ingegneristico / Matematico | Note e Particolarità della Professoressa |
|---|---|---|
| $\underline{x}, \underline{y}, \underline{w}$ | **Vettori** (es. sollecitazione, osservazione, rumore). | Indicano sempre un vettore mediante il **trattino sottostante** ($\underline{x}$ invece del grassetto $\mathbf{x}$). |
| $X, Y$ vs $x, y$ | **Variabile Aleatoria** (Maiuscolo) vs **Realizzazione** (Minuscolo). | Distinzione rigorosa tra la variabile aleatoria/vettore $\underline{X}$ e il valore numerico misurato $\underline{x}$. |
| $\underline{Y}$ vs $\underline{y}$ | **Osservabile** vs **Osservazione**. | $\underline{Y}$ è la variabile aleatoria osservabile all'uscita del canale, $\underline{y}$ è l'effettivo dato osservato. |
| $\underline{\hat{x}}$ | **Stima / Decisione** all'uscita del ricevitore. | Denota l'uscita dello **stimatore** (se $\underline{\hat{x}}$ è continuo) o del **classificatore** (se $\underline{\hat{x}}$ è discreto). |
| $\oplus$ | **Somma di Canale / Additività**. | Utilizzato nello schema $\underline{y} = \underline{x} \oplus \underline{w}$ per indicare l'effetto additivo del rumore del canale AWGN. |
| $(\cdot)^T$ | **Trasposta** di un vettore o matrice. | Utilizzata per esprimere i vettori in forma colonna, es. $\underline{X} = [X_1, X_2, \dots, X_N]^T$. |
| $(\cdot)^H$ | **Ermitiana** (Trasposta Coniugata). | Utilizzata in ambito complesso per vettori e matrici di covarianza. |
| $f_{\underline{Y}\|\underline{X}}(\underline{y}\|\underline{x})$ | **Densità o Massa di Probabilità Condizionata**. | Notazione unica usata **sia per PDF che per PMF**, sia in contesto Bayesiano che Non-Bayesiano (dove $\underline{x}$ è trattato come parametro deterministico non noto). |
| $F_{\underline{X}}(\underline{x})$ | **Cumulative Distribution Function (CDF)** congiunta. | Definito come $P(X_1 \leq x_1 \cap \dots \cap X_N \leq x_N)$ o con il simbolo di intersezione/and ($\wedge$). |
| $p_{\underline{X}}(\underline{x})$ / pmf | **Probability Mass Function (PMF)**. | Usata per variabili discrete; definita come $P(X_1 = x_1 \cap \dots \cap X_N = x_N)$. |
| $f_{\underline{X}}(\underline{x})$ / pdf | **Probability Density Function (PDF)**. | Usata per variabili continue; legata alla CDF dalla relazione di derivata $\frac{d}{dx} F_X(x)$. |

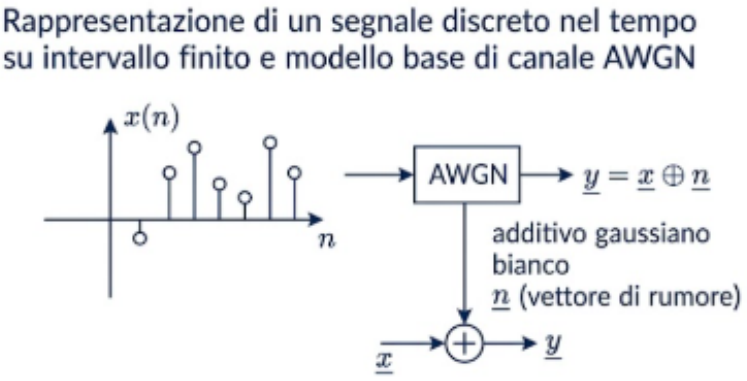
| Simbolo / Notazione | Significato Ingegneristico / Matematico | Note e Particolarità della Professoressa |
|---|---|---|
| $\mathcal{S}_X$ / Supporto | **Supporto della densità/massa di probabilità**. | L'insieme di valori su cui la v.a. è definita o su cui la PDF/PMF è strettamente positiva. |
| $M$ vs $N$ | **Cardinalità dei Simboli** vs **Dimensione del Vettore**. | $M$ indica il numero di simboli/ipotesi discrete ( $\underline{x} \in \{\underline{x}_1, \dots, \underline{x}_M\}$), $N$ indica il numero di componenti/righe del vettore. |

# Blocco 1: Modello del Sistema di Comunicazione, Canale AWGN e Approcci Bayesiani / Non-Bayesiani

## 1.1 Modello del Segnale e Discretizzazione

Nel corso di Elaborazione di Segnali Digitali si considerano segnali definiti su **intervalli di tempo finiti**. Quando si affronta un segnale teoricamente illimitato nel tempo, ci si occupa della sua restrizione temporale e della successiva **discretizzazione**.
I vettori si indicano convenzionalmente con un trattino sottostante (oppure in grassetto):

- $\underline{x}$: vettore di sollecitazione (rappresenta l'informazione trasmessa / ingresso al sistema).
- $\underline{y}$: vettore di osservazione / uscita ricevuta dal canale.




## 1.2 Modello di Canale AWGN e Rumore Bianco vs. Colorato

La relazione tra l'ingresso $\underline{x}$ e l'uscita $\underline{y}$ **non è deterministica** nè tantomeno biunivoca. Se fosse una relazione biunivoca deterministica $y = g(x)$, il recupero dell'informazione sarebbe banale mediante la funzione inversa $x = g^{-1}(y)$. La relazione è invece **aleatoria** a causa della presenza del disturbo introdottos dal canale di trasmissione.

Il modello di canale più semplice da descrivere analiticamente è il canale **AWGN** (*Additive White Gaussian Noise*):

$$\underline{y} = \underline{x} \oplus \underline{w}$$

Dove:

- **Additive (Additivo):** Il rumore $\underline{w}$ si somma direttamente al segnale trasmesso $\underline{x}$.
- **White (Bianco):** La matrice di covarianza del rumore è proporzionale alla matrice identità ($\mathbf{K}_{ww} = \sigma_w^2 \mathbf{I}$). Ciò significa che la potenza del rumore è uniforme in tutte le direzioni/frequenze e le sue componenti sono slegate/sfericamente simmetriche.
- **Gaussian (Gaussiano):** Il rumore segue una distribuzione normale (gaussiana).
- **Noise (Rumore/Disturbo):** L'inquinamento aleatorio sovrapposto all'informazione utile.

## Confronto Ingegneristico: Rumore Bianco vs. Rumore Colorato

- **Rumore Bianco:** Poiché la matrice di covarianza è proporzionale all'identità, qualsiasi rotazione o cambio di coordinate lascia inalterata la statistica del disturbo (il disturbo ha pari intensità in tutte le posizioni/direzioni). Di conseguenza, "ripulire" un segnale affetto da rumore bianco risulta complesso poiché non esiste una direzione privilegiata priva di rumore.
- **Rumore Colorato:** La matrice di covarianza non è identica. Esistono direzioni nello spazio dei segnali (o frequenze) in cui la componente di rumore è significativamente minore.
    - *Esempio operativo:* Se disponiamo di 4 canali di trasmissione e il rumore è colorato, possiamo individuare la direzione/canale caratterizzato da minore varianza di rumore e trasmettere preferenzialmente su di esso per ottimizzare il SNR (*Signal-to-Noise Ratio*).

# 1.3 Descrizione Probabilistica del Canale e Task-Oriented Communication

Quando non è possibile definire una semplice legge analitica ingresso-uscita $y = g(x)$, si descrive il legame tra $\underline{x}$ ed $\underline{y}$ in termini probabilistici tramite la **densità di probabilità condizionata** $f_{\underline{Y}|\underline{X}}(\underline{y}|\underline{x})$ (o PMF condizionata nel discreto).
È comune incontrare **sistemi misti**:

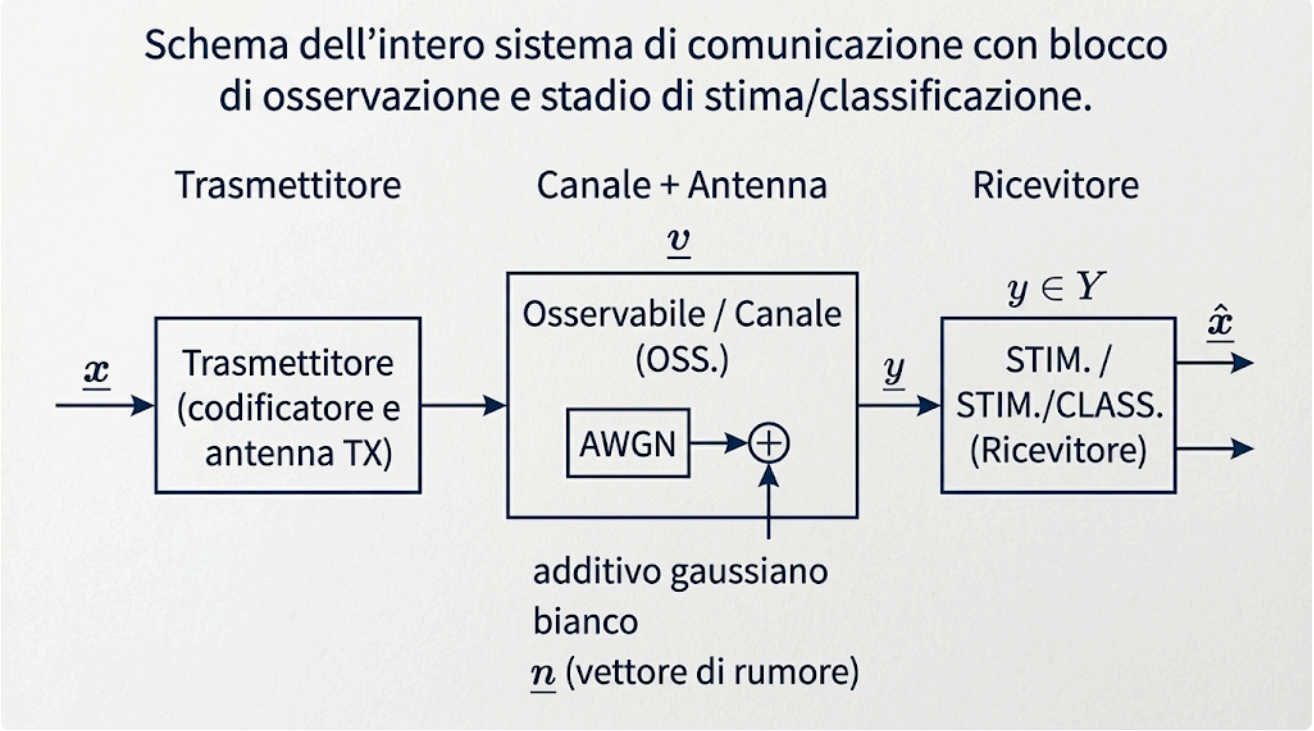
- $\underline{x}$ è discreto (es. simboli d'alfabeto $M$-ario).
- $\underline{y}$ è continuo (es. segnale affetto da rumore gaussiano).
  In tal caso, invece di una funzione algebrica $y = g(x)$, la descrizione formale del canale è affidata alla famiglia di PDF condizionate $\{f_{\underline{Y}|\underline{X}}(\underline{y}|\underline{x}_i)\}_{i=1}^{M}$.

## Semantic & Task-Oriented Communication

Il sistema di trasmissione non si progetta "in astratto", ma in funzione del **task/obiettivo** e della qualità richiesta all'uscita:

1. **Ambito di risoluzione ed estrazione:** Possiamo conoscere la natura fisica di $x$ (es. temperatura, tensione), ma rifiutare la sua caratterizzazione statistica oppure decidere di estrarre da $y$ solo determinati attributi (*features*).
2. **Esempio dei Display:** Se il destinatario finale è un display a bassa risoluzione, ridurre il bitrate in trasmissione non compromette la percezione visiva dell'utente, mentre per un display ad alta risoluzione occorrono prestazioni elevate.
3. **Comunicazione Semantica:** Si supera il paradigma classico di Shannon orientando l'ottimizzazione del sistema (minima probabilità d'errore o minimo errore quadratico medio) sul raggiungere lo specifico *goal* applicativo (*Task-Oriented Communication*).

# 1.4 Architettura del Ricevitore: Stimatore vs. Classificatore




L'osservazione $\underline{y}$ rappresenta l'effetto complessivo della catena di trasmissione (trasmettitore, canale fisico, antenne). A valle dell'osservazione $\underline{y}$ si inserisce l'elaboratore d'uscita:

1. **Stimatore ($\hat{\underline{x}}$ continuo):** Se lo spazio dei possibili valori di $\underline{x}$ è un insieme ad ampiezza continua ($\underline{x} \in \mathbb{R}^N$), il blocco genera una stima continua $\hat{\underline{x}}$.
2. **Classificatore / Decisore ($\hat{\underline{x}}$ discreto):** Se l'insieme dei possibili valori trasmessi ha cardinalità discreta ($\underline{x} \in \{\underline{x}_1, \underline{x}_2, \ldots, \underline{x}_M\}$), il blocco seleziona una decisione discreta $\hat{\underline{x}}$.

# 1.5 Contesto Bayesiano vs. Non-Bayesiano e Stimatori Robusti

In base alla conoscenza preliminare che si possiede (o si sceglie di utilizzare) sulla variabile d'ingresso $\underline{x}$, lo scenario si divide in due grandi filosofie di progettazione:

| Caratteristica | Contesto Bayesiano | Contesto Non-Bayesiano |
|---|---|---|
| **Natura di $\underline{x}$** | Modellato come **vettore aleatorio**. | Modellato come **parametro/vettore deterministico non noto**. |
| **Conoscenza a priori** | Si conosce e si sfrutta la a-priori PDF $f_{\underline{X}}(\underline{x})$ o PMF $P(\underline{X} = \underline{x}_i) = p_i$. | Si **rinuncia** alla conoscenza della PDF/PMF (non nota o non calcolabile). |
| **Proprietà chiave** | Massimizza le prestazioni medie pesando le probabilità a priori. | Corrisponde al caso Bayesiano con **distribuzione uniforme a priori** ( $p_i = \frac{1}{M}$). |

## Motivazioni per l'Uso di Approcci Non-Bayesiani e Robustezza

Perché si sceglie l'approccio Non-Bayesiano anche quando la PDF/PMF a priori sarebbe teoricamente calcolabile?

1. **Complessità Computazionale:** Sfruttare la PDF/PMF a priori può richiedere integrazioni numeriche o calcoli complessi poco adatti ad implementazioni hardware in tempo reale.
2. **Assenza/Incertezza del Modello Statistico:** La distribuzione a priori potrebbe non essere nota con certezza.
3. **Robustezza del Sistema:** Progettare uno **stimatore robusto** garantisce prestazioni stabili ed elevate anche a fronte di deviazioni o errori nelle ipotesi statistiche su $\underline{x}$ e su $\underline{y}$. Si evita così che un errore di modellazione infici drasticamente l'accuratezza del sistema.

Ecco l'elaborazione del **Blocco 2**, formattata in Markdown/LaTeX con la numerazione progressiva richiesta e spaziature ridotte.

# Blocco 2: Richiami di Vettori Aleatori e Caratterizzazione Discreta (CDF, PMF e Bernoulli)

## 2.1 Convenzioni di Notazione e Struttura dei Vettori

Per evitare ambiguità, nel corso si adottano le seguenti convenzioni:

- **Variabili e Vettori Aleatori:** Le variabili aleatorie si indicano con lettere maiuscole ( $X, Y$), mentre i vettori aleatori utilizzano il trattino sottostante $\underline{X}$.
- **Realizzazioni:** Le specifiche realizzazioni (valori assunti) si indicano con lettere minuscole: $x, y$ per scalari e $\underline{x}, \underline{y}$ per vettori.
- **Vettore Colonna:** Un vettore di dimensione $N \times 1$ si rappresenta come:

$$\underline{X} = \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_N \end{bmatrix}, \quad \underline{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_N \end{bmatrix}$$

- **Operatori di Trasposizione:** Si indica con $(\cdot)^T$ il trasposto e con $(\cdot)^H$ l'Ermitiano (trasposto coniugato).
- **Distinzione tra Osservabili e Osservazione:** $\underline{Y}$ indica la variabile/vettore aleatorio osservabile, mentre $\underline{y}$ è l'effettivo dato numerico osservato.

## 2.2 Funzione di Distribuzione Congiunta (CDF)

La **Cumulative Distribution Function (CDF)** congiunta di un vettore aleatorio $\underline{X} = [X_1, X_2, \ldots, X_N]^T$ descrive la probabilità che ciascuna componente non superi un determinato valore soglia $x_i$:

$$F_{\underline{X}}(\underline{x}) \triangleq P(X_1 \leq x_1 \cap X_2 \leq x_2 \cap \cdots \cap X_N \leq x_N)$$

Nel caso scalare ($N = 1$), si riduce a:

$$F_{X_1}(x_1) \triangleq P(X_1 \leq x_1)$$

## 2.3 Caratterizzazione Discreta: PMF e Variabile di Bernoulli

Se $\underline{X}$ assume valori in un insieme discreto, la caratterizzazione statistica è fornita dalla **Probability Mass Function (PMF)** congiunta:

$$p_{\underline{X}}(\underline{x}) \triangleq P(X_1 = x_1 \cap X_2 = x_2 \cap \cdots \cap X_N = x_N)$$

Per una singola variabile discreta $X_1$, la PMF vale $p_{X_1}(x_1) = P(X_1 = x_1) = p(x_1)$.

### Esempio: Variabile Aleatoria di Bernoulli $X_1 \sim \mathcal{B}(p)$

Si consideri $X_1 \in \{0, 1\}$ con parametro $p$:

- $P(X_1 = 1) = p$
- $P(X_1 = 0) = 1 - p$
  La corrispondente CDF $F_{X_1}(x_1)$ presenta una struttura a gradino (con salti):

$$F_{X_1}(x_1) = \begin{cases} 0 & \text{se } x_1 < 0 \\ 1-p & \text{se } 0 \le x_1 < 1 \\ 1 & \text{se } x_1 \ge 1 \end{cases}$$

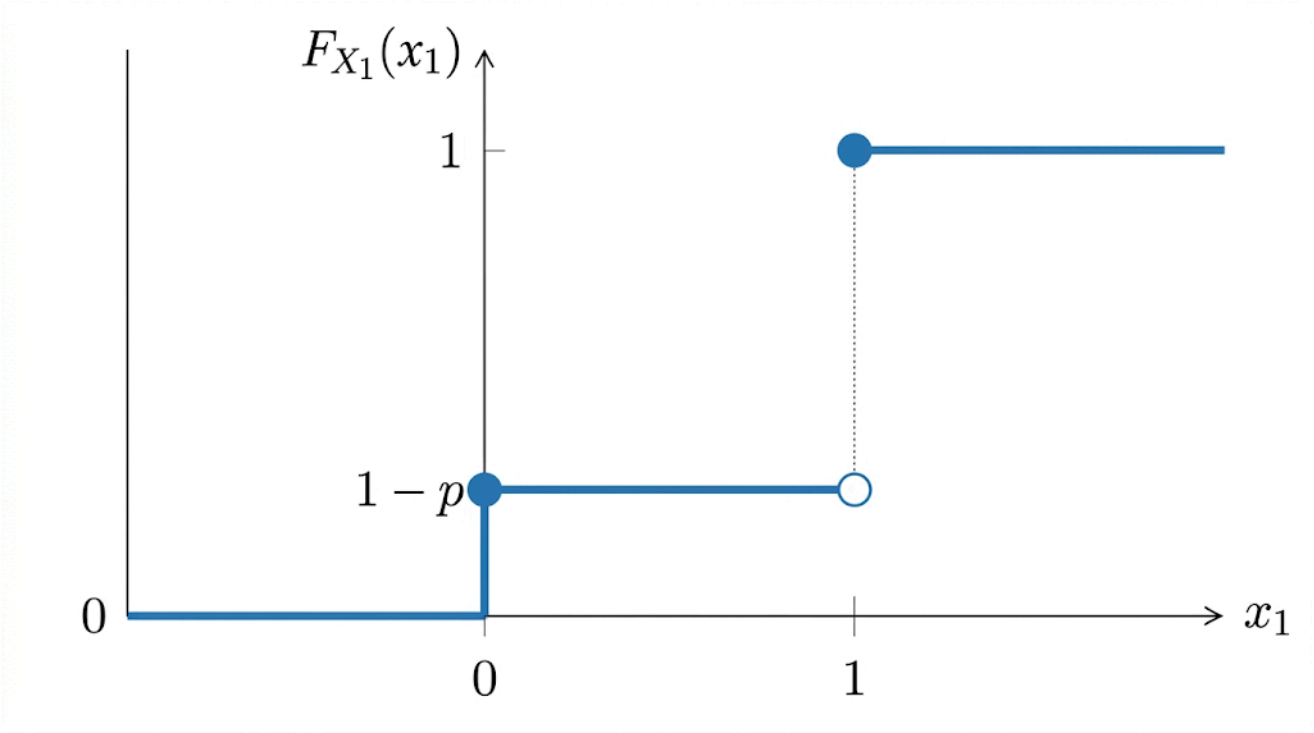



*Grafico della CDF $F{X1}(x_1)$ per una variabile aleatoria di Bernoulli avente salti di ampiezza pari alle probabilità puntuali.*

Dall'andamento grafico della CDF è sempre possibile ricavare la PMF nei punti di discontinuità:

- L'ampiezza di ciascun salto in un punto $x_1$ corrisponde esattamente al valore della PMF in quel punto: $P(X_1 = x_1) = F_{X_1}(x_1^+) - F_{X_1}(x_1^-)$.
- Tra due punti di salto successivi, la CDF rimane costante, indicando probabilità nulla per i valori compresi nell'intervallo.

# Blocco 3: Caratterizzazione Continua (PDF), Dimostrazione degli Eventi Disgiunti e Proprietà Fondamentali

## 3.1 Probability Density Function (PDF) e Significato Ingegneristico

Per variabili aleatorie continue, la **Probability Density Function (PDF)** è definita come la derivata prima della CDF (nel caso scalare):

$$f_{X_1}(x_1) \triangleq \frac{d}{dx_1} F_{X_1}(x_1)$$

Ne deriva che la CDF si calcola integrando la PDF da $-\infty$ a $x_1$:

$$F_{X_1}(x_1) = \int_{-\infty}^{x_1} f_{X_1}(\xi)\, d\xi \triangleq P(X_1 \leq x_1)$$

Nel caso di un vettore di dimensione $N = 2$, la PDF congiunta $f_{\underline{X}}(\underline{x}) = f_{X_1,X_2}(x_1, x_2)$ si ottiene tramite derivata parziale mista di ordine 2:

$$f_{\underline{X}}(\underline{x}) \triangleq \frac{\partial^2}{\partial x_1 \partial x_2} F_{\underline{X}}(x_1, x_2)$$

### Significato Ingegneristico della PDF

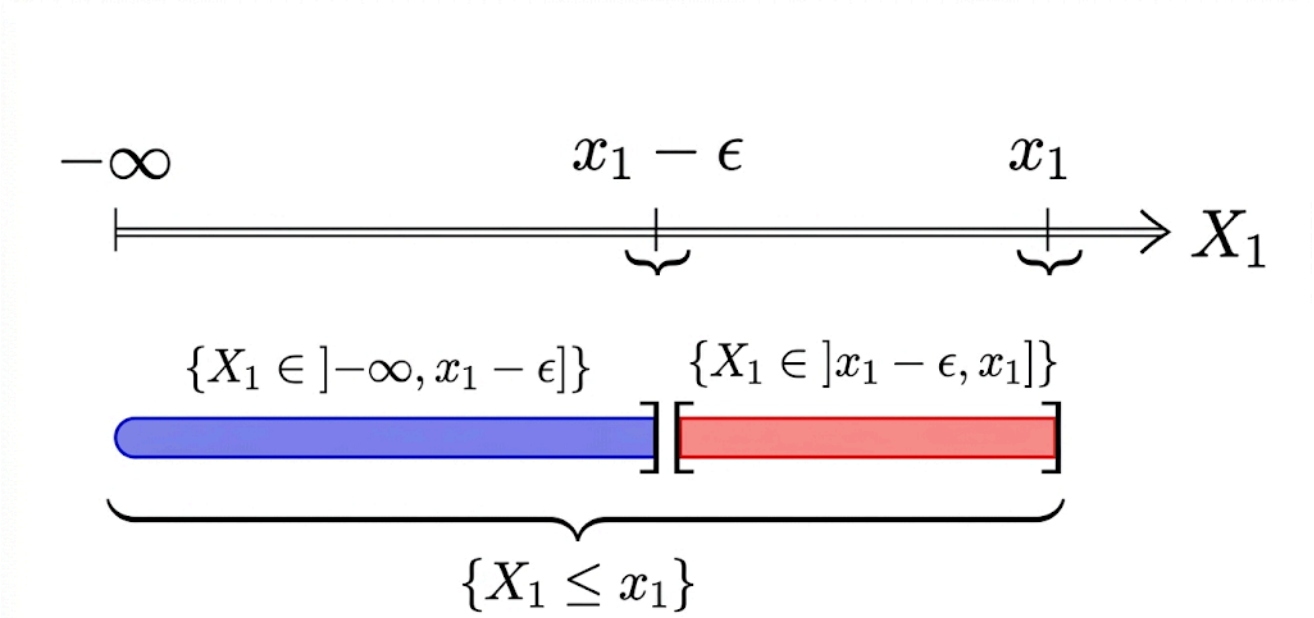
La PDF **non è una probabilità**, ma una *densità di probabilità*. Il suo significato ingegneristico fondamentale è che, moltiplicata per la durata di un intervallo infinitesimo $dx_1$, fornisce la probabilità che la variabile aleatoria $X_1$ cada all'interno dell'intervallo $[x_1, x_1 + dx_1]$:

$$P(x_1 < X_1 \leq x_1 + dx_1) \approx f_{X_1}(x_1) \cdot dx_1$$

## 3.2 Dimostrazione Formale della Differenza di CDF tramite Eventi Disgiunti

Per dimostrare il legame tra la CDF e la probabilità che $X_1$ appartenga a un intervallo limitato, si considera la differenza tra la CDF valutata in $x_1$ e la CDF valutata in $x_1 - \epsilon$ (con $\epsilon > 0$):

$$F_{X_1}(x_1) - F_{X_1}(x_1 - \epsilon) = P(X_1 \leq x_1) - P(X_1 \leq x_1 - \epsilon)$$




*Rappresentazione grafica della scomposizione dell'evento $\{X_1 \leq x_1\}$ nell'unione di due intervalli disgiunti su asse reale.*

### Dimostrazione Passo-Passo:

1. Si scompone l'evento $\{X_1 \in ]-\infty, x_1]\}$ nell'unione di due eventi limitati ed **incompatibili/disgiunti**:
$$\{X_1 \leq x_1\} = \{X_1 \in ]-\infty, x_1 - \epsilon]\} \cup \{X_1 \in ]x_1 - \epsilon, x_1]\}$$
2. **Proprietà di Additività:** Poiché i due intervalli sono disgiunti (la probabilità che accadano contemporaneamente è nulla, da **non confondere mai** con il concetto di indipendenza stocastica), la probabilità dell'unione è pari alla somma delle singole probabilità:
$$P(X_1 \leq x_1) = P(X_1 \in ]-\infty, x_1 - \epsilon]) + P(X_1 \in ]x_1 - \epsilon, x_1])$$
3. Risostituendo la definizione di CDF $P(X_1 \in ]-\infty, x_1 - \epsilon]) = P(X_1 \leq x_1 - \epsilon)$:
$$P(X_1 \leq x_1) = P(X_1 \leq x_1 - \epsilon) + P(x_1 - \epsilon < X_1 \leq x_1)$$
4. Portando a sinistra il termine $P(X_1 \leq x_1 - \epsilon)$, si ottiene la relazione cercata:
$$F_{X_1}(x_1) - F_{X_1}(x_1 - \epsilon) = P(x_1 - \epsilon < X_1 \leq x_1)$$

Dividendo entrambi i membri per $\epsilon$ e passando al limite per $\epsilon \to 0$, il rapporto incrementale coincide esattamente con la definizione di derivata prima della CDF, ossia la PDF $f_{X_1}(x_1)$.

## 3.3 Condizioni di Normalizzazione e Marginalizzazione

### 1. Condizioni di Normalizzazione

La probabilità dell'intero spazio campionario dev'essere pari a 1:

- **Caso Discreto (PMF):** $\sum_{x_1} \sum_{x_2} p_{X_1,X_2}(x_1, x_2) = 1$
- **Caso Continuo (PDF):** $\int_{\mathbb{R}^N} f_{\underline{X}}(\underline{x})\, d\underline{x} = 1 \quad \Longrightarrow \quad \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} f_{X_1,X_2}(x_1, x_2)\, dx_1 dx_2 = 1$

### 2. Condizioni di Marginalizzazione (Legge della Probabilità Totale)

Se si possiede la caratterizzazione congiunta di due variabili aleatorie, è sempre possibile ricavare la distribuzione marginale di una singola variabile "eliminando" (sommando o integrando) l'altra variabile:

- **Caso Discreto ($N = 2$):**
$$p_{X_1}(x_1) = \sum_{x_2 \in \mathcal{S}_{X_2}} p_{X_1,X_2}(x_1, x_2)$$

  *Dimostrazione:* Si ottiene applicando la legge delle probabilità totali su tutti i valori mutui ed esaustivi che $X_2$ può assumere.

- **Caso Continuo ($N = 2$):**

$$f_{X_1}(x_1) = \int_{-\infty}^{+\infty} f_{X_1,X_2}(x_1, x_2)\, dx_2$$

*Nota Ingegneristica:* Integrare la PDF congiunta rispetto alla variabile $x_2$ equivale ad applicare il teorema della probabilità totale nel dominio continuo per ottenere la legge marginale $f_{X_1}(x_1)$.

## 3.4 Scomposizione tramite Probabilità Condizionata e Proprietà Commutativa

Per esprimere la PDF congiunta in termini di densità condizionate e marginali, si applica la regola della catena probabilistica:

$$f_{X_1,X_2}(x_1, x_2) = f_{X_1|X_2}(x_1|x_2) \cdot f_{X_2}(x_2)$$

Sfruttando la **proprietà commutativa** delle variabili o degli eventi, la congiunta può essere riscritta in modo del tutto equivalente scambiando il ruolo delle variabili:

$$f_{X_1,X_2}(x_1, x_2) = f_{X_2|X_1}(x_2|x_1) \cdot f_{X_1}(x_1)$$

Da questa uguaglianza discende direttamente il **Teorema di Bayes** per densità di probabilità continue:

$$f_{X_1|X_2}(x_1|x_2) = \frac{f_{X_2|X_1}(x_2|x_1) \cdot f_{X_1}(x_1)}{f_{X_2}(x_2)}$$