ELSD 6

2026-10-05

Blocco 1: Statistica Sufficiente Completa (SSC) e Statistica Sufficiente Minimale (SSM)

1.1 Introduzione e Contesto Informativo

Sia $\underline{y} = [y_1, y_2, \dots, y_N]^T \in \mathcal{Y} \subseteq \mathbb{R}^N$ il vettore delle osservazioni campionarie estratte da un modello con funzione di densità di probabilità (PDF) $f_{\underline{Y}}(\underline{y}; \underline{x})$, dipendente dal parametro (o segnale) incognito $\underline{x} \in \mathcal{X}$.

Sia $T(\underline{y})$ una statistica (ovvero una funzione deterministica e misurabile delle sole osservazioni $\underline{y}$, indipendente da $\underline{x}$). Se $T(\underline{y})$ è una statistica sufficiente per $\underline{x}$, la distribuzione condizionata di $\underline{y}$ dato $T(\underline{y})$ non dipende da $\underline{x}$. Tuttavia, la semplice sufficienza non garantisce che la rappresentazione dei dati sia priva di ridondanze: per questo motivo si introducono le nozioni di **minimalità** e **completezza**.

1.2 Statistica Sufficiente Completa (SSC)

La proprietà di completezza assicura che non esistano trasformazioni non banali della statistica il cui valore atteso sia nullo per ogni possibile valore del parametro $\underline{x}$.

Definizione Formale

Sia $T_c(\underline{y})$ una statistica sufficiente per $\underline{x} \in \mathcal{X}$. La statistica $T_c(\underline{y})$ si definisce **completa** (e costituisce una **Statistica Sufficiente Completa - SSC**) se, per ogni funzione misurabile $g(\cdot)$ indipendente da $\underline{x}$, vale la seguente implicazione per ogni $\underline{x} \in \mathcal{X}$:

$$\mathbb{E}_{\underline{x}}\big[g(T_c(\underline{y}))\big] = 0 \quad \forall \underline{x} \in \mathcal{X} \implies P_{\underline{x}}\big(g(T_c(\underline{y})) = 0\big) = 1 \quad \forall \underline{x} \in \mathcal{X}$$

Significato Fisico e Statistico

- **Assenza di variabilità spuria:** Se $g(T_c)$ avesse media nulla per ogni $\underline{x}$ senza essere quasi certamente nulla, rappresenterebbe una componente fluttuante priva di informazione su $\underline{x}$. La completezza garantisce che $T_c(\underline{y})$ non contenga alcuna informazione ridondante con valore atteso invariante rispetto a $\underline{x}$.
- **Unicità degli stimatori non distorti:** Per il Teorema di Lehmann-Scheffé, se esiste uno stimatore non distorto per $\underline{x}$ ed esiste una SSC $T_c(\underline{y})$, allora lo stimatore ottenuto condizionando rispetto a $T_c(\underline{y})$ è l'unico stimatore non distorto a minima varianza (UMVU).

1.3 Statistica Sufficiente Minimale (SSM)

Mentre la sufficienza garantisce che non vi sia perdita di informazione su $\underline{x}$, la **minimalità** assicura la massima compressione possibile dei dati.

Definizione Formale

Una statistica sufficiente $T_m(\underline{y})$ è detta **sufficiente minimale (SSM)** se, per una qualunque altra statistica sufficiente $T(\underline{y})$, esiste una funzione misurabile $h(\cdot)$ tale che:

$$T_m(\underline{y}) = h(T(\underline{y}))$$

Partizione dello Spazio Campionario

Ogni statistica $T(\underline{y})$ induce una partizione dello spazio osservabile $\mathcal{Y}$ in sottoinsiemi di livello (insiemi in cui $T(\underline{y})$ assume valore costante):

- La statistica sufficiente minimale $T_m(\underline{y})$ genera la partizione meno fine (più grossolana) tra tutte le possibili statistiche sufficienti.
- Qualsiasi altra statistica sufficiente $T(\underline{y})$ suddivide ulteriormente le regioni indotte da $T_m(\underline{y})$, aggiungendo dettagli irrilevanti ai fini dell'inferenza su $\underline{x}$.

1.4 Teorema di Equivalenza Funzionale (Relazione tra SSC e SSM)

Un risultato fondamentale stabilisce un legame diretto e costruttivo tra la completezza e la minimalità.

Enunciato del Teorema

Se $T_c(\underline{y})$ è una **Statistica Sufficiente Completa (SSC)** per $\underline{x} \in \mathcal{X}$, allora $T_c(\underline{y})$ è anche una **Statistica Sufficiente Minimale (SSM)**.

1.5 Dimostrazione Dettagliata del Teorema di Equivalenza

Ipotesi

- **Ipotesi 1:** $T_c(\underline{y})$ è una statistica sufficiente e completa per $\underline{x}$.
- **Ipotesi 2:** Sia $T_m(\underline{y})$ una generica statistica sufficiente minimale per $\underline{x}$.

Tesi

$T_c(\underline{y})$ è equivalente a $T_m(\underline{y})$ a meno di una trasformazione invertibile, e di conseguenza $T_c(\underline{y})$ è una statistica sufficiente minimale.

Sviluppo dei Passaggi Logici

- **Passo 1: Applicazione della definizione di SSM** Poiché $T_m(\underline{y})$ è per ipotesi sufficiente minimale e $T_c(\underline{y})$ è una statistica sufficiente, dalla definizione di minimalità deve esistere una funzione misurabile $h(\cdot)$ tale che:

$$T_m(\underline{y}) = h(T_c(\underline{y}))$$

- **Passo 2: Costruzione dell'aspettativa condizionata** Consideriamo la speranza condizionata di $T_c(\underline{y})$ dato $T_m(\underline{y})$:

$$g(T_m(\underline{y})) = \mathbb{E}\big[T_c(\underline{y}) \mid T_m(\underline{y})\big]$$

  Poiché $T_m(\underline{y})$ è una statistica sufficiente, la distribuzione condizionata di $\underline{y} \mid T_m(\underline{y})$ non dipende da $\underline{x}$. Di conseguenza, la funzione $g(\cdot)$ non dipende dal parametro $\underline{x}$.
- **Passo 3: Applicazione del Teorema della Media Condizionata (Legge dell'Aspettativa Iterata)** Sfruttando la proprietà degli aspettativi condizionati $\mathbb{E}[X] = \mathbb{E}\big[\mathbb{E}[X \mid Y]\big]$, valutiamo il valore atteso della differenza $T_c(\underline{y}) - g(T_m(\underline{y}))$:

$$\mathbb{E}_{\underline{x}}\big[T_c(\underline{y}) - g(T_m(\underline{y}))\big] = \mathbb{E}_{\underline{x}}[T_c(\underline{y})] - \mathbb{E}_{\underline{x}}\Big[\mathbb{E}\big[T_c(\underline{y}) \mid T_m(\underline{y})\big]\Big] = \mathbb{E}_{\underline{x}}[T_c(\underline{y})] - \mathbb{E}_{\underline{x}}[T_c(\underline{y})] = 0$$

- **Passo 4: Sostituzione in funzione di $T_c(\underline{y})$** Poiché al Passo 1 abbiamo stabilito che $T_m(\underline{y}) = h(T_c(\underline{y}))$, la composizione $g(T_m(\underline{y}))$ si riscrive direttamente come:

$$g(T_m(\underline{y})) = g(h(T_c(\underline{y}))) = \phi(T_c(\underline{y}))$$

  Definiamo la funzione $\phi_0(T_c) = T_c - \phi(T_c)$. Sostituendo nella relazione di media nulla ottenuta al Passo 3:

$$\mathbb{E}_{\underline{x}}\big[\phi_0(T_c(\underline{y}))\big] = \mathbb{E}_{\underline{x}}\big[T_c(\underline{y}) - \phi(T_c(\underline{y}))\big] = 0 \quad \forall \underline{x} \in \mathcal{X}$$

- **Passo 5: Sfruttamento della condizione di Completezza** Per l'ipotesi di completezza su $T_c(\underline{y})$, l'unica funzione $\phi_0(T_c)$ ad avere valore atteso identicamente nullo per ogni valore di $\underline{x} \in \mathcal{X}$ è quella quasi certamente nulla:

$$P_{\underline{x}}\big(\phi_0(T_c(\underline{y})) = 0\big) = 1 \implies T_c(\underline{y}) - \phi(T_c(\underline{y})) = 0 \quad \text{q.c.}$$

  Di conseguenza:

$$T_c(\underline{y}) = g(T_m(\underline{y})) \quad \text{q.c.}$$

Sintesi e Conclusione della Dimostrazione

Dalle due relazioni ottenute:

1. $T_m(\underline{y}) = h(T_c(\underline{y}))$ (dalla minimalità di T_m)
2. $T_c(\underline{y}) = g(T_m(\underline{y}))$ (dalla completezza di T_c)

Si conclude che $T_c(\underline{y})$ e $T_m(\underline{y})$ sono legate da una trasformazione biunivoca. Di conseguenza, la partizione dello spazio dei dati indotta da $T_c(\underline{y})$ coincide con quella indotta da $T_m(\underline{y})$.

Blocco 2: Verifica della Completezza per la Statistica Sufficiente Gaussiana

2.1 Modellizzazione del Problema e Definizione delle Osservazioni

Consideriamo un vettore di osservazioni casuali $\underline{y} = [y_1, y_2, \dots, y_N]^T \in \mathbb{R}^N$ costituito da N variabili casuali indipendenti e identicamente distribuite (i.i.d.) secondo una distribuzione Gaussiana con media incognita $x \in \mathbb{R}$ e varianza nota σ^2:

$$y_i \sim \mathcal{N}(x, \sigma^2), \quad i = 1, 2, \dots, N$$

In forma vettoriale compatto, il modello di osservazione si scrive:

$$\underline{y} = x\underline{1} + \underline{w}$$

dove $\underline{1} = [1, 1, \dots, 1]^T$ è il vettore colonna unitario di dimensione N, e $\underline{w} \sim \mathcal{N}(\underline{0}, \sigma^2\mathbf{I}_N)$ è il vettore di rumore gaussiano a media nulla e matrice di covarianza sferica.

La funzione di densità di probabilità (PDF) congiunta del vettore $\underline{y}$, dato il parametro x, è data da:

$$f_{\underline{Y}}(\underline{y}; x) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^{N} (y_i - x)^2 \right)$$

Sfruttando il Teorema di Fattorizzazione di Fisher-Neyman, si individua facilmente la statistica sufficiente primaria per il parametro di media x:

$$T(\underline{y}) = \sum_{i=1}^{N} y_i$$

Poiché la somma di N variabili casuali gaussiane indipendenti $\mathcal{N}(x, \sigma^2)$ è anch'essa una variabile casuale gaussiana, la distribuzione della statistica $T = T(\underline{y})$ è:

$$T \sim \mathcal{N}(Nx, N\sigma^2)$$

L'obiettivo del blocco è dimostrare formalmente che la statistica sufficiente $T(\underline{y}) = \sum_{i=1}^{N} y_i$ è **completa**.

2.2 Impostazione della Condizione di Completezza

Per verificare che $T(\underline{y})$ sia una **Statistica Sufficiente Completa (SSC)**, dobbiamo applicare la definizione di completezza. Occorre mostrare che, data una generica funzione misurabile $g(\cdot)$ indipendente da x, vale la seguente implicazione:

$$\mathbb{E}_x[g(T)] = 0 \quad \forall x \in \mathbb{R} \implies g(T) = 0 \quad \text{q.c.}$$

Sostituendo la densità di probabilità della variabile gaussiana $T \sim \mathcal{N}(Nx, N\sigma^2)$, l'aspettativa si esprime come l'integrale definito su tutto l'asse reale:

$$\mathbb{E}_x[g(T)] = \int_{-\infty}^{+\infty} g(t) \, \frac{1}{\sqrt{2\pi N\sigma^2}} \exp\left(-\frac{(t-Nx)^2}{2N\sigma^2}\right) dt = 0 \quad \forall x \in \mathbb{R}$$

Poiché la costante $\frac{1}{\sqrt{2\pi N\sigma^2}}$ è strettamente positiva, possiamo ometterla semplificandola nell'equazione:

$$\int_{-\infty}^{+\infty} g(t) \, \exp\left(-\frac{(t-Nx)^2}{2N\sigma^2}\right) dt = 0 \quad \forall x \in \mathbb{R}$$

2.3 Riformulazione dell'Integrale come Prodotto di Convoluzione

Espandiamo il quadrato al numeratore dell'esponenziale:

$$(t-Nx)^2 = t^2 - 2Nxt + N^2x^2$$

Sostituendo l'espansione nell'integrale otteniamo:

$$\int_{-\infty}^{+\infty} g(t) \, \exp\left(-\frac{t^2}{2N\sigma^2}\right) \exp\left(\frac{xt}{\sigma^2}\right) \exp\left(-\frac{Nx^2}{2\sigma^2}\right) dt = 0$$

Poiché il termine $\exp\left(-\frac{Nx^2}{2\sigma^2}\right)$ dipende solo da x e non dall'variabile di integrazione t, possiamo portarlo fuori dall'integrale e semplificarlo (essendo un esponenziale reale strettamente maggiore di zero per ogni x):

$$\int_{-\infty}^{+\infty} \left[g(t) \exp\left(-\frac{t^2}{2N\sigma^2}\right)\right] \exp\left(\frac{xt}{\sigma^2}\right) dt = 0 \quad \forall x \in \mathbb{R}$$

2.4 Dimostrazione mediante Trasformata di Fourier

Definiamo la funzione ausiliaria $h(t)$ come:

$$h(t) = g(t) \exp\left(-\frac{t^2}{2N\sigma^2}\right)$$

Sostituendo $h(t)$ nell'equazione, si ottiene:

$$\int_{-\infty}^{+\infty} h(t) \exp\left(\frac{xt}{\sigma^2}\right) dt = 0 \quad \forall x \in \mathbb{R}$$

Eseguiamo un cambio di variabile nel dominio dei parametri ponendo la variabile complessa/frequenziale ω:

$$u = -\frac{x}{\sigma^2} \implies \frac{x}{\sigma^2} = -u$$

L'equazione diventa:

$$\int_{-\infty}^{+\infty} h(t) e^{-ut} dt = 0 \quad \forall u \in \mathbb{R}$$

Estendendo il parametro u lungo l'asse immaginario ($u = j\omega$), l'integrale a sinistra coincide esattamente con la **Trasformata di Fourier Bilatera** della funzione $h(t)$:

$$\mathcal{F}\{h(t)\}(\omega) = \int_{-\infty}^{+\infty} h(t) e^{-j\omega t} dt = 0 \quad \forall \omega \in \mathbb{R}$$

Poiché la trasformata di Fourier di $h(t)$ è identicamente nulla per ogni frequenza ω, per le proprietà dell'antitrasformata di Fourier e l'unicità della trasformata di Schwarz/L2, la funzione originale $h(t)$ deve essere quasi certamente nulla su tutto il dominio reale:

$$h(t) = 0 \quad \text{q.c.} \quad \forall t \in \mathbb{R}$$

Ricordando la definizione di $h(t)$:

$$g(t) \exp\left(-\frac{t^2}{2N\sigma^2}\right) = 0 \quad \text{q.c.}$$

Poiché l'esponenziale gaussiano $\exp\left(-\frac{t^2}{2N\sigma^2}\right) > 0$ per qualsiasi valore di $t \in \mathbb{R}$, l'unica soluzione ammissibile è:

$$g(t) = 0 \quad \text{q.c.}$$

2.5 Conclusione del Blocco

Abbiamo dimostrato che l'unica trasformazione $g(\cdot)$ che soddisfa l'uguaglianza $\mathbb{E}_x[g(T)] = 0$ per ogni valore del parametro incognito $x \in \mathbb{R}$ è la funzione quasi certamente nulla $g(t) = 0$.

Di conseguenza:

1. La statistica $T(\underline{y}) = \sum_{i=1}^{N} y_i$ è una **Statistica Sufficiente Completa (SSC)** per la media x .
2. Per il Teorema di Equivalenza Funzionale dimostrato nel Blocco 1, $T(\underline{y}) = \sum_{i=1}^{N} y_i$ è anche una **Statistica Sufficiente Minimale (SSM)**.

Blocco 3: Famiglia Esponenziale Regolare (K-PEC) e Teorema di Individuazione

3.1 Definizione della Famiglia Esponenziale K-Parametrica (K-PEC)

La **Famiglia Esponenziale Regolare** (spesso indicata come *K-Parameter Exponential Class* o **K-PEC**) rappresenta una classe fondamentale di distribuzioni di probabilità per cui l'individuazione della statistica sufficiente e completa avviene direttamente per ispezione algebrica della struttura della funzione di densità di probabilità (PDF).

Definizione Formale

Un modello di osservazioni $\underline{y} = [y_1, y_2, \dots, y_N]^T \in \mathcal{Y} \subseteq \mathbb{R}^N$ dipendente da un vettore di parametri incogniti $\underline{x} = [x_1, x_2, \dots, x_K]^T \in \mathcal{X} \subseteq \mathbb{R}^K$ appartiene alla **Famiglia Esponenziale K-Parametrica** se la sua PDF (o PMF) congiunta può essere scritta nella seguente forma canonica fattorizzata:

$$f_{\underline{Y}}(\underline{y}; \underline{x}) = C(\underline{x}) \, \exp\left(\sum_{k=1}^{K} A_k(\underline{x}) \, T_k(\underline{y}) \right) h(\underline{y})$$

dove:

- $C(\underline{x}) \geq 0$ è una funzione scalare non negativa che dipende esclusivamente dal vettore dei parametri $\underline{x}$ (agisce come costante di normalizzazione affinché l'integrale/somma della densità sia pari a 1).
- $\{A_k(\underline{x})\}_{k=1}^K$ sono K funzioni scalari reali del solo parametro $\underline{x}$, dette *parametri naturali* o *canonici*.
- $\{T_k(\underline{y})\}_{k=1}^K$ sono K funzioni reali del solo vettore di osservazioni $\underline{y}$, indipendenti dal parametro $\underline{x}$.
- $h(\underline{y}) \geq 0$ è una funzione non negativa delle sole osservazioni $\underline{y}$, indipendente da $\underline{x}$.

Condizioni di Regolarità

La famiglia si definisce **regolare** se:

1. Il supporto della densità $\mathcal{S}_{\underline{y}} = \{\underline{y} \in \mathcal{Y} : f_{\underline{Y}}(\underline{y}; \underline{x}) > 0\}$ non dipende dal parametro incognito $\underline{x}$.
2. Lo spazio dei parametri naturali $\mathcal{A} = \{(A_1(\underline{x}), \dots, A_k(\underline{x})) : \underline{x} \in \mathcal{X}\}$ contiene un insieme aperto K-dimensionale in $\mathbb{R}^K$ (assenza di relazioni di dipendenza lineare o vincoli degeneri tra le funzioni $A_k(\underline{x})$).

3.2 Teorema di Individuazione della Statistica Sufficiente Completa (SSC)

Sotto le condizioni di regolarità della Famiglia Esponenziale K-Parametrica, è possibile determinare immediatamente una statistica sufficiente completa e minimale mediante ispezione diretta della forma analitica della PDF.

Enunciato del Teorema

Se la densità di probabilità $f_{\underline{Y}}(\underline{y};\underline{x})$ appartiene a una **Famiglia Esponenziale K-Parametrica Regolare**, allora il vettore costituito dalle K funzioni $\{T_k(\underline{y})\}_{k=1}^{K}$:

$$\underline{T}(\underline{y}) = \begin{bmatrix} T_1(\underline{y}) \\ T_2(\underline{y}) \\ \vdots \\ T_K(\underline{y}) \end{bmatrix}$$

è una **Statistica Sufficiente Completa (SSC)** e, per il Teorema di Equivalenza Funzionale (dimostrato nel Blocco 1), è anche una **Statistica Sufficiente Minimale (SSM)** per il vettore di parametri $\underline{x}$.

3.3 Applicazione ed Esempio: Modello Gaussiano con Media e Varianza Incognite

Per illustrare il teorema, applichiamo la formulazione K-PEC al caso di N osservazioni i.i.d. distribuite secondo una gaussiana in cui sia la media che la varianza sono incognite.

Modellizzazione

Sia $\underline{y} = [y_1, y_2, \ldots, y_N]^T$ con $y_i \sim \mathcal{N}(\mu, \sigma^2)$ indipendenti, dove il vettore di parametri incogniti è:

$$\underline{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \mu \\ \sigma^2 \end{bmatrix} \in \mathbb{R} \times \mathbb{R}^+ \quad (K = 2)$$

La PDF congiunta delle osservazioni si esprime come:

$$f_{\underline{Y}}(\underline{y};\underline{x}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^{N} (y_i - \mu)^2 \right)$$

Mappatura nella Forma Canonica K-PEC

Espandiamo il termine quadratico nella sommatoria:

$$\sum_{i=1}^{N} (y_i - \mu)^2 = \sum_{i=1}^{N} y_i^2 - 2\mu \sum_{i=1}^{N} y_i + N\mu^2$$

Sostituendo l'espansione nell'esponenziale:

$$f_{\underline{Y}}(\underline{y};\underline{x}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left(-\frac{N\mu^2}{2\sigma^2} \right) \exp\left(\frac{\mu}{\sigma^2} \sum_{i=1}^{N} y_i - \frac{1}{2\sigma^2} \sum_{i=1}^{N} y_i^2 \right)$$

Possiamo ora identificare ciascun fattore della struttura K-PEC ($K = 2$):

1. **Termine parametrico** $C(\underline{x})$:

$$C(\underline{x}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp\left(-\frac{N\mu^2}{2\sigma^2}\right)$$

2. **Parametri naturali $A_1(\underline{x})$ e $A_2(\underline{x})$:**

$$A_1(\underline{x}) = \frac{\mu}{\sigma^2}, \quad A_2(\underline{x}) = -\frac{1}{2\sigma^2}$$

3. **Componenti della Statistica $T_1(\underline{y})$ e $T_2(\underline{y})$:**

$$T_1(\underline{y}) = \sum_{i=1}^{N} y_i, \quad T_2(\underline{y}) = \sum_{i=1}^{N} y_i^2$$

4. **Termine $h(\underline{y})$:**

$$h(\underline{y}) = 1$$

3.4 Conclusione dell'Esempio e del Blocco

Dall'applicazione diretta del Teorema di Individuazione per la Famiglia Esponenziale K-Parametrica ($K = 2$), ricaviamo che la statistica vettoriale:

$$\underline{T}(\underline{y}) = \begin{bmatrix} T_1(\underline{y}) \\ T_2(\underline{y}) \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^{N} y_i \\ \sum_{i=1}^{N} y_i^2 \end{bmatrix}$$

è una **Statistica Sufficiente Completa (SSC)** e **Minimale (SSM)** per la coppia di parametri $\underline{x} = [\mu, \sigma^2]^T$.

Qualsiasi altra trasformazione invertibile di $\underline{T}(\underline{y})$, come la coppia costituita dalla media campionaria e dalla varianza campionaria $\left(\bar{y}, S^2\right)$, rappresenta anch'essa una Statistica Sufficiente Completa e Minimale per il modello.

Blocco 4: Introduzione alla Teoria della Classificazione (Non-Bayesiana vs Bayesiana)

4.1 Modello del Sistema di Decisione e Spazio delle Ipotesi

La teoria della classificazione (o decisione) affronta il problema di assegnare un vettore di osservazioni continue o discrete $\underline{y} \in \mathcal{Y} \subseteq \mathbb{R}^N$ a una tra M possibili classi discrete o ipotesi esclusive:

$$\mathcal{H}_i : \underline{x} = \underline{x}_i, \quad i = 0, 1, \ldots, M-1$$

dove $\underline{x} \in \mathcal{X} = \{\underline{x}_0, \underline{x}_1, \ldots, \underline{x}_{M-1}\}$ rappresenta il vettore del segnale trasmesso (o la classe di appartenenza).

Un **classificatore (o regola di decisione)** è definito da una funzione deterministica $d(\underline{y})$ che mappa lo spazio delle osservazioni $\mathcal{Y}$ nello spazio delle decisioni $\mathcal{X}$:

$$d(\underline{y}) : \mathcal{Y} \to \mathcal{X}$$

4.2 Partizionamento dello Spazio degli Osservabili

La regola di decisione $d(\underline{y})$ indotta dal sistema equivale a una partizione dello spazio osservabile $\mathcal{Y}$ in M regioni di decisione disgiunte $\mathcal{R}_0, \mathcal{R}_1, \ldots, \mathcal{R}_{M-1}$ tali che:

1. $\bigcup_{i=0}^{M-1} \mathcal{R}_i = \mathcal{Y}$ (copertura completa dello spazio campionario)
2. $\mathcal{R}_i \cap \mathcal{R}_j = \emptyset, \quad \forall i \neq j$ (regioni mutuamente esclusive)

La regola di assegnazione associata alla partizione è:

$$d(\underline{y}) = \underline{x}_i \iff \underline{y} \in \mathcal{R}_i$$

L'obiettivo della progettazione del classificatore è determinare i confini di decisione delle regioni $\mathcal{R}_i$ in modo da ottimizzare una determinata metrica di prestazione (es. minimizzare la probabilità d'errore o il rischio medio).

4.3 Metriche di Costo e Funzioni di Perdita

Per valutare la bontà di una decisione $\underline{\hat{x}} = d(\underline{y})$ rispetto al vero segnale emesso $\underline{x}$, si introduce la **funzione di costo** (o funzione di perdita) $C(\underline{x}, \underline{\hat{x}})$.

1. Distanza di Hamming

La **distanza di Hamming** $d_H(\underline{x}, \underline{\hat{x}})$ misura il numero di elementi (o bit/simboli) in cui le componenti del vettore stimato $\underline{\hat{x}}$ differiscono da quelle del vettore trasmesso $\underline{x}$:

$$d_H(\underline{x}, \underline{\hat{x}}) = \sum_{k=1}^{K} I_{\{x_k \neq \hat{x}_k\}}$$

dove $I_{\{\cdot\}}$ è la funzione indicatrice.

2. Costo Uniforme (Funzione Indicatrice d'Errore)

Nel caso di classificazione a blocchi o di simboli discreti in cui tutte le decisioni errate sono equivalenti, si adotta la funzione di costo 0-1 (o costo uniforme):

$$C(\underline{x}, \underline{\hat{x}}) = I_{\{\underline{x} \neq \underline{\hat{x}}\}} = \begin{cases} 0 & \text{se } \underline{\hat{x}} = \underline{x} \quad (\text{decisione corretta}) \\ 1 & \text{se } \underline{\hat{x}} \neq \underline{x} \quad (\text{decisione errata}) \end{cases}$$

4.4 Probabilità di Decisione Corretta e d'Errore

Probabilità di Corretta Decisione Condizionata

Sotto l'ipotesi $\mathcal{H}_i$ (ovvero dato che sia stato trasmesso $\underline{x} = \underline{x}_i$), la probabilità di prendere una decisione corretta $P_{c|i}$ coincide con la probabilità che il vettore di osservazione $\underline{y}$ cada nella regione di decisione associata $\mathcal{R}_i$:

$$P_{c|i} = P(d(\underline{y}) = \underline{x}_i \mid \mathcal{H}_i) = P(\underline{y} \in \mathcal{R}_i \mid \underline{x} = \underline{x}_i) = \int_{\mathcal{R}_i} f_{\underline{Y}|\underline{X}}(\underline{y} \mid \underline{x}_i)\, d\underline{y}$$

Probabilità d'Errore Condizionata

La probabilità di commettere un errore dato che sia stato trasmesso il segnale $\underline{x}_i$ è il complemento a 1 della probabilità di corretta decisione:

$$P_{e|i} = 1 - P_{c|i} = P(\underline{y} \notin \mathcal{R}_i \mid \underline{x} = \underline{x}_i) = \sum_{j \neq i} \int_{\mathcal{R}_j} f_{\underline{Y}|\underline{X}}(\underline{y} \mid \underline{x}_i)\, d\underline{y}$$

4.5 Confronto tra Approccio Non-Bayesiano e Bayesiano

I problemi di decisione e classificazione si dividono in due grandi famiglie metodologiche a seconda della natura attribuita al segnale incognito $\underline{x}$:

1. Approccio Non-Bayesiano (Determinista)

- **Ipotesi sul parametro:** Il vettore $\underline{x}$ è un parametro deterministico incognito. Non sono note o non esistono distribuzioni di probabilità *a priori* associate ai possibili stati $\underline{x}_i$.
- **Criteri di Ottimizzazione:** Poiché non è possibile calcolare una probabilità d'errore media marginale, si formulano criteri min-max o vincolati. Nel caso di test di ipotesi binario, si utilizza il **Criterio di Neyman-Pearson**, che fissa la probabilità di falso allarme $P_{FA} \leq \alpha$ e massimizza la probabilità di corretta rilevazione P_D.

2. Approccio Bayesiano (Stocastico)

- **Ipotesi sul parametro:** Il vettore $\underline{x}$ è modellato come una variabile (o vettore) casuale caratterizzata da una **distribuzione di probabilità a priori** nota $P(\underline{x} = \underline{x}_i) = P(\mathcal{H}_i) = \pi_i$, con $\sum_{i=0}^{M-1} \pi_i = 1$.
- **Probabilità d'Errore Media (Bayesiana):** Sfruttando il Teorema della Probabilità Totale, la probabilità media di decisione corretta P_c e la probabilità media d'errore P_e si esprimono come:

$$P_c = \sum_{i=0}^{M-1} \pi_i\, P_{c|i} = \sum_{i=0}^{M-1} \pi_i \int_{\mathcal{R}_i} f_{\underline{Y}|\underline{X}}(\underline{y} \mid \underline{x}_i)\, d\underline{y}$$

$$P_e = 1 - P_c = \sum_{i=0}^{M-1} \pi_i\, P_{e|i}$$

- **Criterio del Minimo Rischio / Minima Probabilità d'Errore (MAP):** L'obiettivo Bayesiano fondamentale è la scelta della partizione $\{\mathcal{R}_i\}_{i=0}^{M-1}$ che minimizza la

probabilità media d'errore P_e (o che massimizza la probabilità di corretta decisione P_c). Per il criterio del **Maximum A Posteriori (MAP)**, ogni osservazione $\underline{y}$ viene assegnata alla classe $\underline{x}_i$ che massimizza la probabilità *a posteriori* $P(\mathcal{H}_i \mid \underline{y})$.