ELSD 7

2026-10-09

tags:

- #comunicazioni_digitali
- #teoria_della_decisione
- #neyman_pearson
- #classificazione_statistica
- #signal_processing

Blocco 1: Fondamenti della Decisione Statistica e Matrice delle Prestazioni

1.1 Modello del sistema e spazio degli osservabili

Il problema fondamentale della teoria della decisione e della classificazione riguarda l'estrazione di uno stato discreto non osservabile direttamente a partire da un insieme di misurazioni o osservazioni affette da incertezza o rumore.

Il modello generale del sistema è strutturato secondo la seguente catena concettuale:

- **Stato reale** x: rappresenta la grandezza fisica o la classe di interesse. Lo stato può essere scalare o vettoriale, continuo o discreto, ed essere modellato come una variabile aleatoria oppure come un parametro deterministico ma ignoto. Nel contesto della **classificazione**, lo stato x appartiene a un insieme discreto $\mathcal{X}$ con cardinalità finita Q, ossia $|\mathcal{X}| = Q$:

$$\mathcal{X} = \{x_1, x_2, \dots, x_Q\}$$

- **Canale/Schema di osservazione**: regola la dipendenza fisica e statistica tra lo stato x e l'osservabile.
- **Vettore delle osservazioni** $\mathbf{y}$: rappresenta il dato misurato a valle dello schema di osservazione. Generalmente $\mathbf{y} \in \mathcal{A}_{\mathbf{y}} \subseteq \mathbb{R}^N$, dove $\mathcal{A}_{\mathbf{y}}$ costituisce lo **spazio degli osservabili** (N-dimensionale e continuo).
- **Regola di decisione** $d(\mathbf{y}) = \hat{x}$: è la funzione (o algoritmo di classificazione) che elabora il vettore continuo $\mathbf{y}$ e restituisce una stima discreta $\hat{x} \in \mathcal{X}$ dello stato reale.

Poiché $d(\mathbf{y})$ mappa uno spazio continuo N-dimensionale $\mathcal{A}_{\mathbf{y}}$ su un insieme discreto di cardinalità Q, la funzione di decisione non può essere iniettiva. Essa induce

matematicamente una **partizione** dello spazio degli osservabili $\mathcal{A}_{\mathbf{y}}$ in Q sottoinsiemi disgiunti $A_1, A_2, \ldots, A_Q$ (detti anche *regioni di decisione* o Z_i), tali per cui:

1. **Mutua esclusività (regioni disgiunte):**

$$A_i \cap A_j = \emptyset \quad \forall i \neq j$$

2. **Copertura dello spazio degli osservabili:**

$$\bigcup_{i=1}^{Q} A_i = \mathcal{A}_{\mathbf{y}}$$

La regola di decisione equivale all'assegnazione:

$$\text{Se } \mathbf{y} \in A_i \implies d(\mathbf{y}) = H_i \quad (\text{ovvero } \hat{x} = x_i)$$

Formulazione generalizzata tramite Ipotesi (H_i)

In molti casi pratici, lo stato x non assume un singolo valore discreto isolato, ma appartiene a un sottoinsieme di stati $X_i \subset \mathcal{X}$. L'effetto dell'appartenenza a X_i si riflette in un'unica caratterizzazione statistica sulle osservazioni $\mathbf{y}$. Si definisce pertanto l' i**-esima ipotesi** H_i come l'evento $x \in X_i$.

La dipendenza statistica dell'osservabile dall'ipotesi verificatasi è descritta dalla **funzione di densità di probabilità (PDF) condizionata**:

$$f(\mathbf{y}|H_i)$$

Il problema di classificazione si riduce quindi a determinare a quale ipotetica PDF condizionata $f(\mathbf{y}|H_i)$ appartenga il vettore misurato $\mathbf{y}$, individuando la regione A_i a cui esso pertiene.

1.2 Inquadramento metodologico: Approccio Bayesiano vs Non-Bayesiano

La progettazione della regola di decisione $d(\mathbf{y})$ e la scelta della partizione $\{A_i\}_{i=1}^{Q}$ dipendono dall'informazione a priori disponibile sullo stato x. Si distinguono due approcci fondamentali:

1. **Approccio Non-Bayesiano (Frequentista)**

Si applica quando lo stato x (o l'ipotesi H_i) è un parametro deterministico ignoto, oppure quando le probabilità con cui le classi si verificano non sono note a priori né stimabili.

- Non si definisce alcuna distribuzione di probabilità a priori sulle ipotesi H_i.
- Il condizionamento $f(\mathbf{y}|H_i)$ va inteso in senso strettamente parametrico/funzionale.
- Il criterio di decisione deve basarsi unicamente sulla verosimiglianza dei dati osservati sotto ciascuna ipotesi (es. Criterio di Neyman-Pearson o Maximum Likelihood).

2. **Approccio Bayesiano**

Si applica quando lo stato x è modellabile come una variabile aleatoria e si conosce la **probabilità a priori** $P(H_i)$ del verificarsi di ciascuna ipotesi prima di effettuare la misurazione:

$$\sum_{i=1}^{Q} P(H_i) = 1$$

Dopo aver osservato il vettore $\mathbf{y}$, l'informazione viene aggiornata calcolando la **probabilità a posteriori** $P(H_i|\mathbf{y})$ tramite il Teorema di Bayes:

$$P(H_i|\mathbf{y}) = \frac{f(\mathbf{y}|H_i)P(H_i)}{f(\mathbf{y})} = \frac{f(\mathbf{y}|H_i)P(H_i)}{\sum_{j=1}^{Q} f(\mathbf{y}|H_j)P(H_j)}$$

1.3 Matrice delle Prestazioni e Impossibilità del Classificatore Ideale

Definizioni e Matrice delle Prestazioni $\mathbf{P}$

Per valutare la bontà di un classificatore, si calcolano le probabilità condizionate di decisione. La probabilità di decidere per l'ipotesi H_j dato che si è verificata l'ipotesi reale H_i è definita dall'integrale della PDF condizionata $f(\mathbf{y}|H_i)$ sulla regione di decisione A_j:

$$P(d(\mathbf{y}) = H_j|H_i) \triangleq P(j|i) = \int_{A_j} f(\mathbf{y}|H_i)\, d\mathbf{y}$$

(Nel caso di osservabili discreti, l'integrale si sostituisce con la sommatoria della massa di probabilità $\sum_{\mathbf{y}\in A_j} p(\mathbf{y}|H_i)$).

Raccogliendo tutti i possibili termini $P(j|i)$ per $i, j \in \{1, \dots, Q\}$, si definisce la **Matrice delle Prestazioni** $\mathbf{P}$ di dimensione $Q \times Q$:

[\mathbf{P} = \begin{bmatrix} P(1|1) & P(1|2) & \dots & P(1|Q) \ P(2|1) & P(2|2) & \dots & P(2|Q) \ \vdots & \vdots & \ddots & \vdots \ P(Q|1) & P(Q|2) & \dots & P(Q|Q) \end{bmatrix}]

- **Elementi sulla diagonale principale ($j = i$):** rappresentano le probabilità di **corretta decisione** condizionata $P(c|H_i) = P(i|i)$.
- **Elementi fuori diagonale ($j \neq i$):** rappresentano le probabilità di **decisione errata** condizionata $P(e|H_i) = \sum_{j \neq i} P(j|i) = 1 - P(i|i)$.

Proprietà Stocastica per Colonna

Poiché le regioni $\{A_j\}_{j=1}^{Q}$ costituiscono una partizione esaustiva e disgiunta dello spazio $\mathcal{A}_{\mathbf{y}}$, per ogni colonna fissata i vale la relazione:

$$\sum_{j=1}^{Q} P(j|i) = \sum_{j=1}^{Q} \int_{A_j} f(\mathbf{y}|H_i)\, d\mathbf{y} = \int_{\mathcal{A}_{\mathbf{y}}} f(\mathbf{y}|H_i)\, d\mathbf{y} = 1$$

Questa proprietà implica che la trasposta della matrice delle prestazioni $\mathbf{P}^T$ ammette come autovettore il vettore unitario $\underline{1} = [1, 1, \ldots, 1]^T$ associato all'autovalore $\lambda = 1$:

$$\mathbf{P}^T \underline{1} = \underline{1}$$

Classificazione Binaria ($Q = 2$)

Nel caso di classificazione binaria, le ipotesi vengono tradizionalmente indicate con H_0 (ipotesi nulla o assenza di bersaglio/segnale) ed H_1 (ipotesi alternativa o presenza di bersaglio/segnale).

Le quattro probabilità condizionate assumono la seguente terminologia operativa:

1. **Probabilità di Detezione (Detection):**
$$P_D \triangleq P(1|1) = \int_{A_1} f(\mathbf{y}|H_1)\, d\mathbf{y}$$
2. **Probabilità di Falso Allarme (False Alarm):**
$$P_{FA} \triangleq P(1|0) = \int_{A_1} f(\mathbf{y}|H_0)\, d\mathbf{y}$$
3. **Probabilità di Miss (Mancata Detezione):**
$$P_M \triangleq P(0|1) = \int_{A_0} f(\mathbf{y}|H_1)\, d\mathbf{y} = 1 - P_D$$
4. **Probabilità di Corretta Decisione sotto H_0:**
$$P(0|0) = \int_{A_0} f(\mathbf{y}|H_0)\, d\mathbf{y} = 1 - P_{FA}$$

La matrice delle prestazioni binaria si esprime come:

$$[\mathbf{P} = [P(0|0) \quad P(0|1)\, P(1|0) \quad P(1|1)] = [1 - P_{FA} \quad 1 - P_D\, P_{FA} \quad P_D]]$$

Dimostrazione dell'Impossibilità del Classificatore Ideale

Un classificatore perfetto (o ideale) dovrebbe avere una matrice delle prestazioni identica alla matrice identità $\mathbf{I}$, ovvero:

$$\mathbf{P}_{\text{ideale}} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \implies P_D = 1 \quad \text{e} \quad P_{FA} = 0$$

Dimostriamo analiticamente perché questa condizione non è fisicamente realizzabile quando i supporti delle densità di probabilità $f(\mathbf{y}|H_0)$ e $f(\mathbf{y}|H_1)$ si sovrappongono.

Dimostrazione:
Supponiamo di voler massimizzare la Probabilità di Detezione P_D senza porre alcun vincolo:

$$P_D = \int_{A_1} f(\mathbf{y}|H_1)\, d\mathbf{y} = 1$$

Affinché l'integrale di una densità di probabilità su una regione A_1 sia pari a 1, la regione di decisione A_1 deve necessariamente contenere l'intero supporto della PDF $f(\mathbf{y}|H_1)$. Nel caso di distribuzioni a supporto illimitato (come le gaussiane), ciò impone che la regione A_1 coincida con l'intero spazio degli osservabili:

$$A_1 = \mathcal{A}_{\mathbf{y}}$$

Di conseguenza, la regione complementare $A_0 = \mathcal{A}_{\mathbf{y}} \setminus A_1$ diventa l'insieme vuoto:

$$A_0 = \emptyset$$

Calcoliamo ora la probabilità di corretta decisione sotto H_0:

$$P(0|0) = \int_{A_0} f(\mathbf{y}|H_0)\, d\mathbf{y} = \int_{\emptyset} f(\mathbf{y}|H_0)\, d\mathbf{y} = 0$$

Essendo $P(0|0) = 1 - P_{FA}$, ne consegue direttamente che:

$$1 - P_{FA} = 0 \implies P_{FA} = 1$$

Conclusione concettuale:
Senza un vincolo esplicito, la massimizzazione incondizionata della Detezione ($P_D \to 1$)

porta ad assegnare qualsiasi osservazione alla regione A_1, saturando al 100% anche il Falso Allarme ($P_{FA} \to 1$).

Questo risultato fondamentale dimostra che **non è possibile ottimizzare separatamente** P_D **e** P_{FA} **in modo indipendente**. Tale incompatibilità analitica impone di abbandonare i criteri di ottimizzazione libera e formalizzare il problema come un'**ottimizzazione vincolata**, ponendo un tetto massimo al Falso Allarme ($P_{FA} \leq \alpha$) e massimizzando P_D sotto tale vincolo (Criterio di Neyman-Pearson).

Blocco 2: Criterio di Neyman-Pearson e Test del Rapporto di Verosimiglianza (LRT)

2.1 Formulazione dell'ottimizzazione vincolata

Come dimostrato nel Blocco 1, la massimizzazione incondizionata della Probabilità di Detezione (P_D) conduce alla scelta triviale $A_1 = \mathcal{A}_{\mathbf{y}}$, che satura la Probabilità di Falso Allarme al valore unitario ($P_{FA} = 1$)2. Per progettare un classificatore binario con reali capacità discriminative, è necessario formulare un problema di **ottimizzazione vincolata**3.

Nel contesto radar/sonar così come nella teoria dei test d'ipotesi statistici (Statistical Learning), i due parametri di prestazione prendono il nome di4:

- **Potenza del test / Classificatore**: coincide con la Probabilità di Detezione $P_D = P(d(\mathbf{y}) = H_1 | H_1)$.
- **Significatività del test**: coincide con la Probabilità di Falso Allarme $P_{FA} = P(d(\mathbf{y}) = H_1 | H_0)$.

Il **Criterio di Neyman-Pearson** stabilisce che la regola di decisione ottima $d^*(\mathbf{y})$ è quella che massimizza la potenza del test (P_D) mantenendo il livello di significatività (P_{FA}) al di sotto o uguale a una soglia massima tollerabile $\alpha \in (0, 1)$ stabilita a priori dal progettista:

$$\max_{A_1} P_D \quad \text{sotto il vincolo} \quad P_{FA} \leq \alpha$$

L'oggetto dell'ottimizzazione non è un singolo valore numerico, bensì la **regione di decisione** A_1 (ovvero Z_1) nello spazio multidimensionale delle osservazioni $\mathcal{A}_{\mathbf{y}}$\$5.$Essendolapartizionebinariaesaustiva,laregionecomplementaresaràdeterminatadirettam$ $= \mathcal{A}_{\mathbf{y}} \setminus A_1$.

Esplicitando i due parametri tramite gli integrali delle rispettive funzioni di densità di probabilità (PDF) condizionate sulla regione A_1, il problema si formalizza come:

$$\max_{A_1} \int_{A_1} f(\mathbf{y}|H_1)\, d\mathbf{y} \quad \text{sotto il vincolo} \quad \int_{A_1} f(\mathbf{y}|H_0)\, d\mathbf{y} \leq \alpha$$

2.2 Risoluzione mediante Moltiplicatori di Lagrange

Per convertire il problema di ottimo vincolato in un problema non vincolato, si introduce un **moltiplicatore di Lagrange** non negativo $\lambda \geq 0$ e si costruisce la funzione **Lagrangiana** $J(A_1, \lambda)$:

$$J(A_1, \lambda) = P_D + \lambda(\alpha - P_{FA})$$

Analizzando la struttura della Lagrangiana, si osserva che:

- Se la regione A_1 viene scelta in modo tale che il vincolo sia soddisfatto ($P_{FA} \leq \alpha$), il termine $(\alpha - P_{FA})$ risulta non negativo8.
- Se invece A_1 fa sconfinare il Falso Allarme oltre la soglia ($P_{FA} > \alpha$), il secondo termine diventa negativo, penalizzando il valore complessivo della funzione $J(A_1, \lambda)$9.

Di conseguenza, massimizzare la Lagrangiana $J(A_1, \lambda)$ rispetto alla regione A_1 per un opportuno valore di λ garantisce l'individuazione della regione ottima A_1^* che risolve il problema vincolato originale10.

Sostituendo le definizioni integrali di P_D e P_{FA} all'interno della Lagrangiana, otteniamo:

$$J(A_1, \lambda) = \int_{A_1} f(\mathbf{y}|H_1)\, d\mathbf{y} + \lambda \left(\alpha - \int_{A_1} f(\mathbf{y}|H_0)\, d\mathbf{y} \right)$$

Sfruttando la linearità dell'operatore di integrazione e raggruppando i termini sotto un unico integrale esteso al dominio A_1, la Lagrangiana assume la forma espressiva fondamentale112:

$$J(A_1, \lambda) = \int_{A_1} [f(\mathbf{y}|H_1) - \lambda f(\mathbf{y}|H_0)]\, d\mathbf{y} + \lambda\alpha$$

Il termine $\lambda\alpha$ è una costante indipendente dalla scelta del dominio A_1. Pertanto, la massimizzazione di $J(A_1, \lambda)$ equivale a massimizzare esclusivamente il valore dell'integrale.

2.3 Derivazione della regola di decisione (LRT) e Lemma di Neyman-Pearson

Poiché la funzione integranda $f(\mathbf{y}|H_1) - \lambda f(\mathbf{y}|H_0)$ viene valutata punto per punto su ciascun elemento del vettore osservato $\mathbf{y}$, l'integrale risulta massimo se e solo se la regione di integrazione A_1 include **tutti e soli** i punti dello spazio $\mathcal{A}_\mathbf{y}$ per i quali la quantità integranda è non negativa:

$$\mathbf{y} \in A_1 \iff f(\mathbf{y}|H_1) - \lambda f(\mathbf{y}|H_0) \geq 0$$

Riorganizzando la disuguaglianza (ipotesi di supporto non nullo per $f(\mathbf{y}|H_0)$):

$$f(\mathbf{y}|H_1) \geq \lambda f(\mathbf{y}|H_0) \iff \frac{f(\mathbf{y}|H_1)}{f(\mathbf{y}|H_0)} \geq \lambda$$

Si definisce **Rapporto di Verosimiglianza** (od *Likelihood Ratio*) la quantità scalare $\mathcal{L}(\mathbf{y})$ resa dal rapporto tra le due densità di probabilità condizionate valutate per il vettore misurato $\mathbf{y}$:

$$\mathcal{L}(\mathbf{y}) \triangleq \frac{f(\mathbf{y}|H_1)}{f(\mathbf{y}|H_0)}$$

Il rapporto prende il nome di *verosimiglianza* in quanto, una volta effettuata la misura, il vettore $\mathbf{y}$ è fisicamente determinato, mentre le funzioni $f(\mathbf{y}|H_1)$ e $f(\mathbf{y}|H_0)$ vengono considerate come funzioni parametriche dipendenti dalle rispettive ipotesi H_1 ed H_0.

Il Lemma di Neyman-Pearson e il Test del Rapporto di Verosimiglianza (LRT)

Il risultato ottenuto costituisce l'enunciato del **Lemma di Neyman-Pearson**: il classificatore di massima potenza soggetto a un vincolo di Falso Allarme $P_{FA} \leq \alpha$ è un **Test del Rapporto di Verosimiglianza** (*Likelihood Ratio Test*, LRT), la cui regola di decisione è1more_horiz:

$$\mathcal{L}(\mathbf{y}) = \frac{f(\mathbf{y}|H_1)}{f(\mathbf{y}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda$$

La regola di decisione sintetica si interpreta come segue:

- Se $\mathcal{L}(\mathbf{y}) > \lambda$, il vettore delle osservazioni $\mathbf{y}$ pertiene alla regione A_1 e si decide per l'ipotesi H_1 (presenza del segnale/bersaglio).
- Se $\mathcal{L}(\mathbf{y}) < \lambda$, il vettore $\mathbf{y}$ pertiene alla regione A_0 e si decide per l'ipotesi H_0 (assenza del segnale).
- Se $\mathcal{L}(\mathbf{y}) = \lambda$, la scelta della classe è indifferente (evento a probabilità nulla per variabili casuali continue).

Determinazione della Soglia Ottima λ

Il moltiplicatore di Lagrange λ funge da **soglia di decisione** del test. Per garantire che il classificatore operi esattamente al limite del vincolo di significatività imposto (condizione necessaria per ottenere la massima potenza P_D), la soglia λ deve essere calcolata risolvendo l'equazione implicita:

$$P_{FA}(\lambda) = \int_{A_1(\lambda)} f(\mathbf{y}|H_0)\, d\mathbf{y} = \int_{\{\mathbf{y}:\mathcal{L}(\mathbf{y})\geq\lambda\}} f(\mathbf{y}|H_0)\, d\mathbf{y} = \alpha$$

Nel caso di osservabili continui, la continuità della funzione $P_{FA}(\lambda)$ assicura l'esistenza e l'univocità della soglia λ che soddisfa l'uguaglianza $P_{FA} = \alpha$.

Blocco 3: Invarianza, Log-LRT e Riduzione a Statistica Scalare

3.1 Invarianza e trasformazioni monotone

Il Test del Rapporto di Verosimiglianza (LRT) derivato dal Criterio di Neyman-Pearson impone di valutare la disuguaglianza:

$$\mathcal{L}(\mathbf{y}) = \frac{f(\mathbf{y}|H_1)}{f(\mathbf{y}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda$$

Dal punto di vista dell'analisi delle decisioni, la partizione dello spazio degli osservabili $\mathcal{A}_{\mathbf{y}}$ indotta da questo test è definita unicamente dall'orientamento e dalla posizione della superficie di confine $\{\mathbf{y} : \mathcal{L}(\mathbf{y}) = \lambda\}$.

Se si applica a entrambi i membri della disuguaglianza una funzione arbitraria $g(\cdot)$ che sia **strettamente crescente** sul dominio dei valori assunti da $\mathcal{L}(\mathbf{y}) \in (0, +\infty)$, l'ordinamento analitico tra i due termini viene preservato senza alcuna alterazione delle regioni di decisione A_1 e A_0.

Proprietà di Invarianza

Sia $g : \mathbb{R}^+ \to \mathbb{R}$ una funzione strettamente crescente, ovvero tale per cui $t_1 > t_2 \iff g(t_1) > g(t_2)$. Il test di decisione trasformato:

$$g(\mathcal{L}(\mathbf{y})) \underset{H_0}{\overset{H_1}{\gtrless}} g(\lambda)$$

è **rigorosamente equivalente** al test di partenza. La regione di decisione A_1 rimane identica:

$$A_1 = \{\mathbf{y} \in \mathcal{A}_{\mathbf{y}} : \mathcal{L}(\mathbf{y}) \geq \lambda\} = \{\mathbf{y} \in \mathcal{A}_{\mathbf{y}} : g(\mathcal{L}(\mathbf{y})) \geq g(\lambda)\}$$

Il Log-Likelihood Ratio (LLR)

La trasformazione monotona crescente di gran lunga più utilizzata nella teoria dell'elaborazione dei segnali è il **logaritmo naturale** $g(t) = \ln(t)$. Applicando il logaritmo al Rapporto di Verosimiglianza si definisce il **Log-Likelihood Ratio (LLR)** $\Lambda(\mathbf{y})$:

$$\Lambda(\mathbf{y}) \triangleq \ln \mathcal{L}(\mathbf{y}) = \ln \left(\frac{f(\mathbf{y}|H_1)}{f(\mathbf{y}|H_0)} \right) = \ln f(\mathbf{y}|H_1) - \ln f(\mathbf{y}|H_0)$$

Il test di Neyman-Pearson espresso in forma logaritmica assume la struttura:

$$\Lambda(\mathbf{y}) \underset{H_0}{\overset{H_1}{\gtrless}} \gamma \quad \text{con} \quad \gamma = \ln \lambda$$

Vantaggi operativi dell'uso del Logaritmo:

1. **Semplificazione di distribuzioni esponenziali e Gaussiane:** Molte densità di probabilità fisiche (come la Gaussiana multivariata) contengono termini esponenziali $\exp(\cdot)$. L'applicazione del logaritmo elimina la funzione esponenziale, trasformando esponenti complessi in combinazioni algebriche lineari o quadratiche.
2. **Conversione di prodotti in somme:** In presenza di N misurazioni statisticamente indipendenti, la PDF congiunta è il prodotto delle singole PDF marginali $f(\mathbf{y}|H_i) = \prod_{n=1}^{N} f(y_n|H_i)$. Il logaritmo trasforma il prodotto in una sommatoria:

   $$\Lambda(\mathbf{y}) = \sum_{n=1}^{N} \ln f(y_n|H_1) - \sum_{n=1}^{N} \ln f(y_n|H_0)$$

   Questo rende l'algoritmo di classificazione computazionalmente stabile ed esente da problemi di underflow numerico.

3.2 Semplificazione dimensionale: Riduzione alla Statistica Scalare $D(\mathbf{y})$

L'ostacolo principale nell'applicazione diretta del test di Neyman-Pearson risiede nella natura vettoriale e multidimensionale dell'osservabile $\mathbf{y} \in \mathbb{R}^N$. Calcolare la Probabilità di Falso Allarme P_{FA} e determinare analiticamente la soglia λ richiederebbe la risoluzione di un integrale multiplo di dimensione N su un dominio $A_1 \subset \mathbb{R}^N$ dalla geometria complessa:

$$P_{FA} = \int_{A_1} f(\mathbf{y}|H_0)\, d\mathbf{y} = \int_{\{\mathbf{y}:\mathcal{L}(\mathbf{y})\geq\lambda\}} f(\mathbf{y}|H_0)\, d\mathbf{y} = \alpha$$

Attraverso manipolazioni algebriche successive e l'applicazione di opportune trasformazioni monotone (come il logaritmo o la riscalatura per costanti positive), è quasi sempre possibile isolare la dipendenza dai dati osservati $\mathbf{y}$ racchiudendola in un'unica variabile scalare $D(\mathbf{y}) \in \mathbb{R}$, detta **variabile o statistica di decisione**:

$$\mathcal{L}(\mathbf{y}) \geq \lambda \iff \Lambda(\mathbf{y}) \geq \ln \lambda \iff D(\mathbf{y}) \underset{H_0}{\overset{H_1}{\gtrless}} \gamma'$$

dove γ' rappresenta la nuova soglia di decisione equivalente, riparametrata a valle delle trasformazioni algebriche effettuate.

Significato concettuale della riduzione dimensionale:

La variabile di decisione $D(\mathbf{y}) = g(\mathcal{L}(\mathbf{y}))$ effettua una **proiezione non lineare** dallo spazio N-dimensionale delle osservazioni $\mathbb{R}^N$ alla retta reale unidimensionale $\mathbb{R}$.

- La statistica $D(\mathbf{y})$ condensa tutta l'informazione contenuta nel vettore $\mathbf{y}$ necessaria e sufficiente ai fini della classificazione ottima (collegamento con la teoria delle *statistiche sufficienti* di Neyman-Fisher).
- La complessa superficie di decisione N-dimensionale nello spazio $\mathcal{A}_{\mathbf{y}}$ viene mappata semplicemente in un punto di taglio scalare γ' sulla retta reale.

3.3 Calcolo delle prestazioni nel dominio scalare monodimensionale

Grazie alla riduzione a variabile scalare, il calcolo delle prestazioni del classificatore e la determinazione della soglia ottima non richiedono più integrazioni multidimensionali complesse nello spazio delle osservazioni $\mathbb{R}^N$.

Poiché $D = D(\mathbf{y})$ è una trasformazione del vettore aleatorio $\mathbf{y}$, essa costituisce a sua volta una **variabile aleatoria scalare**, la cui caratterizzazione statistica sotto le due ipotesi è espressa dalle **PDF condizionate monodimensionali**:

- $f_D(d|H_0)$: densità di probabilità della statistica di decisione sotto l'ipotesi nulla H_0.
- $f_D(d|H_1)$: densità di probabilità della statistica di decisione sotto l'ipotesi alternativa H_1.

Formulazione Monodimensionale di P_{FA} e P_D

Nel dominio scalare, la regione di decisione A_1 si riduce all'intervallo semiretto $[\gamma', +\infty)$. Le probabilità di Falso Allarme e di Detezione assumono la forma integrata monodimensionale:

1. **Probabilità di Falso Allarme (Significatività):**

$$P_{FA} = P(D \geq \gamma'|H_0) = \int_{\gamma'}^{+\infty} f_D(d|H_0)\, dd = \alpha$$

2. **Probabilità di Detezione (Potenza):**

$$P_D = P(D \geq \gamma'|H_1) = \int_{\gamma'}^{+\infty} f_D(d|H_1)\, dd$$

Procedura Operativa per il Progetto del Classificatore:

1. **Derivazione della Statistica Scalare:** Si calcola il rapporto di verosimiglianza $\mathcal{L}(\mathbf{y})$ o il log-rapporto $\Lambda(\mathbf{y})$ e si isola la variabile di decisione scalare $D(\mathbf{y})$.
2. **Caratterizzazione Statistica:** Si determinano le PDF monodimensionali condizionate $f_D(d|H_0)$ e $f_D(d|H_1)$ (spesso Gaussiane, Chi-quadro o Riciane a seconda del modello di rumore).
3. **Calcolo della Soglia γ':** Si risolve l'equazione scalare ad un'incognita $\int_{\gamma'}^{+\infty} f_D(d|H_0)\,dd = \alpha$ ricavando il valore numerico esatto di γ'.
4. **Valutazione della Potenza P_D:** Si sostituisce la soglia γ' calcolata nell'integrale di P_D per ottenere la prestazione di rivelazione del sistema.

Nel caso in cui la caratterizzazione analitica esplicita della PDF $f_D(d|H_i)$ risulti analiticamente intrattabile, si ricorre alla stima numerica della soglia e delle prestazioni mediante **simulazioni Monte Carlo**.