ELSD 8

2026-10-14

Blocco 1: Classificazione Binaria di un Segnale Noto in Rumore Gaussiano (Caso AWGN) e Test UMP

1.1 Modello del problema e derivazione di LRT ed LLR

Un problema centrale nell'elaborazione dei segnali e nelle comunicazioni digitali è la rivelazione della presenza o assenza di un segnale deterministico noto immerso in un disturbo di natura aleatoria. Si considera un vettore di osservazioni N-dimensionale $\mathbf{y} = [y_1, y_2, \dots, y_N]^T \in \mathbb{R}^N$ costituito da campioni temporali affetti da **rumore bianco gaussiano additivo (AWGN)** i.i.d. con media nulla e varianza nota σ^2, ossia $w_i \sim \mathcal{N}(0, \sigma^2)$.

Il problema di decisione binaria si formalizza contrapponendo due ipotesi statistiche:

- **Ipotesi nulla H_0 (assenza di segnale):** il dato misurato contiene unicamente il rumore di fondo.

$$H_0 : y_i = w_i \implies y_i \sim \mathcal{N}(0, \sigma^2) \quad \forall i = 1, \dots, N$$

- **Ipotesi alternativa H_1 (presenza di segnale):** il dato contiene un segnale costante deterministico di ampiezza A sovrapposto al rumore.

$$H_1 : y_i = A + w_i \implies y_i \sim \mathcal{N}(A, \sigma^2) \quad \forall i = 1, \dots, N$$

I campioni y_i risultano condizionatamente indipendenti data l'ipotesi verificatasi. Le rispettive funzioni di densità di probabilità (PDF) condizionate si esprimono come prodotto delle singole densità marginali gaussiane:

$$f(\mathbf{y}|H_0) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{y_i^2}{2\sigma^2}\right) = \left(\frac{1}{2\pi\sigma^2}\right)^{N/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{N} y_i^2\right)$$

$$f(\mathbf{y}|H_1) = \prod_{i=1}^{N} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(y_i - A)^2}{2\sigma^2}\right) = \left(\frac{1}{2\pi\sigma^2}\right)^{N/2} \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{N} (y_i - A)^2\right)$$

Derivazione del Test del Rapporto di Verosimiglianza (LRT)

In base al Criterio di Neyman-Pearson, la regola di decisione ottima che massimizza la Probabilità di Detezione P_D sotto un vincolo di Probabilità di Falso Allarme $P_{FA} \leq \alpha$ è fornita dal **Test del Rapporto di Verosimiglianza (LRT)**:

$$\mathcal{L}(\mathbf{y}) \triangleq \frac{f(\mathbf{y}|H_1)}{f(\mathbf{y}|H_0)} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda$$

Sostituendo le espressioni delle PDF gaussiane nel rapporto $\mathcal{L}(\mathbf{y})$, le costanti di normalizzazione $(2\pi\sigma^2)^{-N/2}$ a numeratore e denominatore si elidono semplificandosi:

$$\mathcal{L}(\mathbf{y}) = \frac{\exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{N}(y_i - A)^2\right)}{\exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{N} y_i^2\right)} = \exp\left(\frac{1}{2\sigma^2}\left[\sum_{i=1}^{N} y_i^2 - \sum_{i=1}^{N}(y_i - A)^2\right]\right)$$

Sviluppando il quadrato del binomio presente nell'esponente del numeratore, otteniamo:

$$\sum_{i=1}^{N}(y_i - A)^2 = \sum_{i=1}^{N} y_i^2 - 2A\sum_{i=1}^{N} y_i + NA^2$$

La differenza tra i quadrati delle sommatorie isola il termine di correlazione incrociata e l'energia del segnale:

$$\sum_{i=1}^{N} y_i^2 - \sum_{i=1}^{N}(y_i - A)^2 = 2A\sum_{i=1}^{N} y_i - NA^2$$

Il Rapporto di Verosimiglianza assume pertanto la forma analitica:

$$\mathcal{L}(\mathbf{y}) = \exp\left(\frac{A}{\sigma^2}\sum_{i=1}^{N} y_i - \frac{NA^2}{2\sigma^2}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \lambda$$

Passaggio al Log-Likelihood Ratio (LLR)

Poiché il logaritmo naturale è una funzione strettamente crescente sul dominio positivo, la sua applicazione a entrambi i membri della disuguaglianza conserva rigorosamente l'ordinamento analitico e le regioni di decisione. Definiamo il **Log-Likelihood Ratio (LLR)** $\Lambda(\mathbf{y}) \triangleq \ln \mathcal{L}(\mathbf{y})$:

$$\Lambda(\mathbf{y}) = \frac{A}{\sigma^2}\sum_{i=1}^{N} y_i - \frac{NA^2}{2\sigma^2} \underset{H_0}{\overset{H_1}{\gtrless}} \ln \lambda$$

1.2 Statistica di decisione e caratterizzazione statistica

Per trasformare il test in un algoritmo operativo efficiente, è necessario isolare le componenti dipendenti dalle osservazioni $\mathbf{y}$ da quelle puramente deterministiche e costanti.

Riorganizzando i termini della disuguaglianza logaritmica:

$$\frac{A}{\sigma^2}\sum_{i=1}^{N} y_i \underset{H_0}{\overset{H_1}{\gtrless}} \ln\lambda + \frac{NA^2}{2\sigma^2}$$

Ipotizzando inizialmente che l'ampiezza del segnale sia strettamente positiva ($A > 0$), possiamo dividere ambo i membri per il fattore positivo $\frac{A}{\sigma^2}$ senza invertire il verso del confronto:

$$\sum_{i=1}^{N} y_i \underset{H_0}{\overset{H_1}{\gtrless}} \frac{\sigma^2}{A}\ln\lambda + \frac{NA}{2} \triangleq \eta$$

Definiamo la **statistica di decisione scalare grezza** $D(\mathbf{y}) \triangleq \sum_{i=1}^{N} y_i$. Dal punto di vista sistemistico, la statistica $D(\mathbf{y})$ rappresenta l'uscita di un **sommatore/integratore numerico** dei campioni ricevuti, riducendo lo spazio N-dimensionale delle osservazioni a un singolo valore reale.

Caratterizzazione statistica della variabile $D(\mathbf{y})$

Essendo la somma algebrica di N variabili casuali gaussiane indipendenti, la variabile $D(\mathbf{y})$ conserva una distribuzione gaussiana sotto entrambe le ipotesi:

- **Sotto l'ipotesi** H_0: $y_i \sim \mathcal{N}(0, \sigma^2) \implies D \sim \mathcal{N}(0, N\sigma^2)$
- **Sotto l'ipotesi** H_1: $y_i \sim \mathcal{N}(A, \sigma^2) \implies D \sim \mathcal{N}(NA, N\sigma^2)$

Normalizzazione a Varianza Unitaria $D'(\mathbf{y})$

Per rendere il calcolo delle prestazioni svincolato dai parametri dimensionali di varianza, si definisce la **statistica di decisione normalizzata** $D'(\mathbf{y})$ dividendo $D(\mathbf{y})$ per la sua deviazione standard sotto H_0, ovvero $\sqrt{N}\sigma$:

$$D'(\mathbf{y}) \triangleq \frac{\sum_{i=1}^{N} y_i}{\sqrt{N}\sigma}$$

La regola di decisione riscalata assume la forma equivalente:

$$D'(\mathbf{y}) \underset{H_0}{\overset{H_1}{\gtrless}} \eta'$$

dove $\eta' \triangleq \frac{\eta}{\sqrt{N}\sigma}$ rappresenta la soglia di decisione normalizzata.

La caratterizzazione statistica della variabile scalare normalizzata D' si riduce a:

- **Sotto** H_0: $D' \sim \mathcal{N}(0, 1)$
- **Sotto** H_1: $D' \sim \mathcal{N}\left(\frac{NA}{\sqrt{N}\sigma}, 1\right) = \mathcal{N}\left(\sqrt{\frac{NA^2}{\sigma^2}}, 1\right) = \mathcal{N}(\sqrt{d^2}, 1)$

La quantità $d^2 \triangleq \frac{NA^2}{\sigma^2} = \mathrm{SNR}_d$ rappresenta l'**Indice di Deflessione** (o SNR di energia del segnale sul rumore). Essa misura lo spostamento relativo della media della distribuzione sotto H_1 rispetto a H_0 sul dominio reale.

1.3 Calcolo delle prestazioni e Test Uniformemente Più Potente (UMP)

Calcolo del Falso Allarme P_{FA} e della Soglia Ottima η'

Sotto l'ipotesi nulla H_0, la variabile D' segue una distribuzione normale standard $\mathcal{N}(0,1)$. La Probabilità di Falso Allarme P_{FA} corrisponde all'integrale dell'area di coda della PDF oltre la soglia η':

$$P_{FA} = P(D' \geq \eta' | H_0) = \int_{\eta'}^{+\infty} \frac{1}{\sqrt{2\pi}} e^{-t^2/2}\, dt \triangleq Q(\eta')$$

dove $Q(\cdot)$ indica la **funzione Q di Gauss** (complementare della funzione di distribuzione cumulativa normale).

Imponendo il vincolo di significatività di Neyman-Pearson $P_{FA} = \alpha$, possiamo invertire la funzione Q ricavando il valore esatto della soglia ottima normalizzata η':

$$\eta' = Q^{-1}(\alpha)$$

Questo risultato esplicita un principio concettuale di primaria importanza: **la soglia di decisione normalizzata η' dipende unicamente dal livello di significatività tollerato α, ed è completamente indipendente dall'ampiezza del segnale A.**

Calcolo della Probabilità di Detezione P_D

Sotto l'ipotesi H_1, la statistica D' ha media pari a $\frac{\sqrt{N}A}{\sigma} = \sqrt{\mathrm{SNR}_d}$ e varianza unitaria. La Probabilità di Detezione P_D è data dall'integrale della PDF traslata oltre la medesima soglia η':

$$P_D = P(D' \geq \eta' | H_1) = Q\left(\eta' - \frac{\sqrt{N}A}{\sigma}\right) = Q\left(Q^{-1}(\alpha) - \sqrt{\frac{NA^2}{\sigma^2}}\right)$$

Come previsto, mentre la soglia η' prescinde da A, la prestazione di rivelazione P_D cresce monotonicamente con l'aumentare dell'ampiezza A e del numero di campioni N attraverso l'SNR complessivo.

Ipotesi Semplici vs Ipotesi Composte

- Un'ipotesi si definisce **semplice** quando la funzione di densità di probabilità degli osservabili è specificata in modo unico ed esplicito in ogni suo parametro (ad esempio quando l'ampiezza $A = A_0$ è nota con certezza).
- Un'ipotesi si definisce **composta** quando la PDF appartiene a una famiglia parametrica ma il parametro reale non è un valore numerico fisso, bensì appartiene a un insieme continuo di valori possibili (ad esempio $A \in (0, +\infty)$ con ampiezza incognita ma vincolata ad essere positiva).

Il Test Uniformemente Più Potente (UMP - Uniformly Most Powerful)

In presenza di un'ipotesi alternativa composta, la teoria della decisione cerca di stabilire se esista un unico classificatore capace di rimanere ottimo al variare del parametro incognito.

Un test si definisce **Uniformemente Più Potente (UMP)** per un'ipotesi composta se la sua regola di decisione massimizza la Probabilità di Detezione P_D rispetto a qualsiasi altro test ammissibile per **qualsiasi valore del parametro** appartenente al dominio dell'ipotesi composta.

Nel nostro sistema di rivelazione in rumore gaussiano, poiché la struttura della statistica di decisione $D'(\mathbf{y}) = \frac{\sum y_i}{\sqrt{N}\sigma}$ e la soglia ottima $\eta' = Q^{-1}(\alpha)$ non contengono alcun termine dipendente dall'ampiezza A (a patto che $A > 0$), **lo STESSO ricevitore (sommatore/integratore) risulta contemporaneamente ottimo per qualsiasi ampiezza del segnale positiva**.

Il progettista non ha alcuna necessità di adattare o riconfigurare l'hardware e gli algoritmi del ricevitore qualora l'ampiezza del segnale trasmesso A vari nel tempo o non sia nota a priori, purché si mantenga il segno positivo.

Condizioni di Inviabilità UMP e Cenni al Test GLRT

Se l'ampiezza A potesse assumere sia valori positivi che negativi ($A \in \mathbb{R} \setminus \{0\}$), la divisione per A nel passaggio all'LLR invertirebbe la disuguaglianza per $A < 0$, rendendo impossibile definire una regione di decisione unica e distruggendo la proprietà UMP.

Nei casi in cui un test UMP non esiste (ad esempio in presenza di parametri di disturbo o segnali a fase casuale), si ricorre al **Generalized Likelihood Ratio Test (GLRT)**. Il test GLRT stima preventivamente i parametri incogniti tramite la Stima di Massima Verosimiglianza (MLE) sotto ciascuna ipotesi, sostituendo gli stimatori $\hat{A}_{ML}$ all'interno del rapporto di verosimiglianza.

Blocco 2: Proprietà Geometriche ed Analitiche della Curva ROC (Receiver Operating Characteristic)

2.1 Definizione ed estremi della curva ROC

La **curva ROC** (*Receiver Operating Characteristic*) costituisce la rappresentazione grafica tracciata nel piano cartesiano delle prestazioni per valutare la capacità discriminativa di un classificatore o detector12. Essa esprime la **Probabilità di Detezione** P_D in funzione della **Probabilità di Falso Allarme** P_{FA} al variare continuo della soglia di decisione del test.

Dominio e Regione di Operatività

Poiché P_D e P_{FA} rappresentano probabilità condizionate, i loro valori sono rigorosamente vincolati all'intervallo. Di conseguenza:

- La curva ROC è interamente racchiusa all'interno del **quadrato unitario** $\times$ del piano cartesiano (P_{FA}, P_D).
- Ogni punto della curva corrisponde a uno specifico funzionamento operativo del sistema, identificato univocamente da una particolare scelta della soglia di decisione.

I Punti Limite Estremi

Ogni curva ROC associata a variabili casuali continue passa necessariamente per i due punti di angolo estremo del quadrato unitario:

1. **Il punto $(0,0)$ (Origine):**
   - **Condizione sulla soglia:** Corrisponde al limite in cui la soglia di decisione tende a $+\infty$ (ossia $\lambda \to +\infty$ per il Likelihood Ratio $\mathcal{L}(\mathbf{y})$, $\gamma \to +\infty$ per il Log-LRT $\Lambda(\mathbf{y})$, oppure $\eta \to +\infty$ per la statistica D).
   - **Significato fisico:** Impostare una soglia infinitamente alta equivale a restringere la regione di decisione A_1 all'insieme vuoto ($A_1 = \emptyset$). Il classificatore non decide mai per l'ipotesi H_1, annullando completamente il Falso Allarme ($P_{FA} = 0$), ma azzerando simultaneamente anche la Detezione ($P_D = 0$).
2. **Il punto $(1,1)$ (Angolo Superiore Destro):**
   - **Condizione sulla soglia:** Corrisponde al limite opposto in cui la soglia di decisione tende a 0 per il Likelihood Ratio ($\lambda \to 0$), oppure a $-\infty$ per il Log-LRT e per la statistica di decisione ($\gamma, \eta \to -\infty$).
   - **Significato fisico:** Una soglia nulla o infinitamente negativa espande la regione di decisione A_1 all'intero spazio degli osservabili ($A_1 = \mathcal{A}_{\mathbf{y}}$). Il sistema assegna qualsiasi osservazione all'ipotesi H_1, garantendo la detezione totale ($P_D = 1$), ma saturando al contempo il Falso Allarme al valore unitario ($P_{FA} = 1$).

La Bisettrice di Random Guessing ($P_D = P_{FA}$)

La diagonale principale del quadrato unitario, identificata dalla retta $P_D = P_{FA}$, rappresenta il limite prestazionale di un **classificatore casuale privo di informazione** (random guesser). Un sistema che decide per l'ipotesi H_1 lanciando una moneta truccata con probabilità fissa p (indipendentemente dai dati misurati $\mathbf{y}$) otterrà sempre $P_D = p$ e $P_{FA} = p$.

Qualsiasi classificatore ottimo basato sul Test del Rapporto di Verosimiglianza ha una curva ROC che giace **rigorosamente al di sopra della bisettrice** ($P_D \geq P_{FA}$ per ogni valore di Falso Allarme).

2.2 Concavità della curva ROC e Disuguaglianza di Jensen

Una delle proprietà analitiche fondamentali delle curve ROC per variabili continue è la loro **concavità** verso il basso.

Definizione Geometrica ed Analitica di Concavità

Una funzione $f(x)$ si definisce **concava** su un intervallo se, presi due punti arbitrari $A = (x_A, f(x_A))$ e $B = (x_B, f(x_B))$ sulla curva, il segmento rettilineo che congiunge A e B (detto corda) giace interamente al di sotto o al più coincide con il grafico della funzione stessa.

Analiticamente, per ogni combinazione convessa individuata dal parametro $\beta \in 3$, la condizione di concavità si esprime come:

$$f(\beta x_A + (1-\beta)x_B) \geq \beta f(x_A) + (1-\beta) f(x_B)$$

Collegamento con la Disuguaglianza di Jensen

Interpretando il parametro β e il suo complementare $(1-\beta)$ come la distribuzione di massa di probabilità di una variabile aleatoria discreta che assume i valori x_A e x_B, la combinazione convessa $\beta x_A + (1-\beta)x_B$ rappresenta il valore atteso della variabile $E[X]$.

La condizione di concavità si formalizza nella celebre **Disuguaglianza di Jensen**: per qualsiasi funzione concava $f(\cdot)$, la funzione calcolata nella media della variabile aleatoria è sempre maggiore o uguale alla media della funzione della variabile aleatoria:

$$f(E[X]) \geq E[f(X)]$$

Dimostrazione Operativa della Concavità della ROC

La concavità della curva ROC può essere dimostrata mediante un'argomentazione fondata sulla teoria delle decisioni:

1. Consideriamo due punti di funzionamento distinti sulla ROC, $A = (P_{FA}^{(A)}, P_D^{(A)})$ e $B = (P_{FA}^{(B)}, P_D^{(B)})$, ottenuti applicando il Test di Neyman-Pearson con due diverse soglie λ_A e λ_B.
2. Immaginiamo di costruire un **classificatore probabilistico randomizzato** che, per ogni osservazione $\mathbf{y}$, seleziona la regola di decisione A con probabilità β e la regola di decisione B con probabilità $1 - \beta$ (con $\beta \in 3$).
3. Per la proprietà di linearità del calcolo delle probabilità, le prestazioni del classificatore combinato saranno esattamente la combinazione convessa delle prestazioni dei singoli test:

$$P_{FA}^{(\text{comb})} = \beta P_{FA}^{(A)} + (1-\beta) P_{FA}^{(B)}$$

$$P_D^{(\text{comb})} = \beta P_D^{(A)} + (1-\beta) P_D^{(B)}$$

   Sul piano (P_{FA}, P_D), il punto corrispondente al classificatore combinato $(P_{FA}^{(\text{comb})}, P_D^{(\text{comb})})$ giace esattamente sul **segmento rettilineo** che congiunge i punti A e B.
4. Tuttavia, il **Lemma di Neyman-Pearson** garantisce che il Test del Rapporto di Verosimiglianza progettato direttamente per il livello di falso allarme $P_{FA}^{(\text{comb})}$ è il test di **massima potenza assoluta**2021. Pertanto, la Probabilità di Detezione fornita dalla curva ROC ottima in corrispondenza del Falso Allarme $P_{FA}^{(\text{comb})}$ deve essere maggiore o al più uguale a quella ottenuta da qualsiasi altro test ammissibile, incluso il test combinato randomizzato:

$$P_D\left(P_{FA}^{(\text{comb})}\right) \geq P_D^{(\text{comb})} = \beta P_D^{(A)} + (1-\beta) P_D^{(B)}$$

Poiché la curva ROC giace sempre al di sopra di qualsiasi corda che congiunge due suoi punti, resta rigorosamente dimostrato che **la curva ROC è una funzione concava**.

2.3 Significato geometrico della pendenza della curva ROC

Oltre alla concavità, un'ulteriore proprietà fondamentale riguarda la derivata prima della curva ROC in ciascun punto di funzionamento.

Derivata Locale e Soglia λ

Nel problema di ottimizzazione vincolata di Neyman-Pearson, la massimizzazione della Lagrangiana $J(A_1, \lambda) = P_D + \lambda(\alpha - P_{FA})$ ha portato a definire il confine della regione di decisione A_1 mediante l'uguaglianza tra il Rapporto di Verosimiglianza e la soglia λ.

Considerando piccole variazioni della regione di decisione attorno al valore ottimo, il rapporto tra l'incremento infinitesimo della Detezione dP_D e l'incremento infinitesimo del Falso Allarme dP_{FA} definisce la pendenza locale della curva tangente alla ROC:

$$\frac{dP_D}{dP_{FA}} = \lambda$$

Interpretazione Geometrica e Fisica

1. **Pendenza uguale alla Soglia del Likelihood Ratio:** In qualsiasi punto (P_{FA}, P_D) della curva ROC, la derivata locale (inclinazione della retta tangente) è **esattamente pari al valore del Likelihood Ratio** λ utilizzato come soglia di decisione per ottenere quel determinato punto di lavoro.
2. **Andamento Monotono della Pendenza:** Poiché la curva ROC è concava, la sua pendenza $\frac{dP_D}{dP_{FA}} = \lambda$ è una funzione **monotona decrescente** all'aumentare di P_{FA}:
   - Nell'origine $(0, 0)$, la soglia tende a $+\infty$ ($\lambda \to +\infty$), e la curva parte con una tangente **verticale** (pendenza infinita).
   - Man mano che si riduce la soglia λ per consentire un Falso Allarme più elevato, la pendenza della tangente diminuisce progressivamente.
   - Nell'angolo $(1, 1)$, la soglia tende a 0 ($\lambda \to 0$), e la pendenza della curva tende ad appiattirsi orizzontalmente.
3. **Trade-off Costi/Benefici:** Il valore di $\lambda = \frac{dP_D}{dP_{FA}}$ esprime il "tasso di cambio" tra Detezione e Falso Allarme. Quando λ è grande (vicino all'origine), una piccolissima concessione in termini di Falso Allarme produce un enorme incremento nella Probabilità di Detezione; al contrario, quando λ è piccolo (vicino a 1), ulteriori aumenti di Falso Allarme producono incrementi trascurabili di Detezione.

Blocco 3: Classificazione con Osservabili Discreti e Test di Neyman-Pearson Randomizzato

3.1 Test d'ipotesi per osservabili discreti (Modello Bernoulli)

Nelle applicazioni reali dell'elaborazione numerica dei segnali, le misurazioni o le decisioni locali possono assumere valori appartenenti a insiemi discreti o binari (es. uscite di quantizzatori, rivelatori locali in reti di sensori distribuite o prove di conteggio).

Si considera un vettore di osservazioni N-dimensionale $\mathbf{y} = [y_1, y_2, \dots, y_N]^T$, dove ciascun campione $y_i \in \{0, 1\}$ è una variabile aleatoria discreta distribuita secondo una prova di **Bernoulli** $y_i \sim \mathcal{B}(1, p)$. I campioni si assumono condizionatamente indipendenti e identicamente distribuiti (i.i.d.) data l'ipotesi.

Il problema di classificazione binaria si esprime come confronto tra due parametri di probabilità p_0 e p_1:

- **Ipotesi nulla** H_0: $y_i \sim \mathcal{B}(1, p_0) \implies P(y_i = 1|H_0) = p_0, \quad P(y_i = 0|H_0) = 1 - p_0$
- **Ipotesi alternativa** H_1: $y_i \sim \mathcal{B}(1, p_1) \implies P(y_i = 1|H_1) = p_1, \quad P(y_i = 0|H_1) = 1 - p_1$

Ipotizziamo, senza perdita di generalità, che la probabilità di successo sotto l'ipotesi alternativa sia strettamente maggiore rispetto all'ipotesi nulla: $p_1 > p_0$.

Le **Funzioni di Massa di Probabilità (PMF)** congiunte sotto le due ipotesi si esprimono come prodotto delle singole masse di probabilità bernoulliane:

$$P(\mathbf{y}|H_0) = \prod_{i=1}^{N} p_0^{y_i}(1-p_0)^{1-y_i} = p_0^{\sum_{i=1}^{N} y_i}(1-p_0)^{N-\sum_{i=1}^{N} y_i}$$

$$P(\mathbf{y}|H_1) = \prod_{i=1}^{N} p_1^{y_i}(1-p_1)^{1-y_i} = p_1^{\sum_{i=1}^{N} y_i}(1-p_1)^{N-\sum_{i=1}^{N} y_i}$$

Derivazione dell'LRT e dell'LLR per Osservabili Bernoulliani

Il Criterio di Neyman-Pearson impone la regola del **Rapporto di Verosimiglianza** $\mathcal{L}(\mathbf{y})$ definita sul rapporto delle PMF congiunte:

$$\mathcal{L}(\mathbf{y}) \triangleq \frac{P(\mathbf{y}|H_1)}{P(\mathbf{y}|H_0)} = \frac{p_1^{\sum y_i}(1-p_1)^{N-\sum y_i}}{p_0^{\sum y_i}(1-p_0)^{N-\sum y_i}} = \left(\frac{p_1}{p_0}\right)^{\sum_{i=1}^{N} y_i} \left(\frac{1-p_1}{1-p_0}\right)^{N-\sum_{i=1}^{N} y_i} \underset{H_0}{\overset{H_1}{\gtrless}} \lambda$$

Applicando il logaritmo naturale ad ambo i membri, ricaviamo l'espressione del **Log-Likelihood Ratio (LLR)** $\Lambda(\mathbf{y})$:

$$\Lambda(\mathbf{y}) = \ln \mathcal{L}(\mathbf{y}) = \left(\sum_{i=1}^{N} y_i\right) \ln\left(\frac{p_1}{p_0}\right) + \left(N - \sum_{i=1}^{N} y_i\right) \ln\left(\frac{1-p_1}{1-p_0}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \ln \lambda$$

Raggruppando i termini dipendenti dalle osservazioni $\sum_{i=1}^{N} y_i$:

$$\sum_{i=1}^{N} y_i \left[\ln\left(\frac{p_1}{p_0}\right) - \ln\left(\frac{1-p_1}{1-p_0}\right)\right] + N \ln\left(\frac{1-p_1}{1-p_0}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \ln \lambda$$

$$\sum_{i=1}^{N} y_i \ln\left(\frac{p_1(1-p_0)}{p_0(1-p_1)}\right) \underset{H_0}{\overset{H_1}{\gtrless}} \ln \lambda - N \ln\left(\frac{1-p_1}{1-p_0}\right) \triangleq \eta'$$

Essendo $p_1 > p_0$, il rapporto $\frac{p_1(1-p_0)}{p_0(1-p_1)} > 1$, il che garantisce che il suo logaritmo sia una costante strettamente positiva. Dividendo ambo i membri per tale costante positiva, isoliamo la **statistica di decisione scalare** $D(\mathbf{y})$:

$$D(\mathbf{y}) \triangleq \sum_{i=1}^{N} y_i \underset{H_0}{\overset{H_1}{\gtrless}} \eta''$$

Caratterizzazione della Statistica Binomiale D

La statistica di decisione $D = \sum_{i=1}^{N} y_i$ rappresenta il numero totale di successi su N prove bernoulliane indipendenti. Essa è una variabile aleatoria discreta distribuita secondo una legge **Binomiale** sotto entrambe le ipotesi:

- **Sotto l'ipotesi** H_0**:** $D \sim \mathcal{B}(N, p_0)$
- **Sotto l'ipotesi** H_1**:** $D \sim \mathcal{B}(N, p_1)$

La cui massa di probabilità per un generico valore intero $k \in \{0, 1, \dots, N\}$ vale:

$$P(D = k|H_i) = \binom{N}{k} p_i^k (1 - p_i)^{N-k}$$

3.2 Discontinuità della ROC per osservabili discreti

A differenza del caso continuo (dove le probabilità P_{FA} e P_D variano con continuità al variare della soglia reale η), nel caso discreto la statistica D assume esclusivamente valori interi appartenenti all'insieme $\{0, 1, \dots, N\}$.

Analisi dei Punti Operativi Discreti

Nel calcolare la Probabilità di Falso Allarme in funzione di una soglia deterministica η'':

$$P_{FA}(\eta'') = P(D \geq \eta''|H_0) = \sum_{k=\lceil \eta'' \rceil}^{N} \binom{N}{k} p_0^k (1 - p_0)^{N-k}$$

Se la soglia η'' varia continuamente all'interno di un intervallo compreso tra due interi consecutivi, ad esempio $\eta'' \in (k, k+1]$, la sommatoria discreta non varia. La probabilità $P_{FA}(\eta'')$ rimane rigorosamente costante al valore $P(D \geq k+1|H_0)$.

Di conseguenza:

- Esistono soltanto $N + 2$ **valori distinti** di Probabilità di Falso Allarme e di Detezione ottenibili mediante regole di decisione deterministiche, corrispondenti alle scelte di soglia intera $\eta'' \in \{0, 1, \dots, N, N+1\}$.
- Sul piano cartesiano (P_{FA}, P_D), le prestazioni del classificatore non tracciano una curva continua, bensì un **insieme discreto di** $N + 2$ **punti isolati**.

- Unendo graficamente questi punti isolati, la rappresentazione assume un andamento a gradinata/spezzata che non rispetta in senso stretto la continuità differenziabile vista per le variabili continue.

Impossibilità del Vincolo Deterministico Esatto

La conseguenza operativa di questa discretizzazione è che, dato un generico livello di significatività desiderato $\alpha \in (0, 1)$ (ad esempio $\alpha = 0.05$), **non è in generale possibile trovare una soglia deterministica η'' tale per cui $P_{FA}(\eta'') = \alpha$ esattamente**, a meno che α non coincida casualmente con uno degli $N + 2$ valori discreti ammissibili della distribuzione binomiale.

Se si sceglie la soglia intera più vicina per difetto, si viola il vincolo ($P_{FA} > \alpha$); se si sceglie la soglia più vicina per eccesso, il test diventa eccessivamente conservativo ($P_{FA} < \alpha$), rinunciando a quota parte della massima potenza di detezione P_D teoricamente disponibile.

3.3 Il Test di Neyman-Pearson Randomizzato (Randomized NP Test)

Per superare la limitazione imposta dal carattere discreto delle osservazioni e garantire il rispetto del vincolo $P_{FA} = \alpha$ per **qualsiasi** valore di $\alpha \in$1, la teoria della decisione introduce il **Test di Neyman-Pearson Randomizzato**.

Struttura Operativa della Decisione Probabilistica

Sia α il livello di significatività richiesto. Identifichiamo l'unico valore intero di soglia $k \in \{0, 1, \dots, N\}$ tale per cui il vincolo α risulti compreso tra due livelli discreti consecutivi di falso allarme:

$$P(D \geq k+1 | H_0) < \alpha \leq P(D \geq k | H_0)$$

La regola di decisione del **Test Randomizzato** associa all'esito della statistica $D(\mathbf{y})$ tre diverse azioni:

1. **Se $D(\mathbf{y}) > k$:** si decide **incondizionatamente per H_1** (probabilità di decisione 1).
2. **Se $D(\mathbf{y}) < k$:** si decide **incondizionatamente per H_0** (probabilità di decisione 0).
3. **Se $D(\mathbf{y}) = k$ (punto di confine):** si effettua una **decisione probabilistica (randomizzata)**. Il classificatore decide per l'ipotesi H_1 con una probabilità di monetizzazione $\phi \in (0, 1)$ e per H_0 con probabilità complementare $1 - \phi$.

La funzione di decisione probabilistica $\delta(D)$ si formalizza come:

$$[\delta(D) = \{1 \quad \text{se } D > k \; \phi \quad \text{se } D = k \; 0 \quad \text{se } D < k]$$

Calcolo Esatto della Probabilità di Randomizzazione ϕ

La Probabilità di Falso Allarme del test randomizzato è data dalla media stocastica delle decisioni sotto l'ipotesi H_0:

$$P_{FA} = P(D > k|H_0) + \phi \cdot P(D = k|H_0) = \alpha$$

Poiché $P(D > k|H_0) = P(D \geq k+1|H_0)$, isoliamo il parametro di randomizzazione ϕ:

$$\phi = \frac{\alpha - P(D \geq k+1|H_0)}{P(D = k|H_0)}$$

Essendo $P(D \geq k+1|H_0) < \alpha \leq P(D \geq k|H_0)$, il numeratore è strettamente positivo e minore o uguale al denominatore $P(D = k|H_0) = P(D \geq k|H_0) - P(D \geq k+1|H_0)$. Questo assicura rigorosamente che $\phi \in (0, 1]$.

Calcolo della Probabilità di Detezione P_D

La corrispondente Probabilità di Detezione fornita dal test randomizzato si calcola analogamente sotto l'ipotesi alternativa H_1:

$$P_D = P(D \geq k+1|H_1) + \phi \cdot P(D = k|H_1)$$

Significato Geometrico sul Piano ROC

Dal punto di vista geometrico, l'introduzione della decisione probabilistica ϕ al punto di confine $D = k$ equivale a effettuare un'**interpolazione lineare** tra i due punti operativi discreti adiacenti $(P_{FA}(k+1), P_D(k+1))$ e $(P_{FA}(k), P_D(k))$ nel piano della ROC.

Tracciando i segmenti rettilinei che congiungono gli $N+2$ punti discreti isolati, la curva ROC del Test Randomizzato diventa una spezzata continua e concava che copre interamente l'intervallo 1. In questo modo si ripristina la proprietà di massima potenza assoluta e si garantisce il soddisfacimento esatto di qualsiasi vincolo di significatività $P_{FA} = \alpha$.