ELSD 10

tipo: lezione
materia: Elaborazione dei Segnali Digitali
lezione: ELSD 10
libro_riferimento: Fundamentals of Statistical Signal Processing (Steven M. Kay), Vol. I (Cap. 2, 4, 5) argomenti_trattati:

- Transizione a Stima Non-Bayesiana ed MSE (Varianza + Bias^2)
- Proprietà dello Stimatore ML (Consistenza, Invarianza, Efficienza)
- Modello Lineare Gaussiano, Pseudoinversa e Proiezione Ortogonale
- Teorema di Rao-Blackwell e Teorema di Lehmann-Scheffé (RBLS per MVU)

tags:

- #elsd10
- #stima-non-bayesiana
- #maximum-likelihood
- #modello-lineare
- #mvu
- #rao-blackwell
- #lehmann-scheffe

Blocco 1: Fondamenti della Stima Non-Bayesiana, Parametri di Qualità e Proprietà dello Stimatore ML

1.1 Transizione da Classificazione a Stima Non-Bayesiana

Nel percorso concettuale dell'Elaborazione dei Segnali Digitali e della Teoria delle Decisioni, il passaggio dalla **classificazione** alla **stima** rappresenta la transizione da un dominio di decisione discreto a un dominio continuo.

Il Modello del Sistema e della Misurazione

Il modello generale della stima si compone di tre elementi fondamentali:

1. **Lo Stato / Parametro Incognito (x oppure $\mathbf{x}$):** Rappresenta la grandezza fisica d'interesse (scalare o vettoriale $K \times 1$) che si intende determinare (ad esempio

l'ampiezza di un segnale, la frequenza, la fase, la posizione di un bersaglio o i coefficienti di un filtro).

2. **Il Canale / Schema di Osservazione:** Modella la trasformazione fisica o il legame funzionale $v(x)$ (invertibile o non invertibile) a cui il parametro x viene sottoposto, unito alla sovrapposizione del disturbo aleatorio (rumore w).
3. **Il Vettore delle Osservazioni ($\mathbf{y} \in \mathbb{R}^N$):** Rappresenta l'insieme dei dati misurati e collezionati dall'osservatore. Essendo affetto da rumore, $\mathbf{y}$ è modellato come un vettore aleatorio $N \times 1$ la cui funzione di densità di probabilità (PDF) o di massa (PMF) è parametrizzata dal valore vero dello stato x:

$$\mathbf{y} \sim f(\mathbf{y}|x) \quad \text{oppure} \quad f(\mathbf{y}; x)$$

Confronto Concettuale: Classificazione vs Stima Non-Bayesiana

- **Nella Classificazione (Ambiente Discreto):** Sebbene lo stato reale x possa variare in un insieme continuo, la sua presenza o i suoi effetti sulle osservazioni si riflettono in un numero finito/discreto Q di condizioni operative o **ipotesi** ($H_0, H_1, \ldots, H_{Q-1}$). Il compito del classificatore è assegnare il vettore continuo $\mathbf{y}$ a una regione di decisione discreta $A_i \subset \mathbb{R}^N$.
- **Nella Stima Non-Bayesiana (Ambiente Continuo):** Il parametro x assume valori in un dominio continuo $\mathcal{X} \subseteq \mathbb{R}^K$. La dipendenza di $\mathbf{y}$ da x si manifesta con continuità attraverso la famiglia parametrica di densità $f(\mathbf{y}|x)$.
- **Natura del Parametro (Contesto Non-Bayesiano):** In ambiente **Non-Bayesiano** (frequentista), il parametro x è considerato una grandezza **deterministica incognita ma fissa**. Non si associa ad x alcuna densità di probabilità a priori $p(x)$ né si definiscono probabilità a priori delle ipotesi. La notazione $f(\mathbf{y}|x)$ esprime la verosimiglianza del dato parametrizzata da x, e l'obiettivo dello **stimatore** $\hat{x}(\mathbf{y})$ è costruire una regola (ovvero una funzione misurabile dagli osservabili) che restituisca una stima il più possibile vicina al valore vero di x.

1.2 Parametri di Qualità dello Stimatore

Poiché lo stimatore $\hat{x} = \hat{x}(\mathbf{y})$ è una trasformazione del vettore aleatorio misurato $\mathbf{y}$, esso costituisce a sua volta una **variabile aleatoria** (o vettore aleatorio). Di conseguenza, non ha senso valutare la bontà dello stimatore sulla singola realizzazione numerica, bensì occorre analizzarne le **proprietà statistiche** (media, varianza e dispersione complessiva) al variare delle realizzazioni del rumore.

1. Il Vettore di Polarizzazione / Bias ($\mathbf{b}$)

Il **bias** o polarizzazione misura lo scostamento sistematico medio tra il valore atteso della stima prodotta dall'algoritmo e il valore vero del parametro deterministico x:

$$\mathbf{b}(x) \triangleq E[\hat{x}] - x$$

(Nota di convenzione: definendo l'errore come $\mathbf{e} \triangleq \hat{x} - x$, si ha $E[\mathbf{e}] = \mathbf{b}$; adottando la convenzione opposta $\varepsilon \triangleq x - \hat{x}$, il bias ha segno invertito, ma la sua magnitudo $|\mathbf{b}|$ rimane invariata).

- **Stimatore Non Polarizzato (Unbiased):** Uno stimatore si definisce **non polarizzato** o **corretto** se il suo valore atteso coincide con il parametro vero per **qualsiasi** valore del parametro appartenente al dominio ammissibile:

$$E[\hat{x}] = x \quad \forall x \in \mathcal{X} \iff \mathbf{b}(x) = \mathbf{0}$$

- **Significato Fisico:** In uno stimatore non polarizzato, ripetendo l'esperimento di misura un numero elevato di volte e mediando i risultati, la componente casuale del rumore si annulla in media, fornendo esattamente il valore vero x.

2. La Varianza dello Stimatore ($\mathrm{Var}[\hat{x}]$)

La varianza quantifica la dispersione stocastica o fluttuazione dello stimatore attorno al suo valore medio:

- **Caso Scalare ($x \in \mathbb{R}$):**

$$\mathrm{Var}[\hat{x}] \triangleq E\left[(\hat{x} - E[\hat{x}])^2\right]$$

- **Caso Vettoriale ($\mathbf{x} \in \mathbb{R}^K$):** La dispersione vettoriale si esprime tramite la **traccia della matrice di covarianza** dello stimatore $C_{\hat{x}}$:

$$\mathrm{Var}[\hat{x}] \triangleq \mathrm{Tr}(C_{\hat{x}}) = \sum_{i=1}^{K} \mathrm{Var}[\hat{x}_i] = E\left[|\hat{x} - E[\hat{x}]|^2\right]$$

3. Scomposizione dell'Errore Quadratico Medio (MSE = Varianza + Bias^2)

L'**Errore Quadratico Medio** (*Mean Squared Error*, MSE) rappresenta la metrica sintetica fondamentale per valutare l'accuratezza totale di uno stimatore, combinando sia l'incertezza casuale (varianza) sia l'errore sistematico (bias).

Per uno stimatore vettoriale $\hat{x}$, l'MSE è definito come il valore atteso della norma euclidea al quadrato del vettore errore:

$$\mathrm{MSE}(\hat{x}) \triangleq E\left[|\hat{x} - x|^2\right]$$

Dimostrazione della Scomposizione dell'MSE:

Sommando e sottraendo il valore atteso $E[\hat{x}]$ all'interno del termine d'errore:

$$\hat{x} - x = \big(\hat{x} - E[\hat{x}]\big) + \big(E[\hat{x}] - x\big) = \big(\hat{x} - E[\hat{x}]\big) + \mathbf{b}$$

Calcoliamo la norma euclidea al quadrato sfruttando il prodotto scalare:

$$|\hat{x} - x|^2 = |(\hat{x} - E[\hat{x}]) + \mathbf{b}|^2 = |\hat{x} - E[\hat{x}]|^2 + |\mathbf{b}|^2 + 2\mathbf{b}^T(\hat{x} - E[\hat{x}])$$

Applicando l'operatore valore atteso $E[\cdot]$ a ciascun termine:

$$E\left[|\hat{x} - x|^2\right] = E\left[|\hat{x} - E[\hat{x}]|^2\right] + E\left[|\mathbf{b}|^2\right] + 2\mathbf{b}^T E\left[\hat{x} - E[\hat{x}]\right]$$

Poiché $\mathbf{b}$ è un vettore deterministico, $E[|\mathbf{b}|^2] = |\mathbf{b}|^2$. Inoltre, il valore atteso dello scarto dalla media è nullo: $E[\hat{x} - E[\hat{x}]] = E[\hat{x}] - E[\hat{x}] = \mathbf{0}$. Di conseguenza, il termine incrociato si annulla identicamente:

$$\mathrm{MSE}(\hat{x}) = \mathrm{Tr}(C_{\hat{x}}) + |\mathbf{b}|^2$$

$$\mathrm{MSE} = \text{Varianza dello Stimatore} + \text{Polarizzazione}^2$$

Implicazione Teorica Fondamentale:

Se uno stimatore è **non polarizzato** ($\mathbf{b} = \mathbf{0}$), l'Errore Quadratico Medio coincide **esattamente** con la varianza dello stimatore:

$$\mathbf{b} = \mathbf{0} \implies \mathrm{MSE}(\hat{x}) = \mathrm{Tr}(C_{\hat{x}})$$

1.3 Definizione e Proprietà Fondamentali dello Stimatore ML (Maximum Likelihood)

Lo **Stimatore di Massima Verosimiglianza** (*Maximum Likelihood Estimator*, MLE) rappresenta la metodologia d'elezione per la stima non-bayesiana dei parametri.

Formulazione Matematica

Dato il vettore di osservazioni misurate $\mathbf{y}$, la funzione $f(\mathbf{y}|x)$ viene interpretata come **funzione di verosimiglianza** del parametro x. Lo stimatore ML individua il valore $\hat{x}_{ML}$ che massimizza la verosimiglianza dell'osservazione effettivamente registrata:

$$\hat{x}_{ML}(\mathbf{y}) \triangleq \arg\max_{x \in \mathcal{X}} f(\mathbf{y}|x)$$

Nelle applicazioni pratiche, per via della stretta monotonicità del logaritmo naturale, si massimizza la **log-verosimiglianza** $\ln f(\mathbf{y}|x)$:

$$\hat{x}_{ML}(\mathbf{y}) = \arg\max_{x \in \mathcal{X}} \ln f(\mathbf{y}|x)$$

Interpretazione Fisica

Lo stimatore ML risponde alla seguente domanda intuitiva: "*Qual è quel valore del parametro incognito x che rende massima la probabilità (o la densità) di aver osservato esattamente il dato $\mathbf{y}$ raccolto dal sistema?*"

Le Proprietà Asintotiche dello Stimatore ML

Sebbene per un numero finito di campioni N lo stimatore ML possa presentare un bias non nullo o una varianza non minima, esso gode di straordinarie **proprietà ottime asintotiche** (all'aumentare del numero di osservazioni $N \to \infty$):

1. **Non Polarizzazione Asintotica (Asymptotically Unbiased):** Aumentando il numero di misurazioni N, il valore atteso della stima ML converge al valore vero del parametro:

$$\lim_{N \to \infty} E[\hat{x}_{ML}] = x$$

2. **Consistenza Asintotica (Consistent Estimator):** Al crescere del numero di campioni N, la varianza dello stimatore ML tende a zero:

$$\lim_{N \to \infty} \mathrm{Var}[\hat{x}_{ML}] = 0$$

   Mettendo insieme le proprietà (1) e (2), si ottiene che per $N \to \infty$ l'Errore Quadratico Medio tende a zero ($\lim_{N \to \infty} \mathrm{MSE}(\hat{x}_{ML}) = 0$), il che implica che lo stimatore ML **converge in probabilità** al valore vero del parametro (diventando deterministico e coincidente con x).
3. **Gaussianità ed Efficienza Asintotica:** Sotto generali condizioni di regolarità (esistenza delle derivate della log-verosimiglianza), all'aumentare di N, la distribuzione di probabilità dello stimatore ML tende asintoticamente a una **distribuzione Gaussiana** centrata sul valore vero x e con varianza pari al limite inferiore di Cramér-Rao (CRLB):

$$\hat{x}_{ML} \overset{a}{\sim} \mathcal{N}\left(x, I^{-1}(x)\right)$$

   dove $I(x)$ rappresenta l'**Informazione di Fisher**.

La Proprietà di Invarianza dello Stimatore ML

Una delle proprietà più rilevanti e operativamente utili dello stimatore ML riguarda l'**invarianza rispetto alle trasformazioni funzionali**.

Enunciato del Principio di Invarianza:

Sia $\hat{x}_{ML}$ lo stimatore di Massima Verosimiglianza del parametro x. Se si intende stimare un parametro trasformato $v = g(x)$ (dove $g(\cdot)$ è una funzione scalare o vettoriale arbitraria, **sia essa invertibile o non invertibile**), lo stimatore di Massima Verosimiglianza di v è dato semplicemente dalla medesima funzione $g(\cdot)$ valutata nello stimatore ML di partenza:

$$\hat{v}_{ML} = g(\hat{x}_{ML})$$

Dimostrazione e Significato Operativo:

Se $g(x)$ è una trasformazione biunivoca/invertibile, la massimizzazione della verosimiglianza espressa rispetto a v, ossia $f(\mathbf{y}|g^{-1}(v))$, raggiunge il suo valore massimo esattamente in $\hat{v}_{ML} = g(\hat{x}_{ML})$. Se $g(x)$ non è invertibile, la verosimiglianza indotta $f_V(\mathbf{y}|v) \triangleq \sup_{x:g(x)=v} f(\mathbf{y}|x)$ viene massimizzata nello stesso punto.

Vantaggio Ingegneristico:

Molto spesso la stima diretta di un parametro complesso $v = g(x)$ (ad esempio la potenza in dB $P_{dB} = 10\log_{10}(\sigma^2)$ o l'energia di un segnale) risulta analiticamente ardua. Sfruttando l'invarianza, il progettista può:

1. Stimare in modo semplice il parametro primario x (es. la media o la varianza campionaria $\hat{\sigma}^2_{ML}$).
2. Applicare direttamente la trasformazione non lineare per ottenere lo stimatore ML del parametro secondario: $\hat{P}_{dB,ML} = 10\log_{10}(\hat{\sigma}^2_{ML})$.

Blocco 2: Stima ML nel Modello Lineare Gaussiano (AWGN Multivariato) e Interpretazione Geometrica

2.1 Formulazione del Modello Lineare Gaussiano

Nelle applicazioni ingegneristiche avanzate (identificazione di sistemi, equalizzazione di canale, fit polinomiale e localizzazione radar/array), la relazione tra il vettore dello stato/parametro incognito $\mathbf{x} \in \mathbb{R}^K$ e il vettore delle misurazioni $\mathbf{y} \in \mathbb{R}^N$ (con $N > K$) è frequentemente descritta da una **trasformazione lineare** corrotta da rumore additivo:

$$\mathbf{y} = H\mathbf{x} + \mathbf{w}$$

Struttura Algebrica degli Elementi del Modello

1. **Il Vettore dei Parametri ($\mathbf{x} \in \mathbb{R}^K$):** Contiene i K parametri deterministici incogniti da stimare.
2. **La Matrice di Osservazione ($H \in \mathbb{R}^{N \times K}$):** Matrice deterministica nota di dimensione $N \times K$ (con $N > K$), le cui colonne rappresentano le forme d'onda base o le risposte

impulsive del sistema. Si assume che H abbia **rango pieno per colonna**, ossia $\text{Rank}(H) = K$. Ciò assicura che le K colonne di H siano linearmente indipendenti.

3. **Il Vettore del Rumore Additivo ($\mathbf{w} \in \mathbb{R}^N$):** Rumore bianco gaussiano multivariato (AWGN) a media nulla e matrice di covarianza sferica:

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma^2 I_N)$$

4. **Caratterizzazione del Vettore degli Osservabili ($\mathbf{y} \in \mathbb{R}^N$):** Trattandosi di una trasformazione affine di un vettore gaussiano, la distribuzione condizionata delle osservazioni dato il parametro $\mathbf{x}$ conserva rigorosamente la natura gaussiana, con media pari al segnale trasformato $H\mathbf{x}$ e varianza indotta dal rumore:

$$\mathbf{y} \sim \mathcal{N}(H\mathbf{x}, \sigma^2 I_N)$$

La funzione di densità di probabilità (PDF) condizionata delle osservazioni assume la forma esplicita:

$$f(\mathbf{y}|\mathbf{x}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^N \exp\left(-\frac{1}{2\sigma^2} |\mathbf{y} - H\mathbf{x}|^2 \right)$$

2.2 Derivazione Analitica tramite la Log-Verosimiglianza

Per ricavare lo Stimatore di Massima Verosimiglianza $\hat{\mathbf{x}}_{ML}$, si applica la funzione logaritmo naturale alla verosimiglianza $f(\mathbf{y}|\mathbf{x})$, sfruttandone la stretta monotonicità:

$$\ln f(\mathbf{y}|\mathbf{x}) = -\frac{N}{2}\ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} |\mathbf{y} - H\mathbf{x}|^2$$

Riduzione al Problema dei Minimi Quadrati Ordinari (OLS)

Massimizzare la log-verosimiglianza rispetto al vettore $\mathbf{x}$ equivale a minimizzare la norma euclidea al quadrato dell'errore di misurazione $|\mathbf{y} - H\mathbf{x}|^2$:

$$\hat{\mathbf{x}}_{ML} = \arg\max_{\mathbf{x}} \ln f(\mathbf{y}|\mathbf{x}) = \arg\min_{\mathbf{x}} |\mathbf{y} - H\mathbf{x}|^2$$

Espandiamo la forma quadratica della norma euclidea al quadrato sfruttando le proprietà del prodotto trasposto:

$$|\mathbf{y} - H\mathbf{x}|^2 = (\mathbf{y} - H\mathbf{x})^T(\mathbf{y} - H\mathbf{x}) = \mathbf{y}^T\mathbf{y} - \mathbf{y}^T H\mathbf{x} - \mathbf{x}^T H^T\mathbf{y} + \mathbf{x}^T H^T H\mathbf{x}$$

Essendo lo scostamento incrociato uno scalare (1×1), il termine trasposto coincide con se stesso ($\mathbf{y}^T H\mathbf{x} = \mathbf{x}^T H^T\mathbf{y}$):

$$|\mathbf{y} - H\mathbf{x}|^2 = \mathbf{y}^T\mathbf{y} - 2\mathbf{x}^T H^T\mathbf{y} + \mathbf{x}^T H^T H\mathbf{x}$$

Calcolo del Gradiente Vettoriale ed Equazioni Normali

Trattandosi di una funzione quadratica strettamente convessa rispetto a $\mathbf{x}$ (poiché la matrice $H^T H$ è definita positiva), il punto di minimo globale si determina azzerando il gradiente vettoriale calcolato rispetto al parametro $\mathbf{x}$:

$$\nabla_{\mathbf{x}} \left[|\mathbf{y} - H\mathbf{x}|^2 \right] = \nabla_{\mathbf{x}} \left[\mathbf{y}^T\mathbf{y} - 2\mathbf{x}^T H^T \mathbf{y} + \mathbf{x}^T H^T H \mathbf{x} \right] = \mathbf{0}$$

Sfruttando le regole del calcolo differenziale vettoriale:

- $\nabla_{\mathbf{x}}(\mathbf{x}^T\mathbf{b}) = \mathbf{b} \implies \nabla_{\mathbf{x}}(2\mathbf{x}^T H^T \mathbf{y}) = 2H^T\mathbf{y}$
- $\nabla_{\mathbf{x}}(\mathbf{x}^T A\mathbf{x}) = 2A\mathbf{x}$ (per A simmetrica) $\implies \nabla_{\mathbf{x}}(\mathbf{x}^T H^T H\mathbf{x}) = 2H^T H\mathbf{x}$

Otteniamo il sistema vettoriale delle **Equazioni Normali**:

$$2H^T H\mathbf{x} - 2H^T\mathbf{y} = \mathbf{0} \iff H^T H\mathbf{x} = H^T\mathbf{y}$$

2.3 Soluzione Analitica, Pseudoinversa ed Interpretazione Geometrica

Soluzione Analitica ed Operatore Pseudoinversa

Essendo la matrice H a rango pieno per colonna ($\text{Rank}(H) = K$), la matrice di Gramm $H^T H$ di dimensione $K \times K$ è strettamente definita positiva e pertanto **invertibile**:

$$\hat{\mathbf{x}}_{ML} = (H^T H)^{-1} H^T \mathbf{y}$$

La matrice $H^+ \triangleq (H^T H)^{-1} H^T$ di dimensione $K \times N$ prende il nome di Pseudoinversa di Moore-Penrose (o pseudoinversa sinistra) della matrice H.

Stima del Segnale Trasformato e Proprietà di Invariance

Se l'obiettivo del sistema è stimare il segnale trasformato $\mathbf{v} = H\mathbf{x}$ (la componente di segnale utile priva di rumore), applicando la **Proprietà di Invarianza dello stimatore ML** ricaviamo direttamente:

$$\hat{\mathbf{v}}_{ML} = H\hat{\mathbf{x}}_{ML} = H(H^T H)^{-1} H^T \mathbf{y}$$

Definiamo la matrice $P_H \triangleq H(H^T H)^{-1} H^T$ di dimensione $N \times N$. Essa gode di due proprietà fondamentali:

1. **Simmetria:** $P_H^T = \left(H(H^T H)^{-1} H^T \right)^T = H(H^T H)^{-1} H^T = P_H$
2. **Idempotenza:** $P_H^2 = \left(H(H^T H)^{-1} H^T \right) \left(H(H^T H)^{-1} H^T \right)$
   $= H(H^T H)^{-1} (H^T H)(H^T H)^{-1} H^T = P_H$

In algebra lineare, una matrice simmetrica ed idempotente rappresenta un Operatore di Proiezione Ortogonale.

Interpretazione Geometrica nello Spazio delle Osservazioni

La matrice P_H esegue la **proiezione ortogonale** del vettore misurato rumoroso $\mathbf{y} \in \mathbb{R}^N$ sullo sottospazio vettoriale K-dimensionale generato dalle colonne della matrice H (denotato con $\text{Range}(H)$):

```
        y (Vettore osservato rumoroso in R^N)
        | \
        |  \  w_orth (Errore di misura ortogonale)
        |   \
        v----+--------------------> Range(H) (Sottospazio K-dimensionale)
          v_hat_ML = P_H * y (Segnale stimato ottimale)
```

Lo stimatore ML decompone l'osservazione $\mathbf{y}$ in due componenti ortogonali:

- $\hat{\mathbf{v}}_{ML} = P_H \mathbf{y} \in \text{Range}(H)$ (la componente di segnale ammissibile).
- $\mathbf{e} = (I_N - P_H)\mathbf{y} \in \text{Range}(H)^\perp$ (il residuo di rumore ortogonale allo spazio del segnale).

- [x] ~~**Inserisci foto**: *Scomposizione del vettore osservato tramite l'operatore di proiezione ortogonale* $P_H = H(H^T H)^{-1} H^T$ *e interpretazione geometrica di minimizzazione della distanza euclidea* (da `Elaborazione dei Segnali Digitali.pdf`, Lezione 10, pagina 2 in alto).~~

2.4 Caratterizzazione Statistica ed Ottimalità dello Stimatore ML Lineare

A differenza di molti contesti generici in cui le proprietà dell'ML valgono solo asintoticamente ($N \to \infty$), nel **Modello Lineare Gaussiano** le proprietà di ottimalità valgono **in modo esatto anche per un numero finito di campioni** N:

1. Calcolo del Valore Atteso (Non Polarizzazione)

Verifichiamo la correttezza dello stimatore sostituendo il modello di osservazione $\mathbf{y} = H\mathbf{x} + \mathbf{w}$:

$$E[\hat{\mathbf{x}}_{ML}] = E\left[(H^T H)^{-1} H^T (H\mathbf{x} + \mathbf{w})\right] = (H^T H)^{-1} H^T H\mathbf{x} + (H^T H)^{-1} H^T E[\mathbf{w}]$$

Poiché il rumore ha media nulla ($E[\mathbf{w}] = \mathbf{0}$), otteniamo:

$$E[\hat{\mathbf{x}}_{ML}] = \mathbf{x} \quad \forall \mathbf{x} \in \mathbb{R}^K$$

Lo stimatore ML nel modello lineare gaussiano è **esattamente non polarizzato (unbiased)** per qualsiasi dimensione N.

2. Calcolo della Matrice di Covarianza

Calcoliamo la variabilità stocastica dello stimatore:

$$C_{\hat{\mathbf{x}}_{ML}} = \text{Cov}[\hat{\mathbf{x}}_{ML}] = \text{Cov}\left[(H^T H)^{-1} H^T \mathbf{y}\right] = (H^T H)^{-1} H^T \text{Cov}[\mathbf{y}] \left((H^T H)^{-1} H^T\right)^T$$

Poiché $\text{Cov}[\mathbf{y}] = \sigma^2 I_N$, la relazione si semplifica in:

$$C_{\hat{\mathbf{x}}_{ML}} = \sigma^2 (H^T H)^{-1} H^T I_N H (H^T H)^{-1} = \sigma^2 (H^T H)^{-1} (H^T H)(H^T H)^{-1} = \sigma^2 (H^T H)^{-1}$$

3. Distribuzione di Probabilità Esatta ed Efficienza (Raggiungimento del CRLB)

Essendo una trasformazione lineare del vettore gaussiano $(\mathbf{y})$, lo stimatore $\hat{\mathbf{x}}_{ML}$ segue **esattamente** una distribuzione normale multivariata per qualsiasi N:

$$\hat{\mathbf{x}}_{ML} \sim \mathcal{N}\left(\mathbf{x}, \sigma^2 (H^T H)^{-1}\right)$$

Inoltre, la matrice di covarianza $C_{\hat{\mathbf{x}}_{ML}} = \sigma^2 (H^T H)^{-1}$ coincide esattamente con la matrice del **Limite Inferiore di Cramér-Rao (CRLB)**. Di conseguenza, nel modello lineare gaussiano, lo stimatore ML è **efficiente** e rappresenta lo **stimatore non polarizzato a varianza minima (MVU)**.

Blocco 3: Teoria dello Stimatore MVU, Statistiche Sufficienti e Teorema di Rao-Blackwell-Lehmann-Scheffé (RBLS)

3.1 Definizione di Stimatore MVU (Minimum Variance Unbiased)

Nel contesto della stima non-bayesiana dei parametri, l'obiettivo fondamentale del progettista è individuare uno stimatore che riduca al minimo l'errore di stima. Come dimostrato nella scomposizione dell'Errore Quadratico Medio:

$$\text{MSE}(\hat{x}) = \text{Var}[\hat{x}] + |\mathbf{b}(x)|^2$$

se restringiamo la classe di ricerca agli **stimatori non polarizzati** (ovvero con bias identicamente nullo $\mathbf{b}(x) = \mathbf{0} \implies E[\hat{x}] = x, \forall x \in \mathcal{X}$), la minimizzazione dell'MSE equivale esattamente alla minimizzazione della varianza dello stimatore.

Definizione Formale di Stimatore MVU

Uno stimatore non polarizzato $\hat{x}_{MVU}(\mathbf{y})$ prende il nome di **Stimatore Non Polarizzato a Varianza Minima** (*Minimum Variance Unbiased Estimator*, MVU) se la sua varianza (o la traccia della sua matrice di covarianza) risulta minore o uguale alla varianza di qualsiasi altro generico stimatore non polarizzato $\hat{x}(\mathbf{y})$ **per ogni possibile valore del parametro incognito** x:

$$E[\hat{x}_{MVU}] = x \quad \forall x \in \mathcal{X}$$

$$\mathrm{Var}[\hat{x}_{MVU}] \leq \mathrm{Var}[\hat{x}] \quad \forall x \in \mathcal{X}, \quad \forall \hat{x} \text{ tale che } E[\hat{x}] = x$$

La Sfida della Minimizzazione Uniforme

La difficoltà principale nell'individuazione dello Stimatore MVU risiede nel vincolo di **ottimalità uniforme**: la disuguaglianza $\mathrm{Var}[\hat{x}_{MVU}] \leq \mathrm{Var}[\hat{x}]$ deve valere per **qualsiasi** punto x del dominio.

Uno stimatore banale del tipo $\hat{x}(\mathbf{y}) = x_0$ (costante) presenta varianza nulla nel punto specifico $x = x_0$, ma introduce una polarizzazione enorme per ogni $x \neq x_0$. Lo stimatore MVU deve invece rimanere non polarizzato ovunque e garantire la varianza minima su tutto il dominio parametricamente ammissibile.

3.2 Ruolo della Statistica Sufficiente e Teorema di Rao-Blackwell

Per sintetizzare le osservazioni eliminate dal rumore irrilevante e procedere verso la ricerca dell'MVU, si sfrutta il concetto di **Statistica Sufficiente**.

Richiamo: Teorema di Fattorizzazione di Neyman-Fisher

Una statistica $T(\mathbf{y})$ (scalare o vettoriale) si definisce **sufficiente** per il parametro x se la distribuzione di probabilità condizionata delle osservazioni $\mathbf{y}$ dato $T(\mathbf{y})$ non dipende più dal parametro incognito x.

Per il **Teorema di Fattorizzazione di Neyman-Fisher**, la PDF/PMF condizionata si scompone nel prodotto di due fattori distinti:

$$f(\mathbf{y}|x) = g(T(\mathbf{y}), x) \cdot h(\mathbf{y})$$

dove $g(T(\mathbf{y}), x)$ concentra tutta l'interazione tra i dati e il parametro attraverso la statistica T, mentre $h(\mathbf{y})$ è una funzione puramente dipendente dalle osservazioni.

Il Teorema di Rao-Blackwell (Rao-Blackwellization)

Il **Teorema di Rao-Blackwell** fornisce una procedura analitica sistematica per **ridurre la varianza** di un qualsiasi stimatore non polarizzato di partenza, condizionandolo a una

statistica sufficiente.

Enunciato del Teorema:

Sia $\hat{x}_0(\mathbf{y})$ un generico stimatore non polarizzato per il parametro x, e sia $T(\mathbf{y})$ una statistica sufficiente per x. Si definisce il nuovo stimatore $\hat{x}_1(T)$ tramite l'operatore di **valore atteso condizionato**:

$$\hat{x}_1(T) \triangleq E\left[\hat{x}_0(\mathbf{y}) \mid T(\mathbf{y})\right]$$

Allora valgono le seguenti tre proprietà fondamentali:

1. **Misurabilità e Validità dello Stimatore:** Poiché $T(\mathbf{y})$ è una statistica sufficiente, la distribuzione di $\mathbf{y}$ dato T prescinde da x. Di conseguenza, il valore atteso condizionato $\hat{x}_1 = E[\hat{x}_0|\mathbf{T}]$ è una funzione esclusiva dei dati osservati $T(\mathbf{y})$ e non contiene il parametro incognito x, risultando a tutti gli effetti uno stimatore ammissibile.
2. **Conservazione della Non Polarizzazione:** Il nuovo stimatore $\hat{x}_1$ conserva la correttezza del valore medio:

$$E[\hat{x}_1] = E_T\left[E[\hat{x}_0|T]\right] = E[\hat{x}_0] = x$$

3. **Riduzione (od Uguaglianza) della Varianza:** La varianza dello stimatore condizionato $\hat{x}_1$ è **sempre minore o al più uguale** alla varianza dello stimatore grezzo di partenza $\hat{x}_0$:

$$\mathrm{Var}[\hat{x}_1] \leq \mathrm{Var}[\hat{x}_0] \quad \forall x \in \mathcal{X}$$

Dimostrazione della Riduzione di Varianza:

La dimostrazione si basa sulla **Legge della Varianza Totale** (o Teorema di Decomposizione della Varianza):

$$\mathrm{Var}[\hat{x}_0] = \mathrm{Var}_T\left(E[\hat{x}_0|T]\right) + E_T\left[\mathrm{Var}(\hat{x}_0|T)\right]$$

Riconoscendo che $E[\hat{x}_0|T] = \hat{x}_1(T)$:

$$\mathrm{Var}[\hat{x}_0] = \mathrm{Var}[\hat{x}_1] + E_T\left[\mathrm{Var}(\hat{x}_0|T)\right]$$

Poiché la varianza condizionata $\mathrm{Var}(\hat{x}_0|T)$ è una quantità non negativa, il suo valore atteso $E_T[\mathrm{Var}(\hat{x}_0|T)] \geq 0$. Ne consegue direttamente che:

$$\mathrm{Var}[\hat{x}_0] \geq \mathrm{Var}[\hat{x}_1]$$

L'uguaglianza $\mathrm{Var}[\hat{x}_1] = \mathrm{Var}[\hat{x}_0]$ si verifica se e solo se lo stimatore di partenza $\hat{x}_0$ era già una funzione esclusiva della statistica sufficiente $T(\mathbf{y})$.

- [x] ~~**Inserisci foto**: *Dimostrazione del Teorema di Rao-Blackwell tramite la legge della varianza totale ed isolamento del termine non negativo* $E_T[\mathrm{Var}(\hat{x}_0|T)]$ (da `Elaborazione dei Segnali Digitali.pdf`, Lezione 10, pagina 3 in alto).~~

3.3 Teorema di Lehmann-Scheffé e Condizioni di Ottimalità per l'ML

Il Teorema di Rao-Blackwell garantisce che l'MVU debba essere cercato tra le funzioni di una statistica sufficiente, ma non assicura che il condizionamento di uno stimatore generico produca l'unico MVU assoluto. Per ottenere l'unicità e la certezza dell'MVU si introduce il concetto di **Completezza**.

Definizione di Statistica Sufficiente Completa (SSC)

Una statistica sufficiente $T(\mathbf{y})$ si definisce **completa** (Statistica Sufficiente Completa, SSC) se l'unica funzione misurabile $v(T)$ la cui aspettazione sia identicamente nulla per qualsiasi valore del parametro x è la funzione quasi ovunque nulla:

$$E_x[v(T)] = 0 \quad \forall x \in \mathcal{X} \implies P_x(v(T) = 0) = 1 \quad \forall x \in \mathcal{X}$$

Il Teorema di Lehmann-Scheffé (Rao-Blackwell-Lehmann-Scheffé, RBLS)

Il Teorema di Lehmann-Scheffé stabilisce il criterio definitivo per l'individuazione e la dimostrazione di unicità dello stimatore MVU.

Enunciato del Teorema:

Sia $T_c(\mathbf{y})$ una **Statistica Sufficiente Completa** (SSC) per il parametro x. Se si individua o si costruisce una funzione $g(T_c)$ che risulta essere uno stimatore **non polarizzato** per x (ovvero $E[g(T_c)] = x$), allora:

1. $g(T_c)$ **è l'UNICO stimatore non polarizzato funzione di** T_c**.**
2. $g(T_c)$ **è RIGOROSAMENTE lo Stimatore ad Errore Quadratico Medio Minimo e Varianza Minima (MVU).**

Dimostrazione dell'Unicità dell'MVU:

Supponiamo per assurdo che esistano due distinti stimatori non polarizzati $g_1(T_c)$ e $g_2(T_c)$ entrambi funzioni della medesima SSC T_c. Poiché entrambi sono non polarizzati:

$$E_x[g_1(T_c)] = x \quad \text{e} \quad E_x[g_2(T_c)] = x \quad \forall x$$

Definiamo la funzione differenza $v(T_c) \triangleq g_1(T_c) - g_2(T_c)$. Calcolandone il valore atteso:

$$E_x[v(T_c)] = E_x[g_1(T_c) - g_2(T_c)] = E_x[g_1(T_c)] - E_x[g_2(T_c)] = x - x = 0 \quad \forall x$$

Ma poiché per ipotesi la statistica T_c è **completa**, la condizione $E_x[v(T_c)] = 0, \forall x$ impone che la funzione $v(T_c)$ debba essere identicamente nulla quasi ovunque:

$$v(T_c) = 0 \implies g_1(T_c) = g_2(T_c) \quad \text{quasi ovunque}$$

Questo prova che **esiste un solo ed unico stimatore non polarizzato basato sulla statistica sufficiente completa**, e per il Teorema di Rao-Blackwell tale stimatore unico è inevitabilmente l'**MVU**.

- [x] **Inserisci foto**: ~~*Dimostrazione di unicità dello stimatore MVU per la classe delle statistiche sufficienti complete tramite l'annullamento della funzione differenza* $v(T_c) = g_1(T_c) - g_2(T_c)$ (da `Elaborazione dei Segnali Digitali.pdf`, Lezione 10, pagina 3 in basso).~~

Il Ponte Concettuale tra lo Stimatore ML e lo Stimatore MVU

I teoremi di Rao-Blackwell e Lehmann-Scheffé forniscono una chiave di lettura chiarissima per comprendere le relazioni tra lo **Stimatore di Massima Verosimiglianza (ML)** e lo **Stimatore MVU**:

1. **Proprietà di Dipendenza dalla Statistica Sufficiente:** Per il Teorema di Fattorizzazione di Neyman-Fisher, la log-verosimiglianza si scrive come $\ln f(\mathbf{y}|x) = \ln g(T(\mathbf{y}), x) + \ln h(\mathbf{y})$. Quando si deriva rispetto a x per cercare il massimo ML:

   $$\frac{\partial \ln f(\mathbf{y}|x)}{\partial x} = \frac{\partial \ln g(T(\mathbf{y}), x)}{\partial x} = 0$$

   Lo stimatore ML $\hat{x}_{ML}(\mathbf{y})$ è **sempre unicamente funzione della statistica sufficiente** $T(\mathbf{y})$.
2. **Condizione di Coincidenza tra ML ed MVU:** Se uno stimatore ML $\hat{x}_{ML}$ è **non polarizzato al finito** (ossia $E[\hat{x}_{ML}] = x$ per qualsiasi dimensione del campione N) ed è basato su una Statistica Sufficiente Completa $T_c(\mathbf{y})$, per il Teorema di Lehmann-Scheffé esso **coincide rigorosamente con lo stimatore MVU**.
3. **Appartenenza alla Famiglia Esponenziale (K-PEC):** In tutti i problemi modellabili all'interno della Famiglia Esponenziale Regolare (come il Modello Lineare Gaussiano trattato nel Blocco 2), l'equazione di verosimiglianza fornisce direttamente lo stimatore ML che risulta non polarizzato al finito ed espresso in funzione della SSC. In questi contesti, l'ML e l'MVU sono la medesima entità analitica.

Sintesi Generale della Lezione ELSD 10

Con la conclusione del **Blocco 3**, la Lezione **ELSD 10** ha delineato il quadro teorico della stima non-bayesiana:

- **Blocco 1:** Transizione alla stima continua, metrica dell'MSE ($\mathrm{MSE} = \mathrm{Varianza} + \mathrm{Bias}^2$) e proprietà dello stimatore ML (consistenza, non polarizzazione asintotica ed invarianza $\hat{v}_{ML} = g(\hat{x}_{ML})$).
- **Blocco 2:** Derivazione esatta dell'ML nel modello lineare gaussiano $\mathbf{y} = H\mathbf{x} + \mathbf{w}$, pseudoinversa $\hat{\mathbf{x}}_{ML} = (H^T H)^{-1} H^T \mathbf{y}$, interpretazione geometrica di proiezione ortogonale $P_H = H(H^T H)^{-1} H^T$ e calcolo esatto della covarianza $\sigma^2 (H^T H)^{-1}$.
- **Blocco 3:** Minimizzazione della varianza tramite condizionamento su statistiche sufficienti (Rao-Blackwell) e dimostrazione dell'unicità dell'MVU tramite il Teorema di Lehmann-Scheffé (RBLS).