ELSD 11

2026-10-26

---

tipo: lezione
materia: Comunicazioni Digitali / Elaborazione dei Segnali Digitali
lezione: ELSD 11
data: 2026-10-26
libro_riferimento: Fundamentals of Statistical Signal Processing (Steven M. Kay), Vol. I (Cap. 2, 5, 7)
argomenti_trattati:

- Dimostrazione analitica di Rao-Blackwell e annullamento del termine incrociato
- Procedura diretta di Lehmann-Scheffé per l'individuazione dell'MVU
- Modelli a supporto variabile e Statistica Sufficiente Completa per l'Uniforme U(0, b)
- Statistica d'ordine massimo e decadimento quadratico della varianza (1/N^2)
- Teorema di Invarianza Affine dell'MVU e confronto con la media campionaria
- Teorema di coincidenza tra Stimatore ML ed Stimatore MVU nel Modello Lineare

tags:

- #elsd11
- #rao-blackwell
- #lehmann-scheffe
- #supporto-variabile
- #statistica-ordine-massimo
- #invarianza-affine
- #coincidenza-ml-mvu

TABLE OF CONTENTS

- Blocco 1 Metodologie Operative per l'MVU e Dimostrazione del Teorema di Rao-Blackwell
  - 1.1 Sintesi dei Teoremi RBLS e le Due Vie per Trovare l'MVU
  - 1.2 Dimostrazione Analitica Rigorosa del Teorema di Rao-Blackwell
  - 1.3 Applicazione Rapida Stima della Media Gaussiana
- Blocco 2 Caso Non-Esponenziale – Stima dell'Estremo Superiore b in Distribuzione Uniforme $ mathcal{U}(0, b)$

- 2.1 Modello a supporto variabile e fattorizzazione di Neyman-Fisher
- 2.2 Dimostrazione della Completezza per $T = max y_i$
- 2.3 Costruzione dello Stimatore $ hat{b}_{MVU}$ e Calcolo delle Prestazioni

- Blocco 3 Invarianza Affine dell'MVU, Confronto delle Prestazioni e Modello Lineare Gaussiano
  - 3.1 Teorema di Invarianza Stimatore ML vs Stimatore MVU
  - 3.2 Stima della Media dell'Uniforme $ mu = b/2$ e Confronto con la Media Campionaria
  - 3.3 Il Modello Lineare Gaussiano e la Coincidenza ML-MVU

Blocco 1: Metodologie Operative per l'MVU e Dimostrazione del Teorema di Rao-Blackwell

1.1 Sintesi dei Teoremi RBLS e le Due Vie per Trovare l'MVU

La determinazione dello **Stimatore Non Polarizzato a Varianza Minima (MVU)** costituisce l'obiettivo centrale della stima classica non-bayesiana69. Il fondamento teorico per individuare tale stimatore si basa sull'integrazione di due teoremi cardine:

1. **Teorema di Rao-Blackwell:** Dato un generico stimatore non polarizzato $\hat{x}_0(\mathbf{y})$ (con $E[\hat{x}_0] = x$) e una statistica sufficiente $T(\mathbf{y})$, lo stimatore ottenuto per condizionamento $\hat{x}_1 \triangleq E[\hat{x}_0|T]$ è ancora non polarizzato ($E[\hat{x}_1] = x$) e presenta una varianza non superiore a quella di partenza: $\mathrm{Var}[\hat{x}_1] \leq \mathrm{Var}[\hat{x}_0]$.
2. **Teorema di Lehmann-Scheffé:** Se la statistica di condizionamento $T_c(\mathbf{y})$ è non solo sufficiente, ma anche **completa** (Statistica Sufficiente Completa, SSC), allora $\hat{x}_{MVU} = E[\hat{x}_0|T_c]$ è l'unico stimatore non polarizzato funzione di T_c e garantisce la varianza minima assoluta.

Dall'unione di questi due principi scaturiscono **due metodologie operative alternative** per la costruzione dello stimatore MVU:

Metodo 1: Procedura Canonica per Condizionamento (RBLS)

1. Si individua un qualsiasi stimatore non polarizzato iniziale $\hat{x}_0(\mathbf{y})$ tale che $E[\hat{x}_0] = x$ (anche molto semplice o banale, come la prima singola osservazione $\hat{x}_0 = y_1$).
2. Si individua una Statistica Sufficiente Completa $T_c(\mathbf{y})$ (ad esempio tramite la famiglia esponenziale K-PEC o il teorema di fattorizzazione di Neyman-Fisher).
3. Si calcola il valore atteso condizionato rispetto alla SSC:

$$\hat{x}_{MVU} = E\left[\hat{x}_0(\mathbf{y}) \,\middle|\, T_c(\mathbf{y})\right]$$

   Tale stimatore è garantito essere l'MVU.

Metodo 2: Procedura Diretta (Funzione Non Polarizzata della SSC)

Il Teorema di Lehmann-Scheffé dimostra che, se la SSC T_c esiste, qualsiasi stimatore MVU deve necessariamente essere una funzione deterministica di T_c. Poiché la proprietà di completezza assicura che **esiste una e una sola funzione di T_c priva di polarizzazione**, la ricerca dell'MVU può essere effettuata per ispezione diretta:

1. Si determina la Statistica Sufficiente Completa $T_c(\mathbf{y})$.
2. Si individua (o si costruisce per via algebrica) una generica funzione scalare o vettoriale $g(T_c)$ la cui media coincida esattamente con il parametro da stimare:

$$E\left[g(T_c)\right] = x \quad \forall x$$

3. Per il lemma di unicità di Lehmann-Scheffé, tale funzione coincide immediatamente e rigorosamente con lo stimatore ottimo:

$$\hat{x}_{MVU} = g(T_c(\mathbf{y}))$$

Questa seconda via è di gran lunga la più rapida e computazionalmente vantaggiosa nelle applicazioni pratiche, evitando il calcolo spesso proibitivo di integrali condizionati.

1.2 Dimostrazione Analitica Rigorosa del Teorema di Rao-Blackwell

Consideriamo uno stimatore non polarizzato arbitrario $\hat{x}_0(\mathbf{y})$ per il parametro vettoriale o scalare x, con $E[\hat{x}_0] = x$, e sia $T(\mathbf{y})$ una statistica sufficiente. Definiamo il nuovo stimatore per condizionamento:

$$\hat{x}_1(T) \triangleq E[\hat{x}_0(\mathbf{y})|T(\mathbf{y})]$$

1. Verifica della Correttezza (Unbiasedness) di $\hat{x}_1$

Applicando la **legge delle aspettative iterate** (o proprietà a torre del valore atteso):

$$E[\hat{x}_1] = E_T\left[E_{\mathbf{y}|T}[\hat{x}_0|T]\right] = E_{\mathbf{y}}[\hat{x}_0] = x$$

Lo stimatore condizionato $\hat{x}_1$ è dunque rigorosamente non polarizzato.

2. Scomposizione della Varianza ed Errore Quadratico

Essendo entrambi gli stimatori non polarizzati, la loro varianza coincide con l'Errore Quadratico Medio rispetto al parametro vero x:

$$\mathrm{Var}[\hat{x}_0] = E\left[\|\hat{x}_0 - x\|^2\right]$$

Aggiungendo e sottraendo all'interno della norma la quantità $\hat{x}_1$:

$$\hat{x}_0 - x = (\hat{x}_0 - \hat{x}_1) + (\hat{x}_1 - x)$$

Calcolando la norma al quadrato mediante il prodotto scalare:

$$[\|\hat{x}_0 - x|^2 = |(\hat{x}_0 - \hat{x}_1) + (\hat{x}_1 - x)|^2 = |\hat{x}_1 - x|^2 + |\hat{x}_0 - \hat{x}_1|^2 + 2(\hat{x}_0 - \hat{x}_1)^T(\hat{x}_1 - x)]$$

Applicando l'operatore di aspettazione $E[\cdot]$:

$$\mathrm{Var}[\hat{x}_0] = \underbrace{E\left[\|\hat{x}_1 - x\|^2\right]}_{\mathrm{Var}[\hat{x}_1]} + \underbrace{E\left[\|\hat{x}_0 - \hat{x}_1\|^2\right]}_{\geq 0} + 2\underbrace{E\left[(\hat{x}_0 - \hat{x}_1)^T(\hat{x}_1 - x)\right]}_{\text{Termine Incrociato } I_{cross}}$$

Il secondo termine $E[\|\hat{x}_0 - \hat{x}_1\|^2] \geq 0$ in quanto valore atteso di una quantità non negativa (norma euclidea al quadrato). Rimane da valutare il termine incrociato I_{cross}.

3. Dimostrazione dell'Annullamento del Termine Incrociato

Sfruttando nuovamente il condizionamento rispetto a T tramite la proprietà a torre:

$$I_{cross} = E\left[(\hat{x}_0 - \hat{x}_1)^T(\hat{x}_1 - x)\right] = E_T\left[E_{\mathbf{y}|T}\left[(\hat{x}_0 - \hat{x}_1)^T(\hat{x}_1 - x)\,\middle|\,T\right]\right]$$

Analizziamo il valore atteso interno condizionato a T:

- Il parametro x è deterministico.
- Lo stimatore $\hat{x}_1 = E[\hat{x}_0|T]$ è, per definizione, una funzione deterministica di T; pertanto, una volta fissata la realizzazione di T, il termine $(\hat{x}_1 - x)$ si comporta come un **vettore costante deterministico** rispetto all'aspettazione interna $E_{\mathbf{y}|T}[\cdot|T]$.

Possiamo estrarre il termine costante a fattor comune a destra:

$$E_{\mathbf{y}|T}\left[(\hat{x}_0 - \hat{x}_1)^T(\hat{x}_1 - x)\,\middle|\,T\right] = \left(E_{\mathbf{y}|T}\left[(\hat{x}_0 - \hat{x}_1)\,\middle|\,T\right]\right)^T(\hat{x}_1 - x)$$

Sviluppiamo l'aspettazione del fattore sinistro sfruttando la linearità dell'operatore:

$$E_{\mathbf{y}|T}[\hat{x}_0 - \hat{x}_1|T] = E_{\mathbf{y}|T}[\hat{x}_0|T] - E_{\mathbf{y}|T}[\hat{x}_1|T]$$

Poiché per definizione $E_{\mathbf{y}|T}[\hat{x}_0|T] = \hat{x}_1$ e $\hat{x}_1$ è costante condizionatamente a T ($E_{\mathbf{y}|T}[\hat{x}_1|T] = \hat{x}_1$):

$$E_{\mathbf{y}|T}[\hat{x}_0 - \hat{x}_1|T] = \hat{x}_1 - \hat{x}_1 = \mathbf{0}$$

Di conseguenza, l'aspettazione interna si annulla identicamente per ogni realizzazione di T:

$$I_{cross} = E_T\left[\mathbf{0}^T(\hat{x}_1 - x)\right] = 0$$

4. Conclusione della Dimostrazione

Sostituendo $I_{cross} = 0$ nell'equazione di varianza complessiva:

$$\mathrm{Var}[\hat{x}_0] = \mathrm{Var}[\hat{x}_1] + E\left[\|\hat{x}_0 - \hat{x}_1\|^2\right]$$

Essendo $E[\|\hat{x}_0 - \hat{x}_1\|^2] \geq 0$, si conclude che:

$$\mathrm{Var}[\hat{x}_0] \geq \mathrm{Var}[\hat{x}_1] \iff \mathrm{Var}[\hat{x}_1] \leq \mathrm{Var}[\hat{x}_0]$$

L'uguaglianza $\mathrm{Var}[\hat{x}_1] = \mathrm{Var}[\hat{x}_0]$ si verifica se e solo se $\hat{x}_0 = \hat{x}_1$ quasi ovunque, ossia se lo stimatore grezzo iniziale $\hat{x}_0$ era già una funzione esclusiva della statistica sufficiente T.

1.3 Applicazione Rapida: Stima della Media Gaussiana

Per chiarire l'efficacia del **Metodo 2 (Diretto)**, consideriamo il problema di stimare la media μ a partire da N osservazioni scalari indipendenti e identicamente distribuite secondo una normale:

$$y_i \sim \mathcal{N}(\mu, \sigma^2), \quad i = 1, \ldots, N \quad \text{con } \sigma^2 \text{ nota}$$

Individuazione della SSC tramite la Famiglia Esponenziale (K-PEC)

La densità di probabilità congiunta del vettore $\mathbf{y} = [y_1, \ldots, y_N]^T$ si esprime nella forma canonica della famiglia esponenziale k-parametrica119:

$$f(\mathbf{y}|\mu) = \left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N \exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{N}(y_i - \mu)^2\right)$$

Espandendo il quadrato all'esponente:

$$f(\mathbf{y}|\mu) = \underbrace{\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N \exp\left(-\frac{N\mu^2}{2\sigma^2}\right)}_{c(\mu)} \cdot \underbrace{\exp\left(-\frac{1}{2\sigma^2}\sum_{i=1}^{N} y_i^2\right)}_{h(\mathbf{y})} \cdot \exp\left(\frac{\mu}{\sigma^2}\sum_{i=1}^{N} y_i\right)$$

Il termine di accoppiamento parametro-dati presenta la struttura $\exp\left(\mathbf{a}^T(\mu)\mathbf{T}(\mathbf{y})\right)$ con $\mathbf{a}(\mu) = \frac{\mu}{\sigma^2}$. Per le proprietà generali delle distribuzioni K-PEC regolari, la statistica naturale di accoppiamento costituisce una **Statistica Sufficiente Completa (SSC)** per il parametro μ:

$$T_c(\mathbf{y}) = \sum_{i=1}^{N} y_i$$

Ricerca della Funzione Non Polarizzata $g(T_c)$

Calcoliamo il valore atteso della statistica sufficiente completa T_c:

$$E\left[T_c(\mathbf{y})\right] = E\left[\sum_{i=1}^{N} y_i\right] = \sum_{i=1}^{N} E[y_i] = N\mu$$

La statistica grezza T_c ha media $N\mu$ e presenta dunque una polarizzazione di scala pari a un fattore N.

Per ottenere uno stimatore non polarizzato è sufficiente riscalare linearmente la statistica completa definendo la funzione:

$$g(T_c) \triangleq \frac{T_c(\mathbf{y})}{N} = \frac{1}{N}\sum_{i=1}^{N} y_i$$

Verifichiamo la condizione di correttezza:

$$E[g(T_c)] = E\left[\frac{1}{N}\sum_{i=1}^{N} y_i\right] = \frac{1}{N}(N\mu) = \mu$$

Essendo $g(T_c)$ una funzione della Statistica Sufficiente Completa T_c con valore atteso identicamente pari a μ, per il **Teorema di Lehmann-Scheffé** essa coincide in modo unico con lo stimatore MVU:

$$\hat{\mu}_{MVU} = \frac{1}{N}\sum_{i=1}^{N} y_i = \bar{y}$$

Lo stimatore a minima varianza coincide esattamente con la **media campionaria**, derivata in un singolo passaggio senza la necessità di calcolare integrali di aspettazione condizionata.

Blocco 2: Caso Non-Esponenziale – Stima dell'Estremo Superiore b in Distribuzione Uniforme $\mathcal{U}(0, b)$

2.1 Modello a supporto variabile e fattorizzazione di Neyman-Fisher

Consideriamo un vettore di N osservazioni indipendenti ed identicamente distribuite (i.i.d.) secondo una legge uniforme su intervallo a estremo superiore incognito:

$$y_i \sim \mathcal{U}(0, b) \quad \text{con } b > 0 \text{ parametro deterministico incognito}, \quad i = 1, \dots, N$$

La singola densità di probabilità marginale di ciascun campione è una finestra rettangolare di ampiezza $1/b$ e durata b:

$$f(y_i|b) = \frac{1}{b}\,\mathrm{rect}\left(\frac{y_i - b/2}{b}\right) = \begin{cases} \frac{1}{b} & \text{se } 0 \le y_i \le b \\ 0 & \text{altrove} \end{cases}$$

Per via dell'indipendenza statistica, la densità di probabilità congiunta dell'intero vettore delle osservazioni $\mathbf{y} = [y_1, y_2, \ldots, y_N]^T$ è data dalla produttoria delle singole densità marginali:

$$f(\mathbf{y}|b) = \prod_{i=1}^{N} f(y_i|b) = \begin{cases} \frac{1}{b^N} & \text{se } 0 \le y_i \le b \quad \forall i = 1, \ldots, N \\ 0 & \text{altrove} \end{cases}$$

Riformulazione tramite Statistiche d'Ordine e Funzioni a Gradino

La condizione logica per cui **tutti** gli N campioni devono cadere simultaneamente nell'intervallo $[0, b]$ equivale a richiedere congiuntamente che:

1. Il valore minimo tra tutti i campioni sia non negativo: $\min_i y_i \ge 0$.
2. Il valore massimo tra tutti i campioni sia minore o uguale all'estremo superiore: $\max_i y_i \le b$.

Ordinando i campioni in ordine crescente (statistiche d'ordine):

$$y_{(1)} \le y_{(2)} \le \cdots \le y_{(N)}$$

dove $y_{(1)} \triangleq \min_i y_i$ rappresenta il minimo e $y_{(N)} \triangleq \max_i y_i$ rappresenta il massimo del vettore.

Sfruttando la funzione gradino unitario di Heaviside $u(\cdot)$ (definita come $u(t) = 1$ per $t \ge 0$ e $u(t) = 0$ per $t < 0$), la PDF congiunta si scrive in forma analitica compatta:

$$f(\mathbf{y}|b) = \frac{1}{b^N} \cdot u(y_{(1)}) \cdot u(b - y_{(N)})$$

Individuazione della Statistica Sufficiente

Isoliamo i fattori della PDF congiunta per applicare il **Teorema di Fattorizzazione di Neyman-Fisher**:

$$f(\mathbf{y}|b) = \underbrace{\frac{1}{b^N} u(b - y_{(N)})}_{g(T(\mathbf{y}), b)} \cdot \underbrace{u(y_{(1)})}_{h(\mathbf{y})}$$

- Il termine $h(\mathbf{y}) = u(y_{(1)})$ dipende **esclusivamente dai dati osservati** e non contiene il parametro incognito b.

- Il termine $g(T(\mathbf{y}), b) = \frac{1}{b^N} u(b - y_{(N)})$ concentra l'intera dipendenza dal parametro b e interagisce con le osservazioni **esclusivamente attraverso la statistica scalare**:

$$T(\mathbf{y}) \triangleq y_{(N)} = \max_{i=1,\dots,N} y_i$$

Per il Teorema di Fattorizzazione, $T(\mathbf{y}) = \max_i y_i$ è una **Statistica Sufficiente** per il parametro b.

> **Nota fondamentale:** Poiché il supporto degli osservabili dipende esplicitamente dal parametro incognito (la funzione $u(b - y_{(N)})$ pone il dominio a zero per valori superiori a b), questa distribuzione **non appartiene alla famiglia esponenziale regolare K-PEC**. Di conseguenza, la proprietà di completezza non può essere dedotta per ispezione algebrica della forma canonica, ma deve essere dimostrata esplicitamente tramite la definizione113.

2.2 Dimostrazione della Completezza per $T = \max y_i$

Per applicare il Teorema di Lehmann-Scheffé è necessario verificare che la statistica sufficiente T sia anche **completa**. La condizione di completezza richiede che, data una funzione arbitraria $g(T)$, valga l'implicazione:

$$E_b\left[g(T)\right] = 0 \quad \forall b > 0 \implies g(T) = 0 \quad \text{quasi ovunque}$$

Per calcolare l'aspettazione $E[g(T)]$, dobbiamo prima ricavare la funzione di densità di probabilità $f_T(t)$ della statistica d'ordine massimo.

1. Calcolo della Funzione di Distribuzione Cumulativa (CDF) di T

Per definizione di CDF per la statistica $T = \max(y_1, \dots, y_N)$:

$$F_T(t) \triangleq P(T \le t) = P\left(\max(y_1, \dots, y_N) \le t\right)$$

L'evento per cui il valore massimo tra N variabili risulta minore o uguale a t si verifica se e solo se **ciascuna singola variabile** è minore o uguale a t:

$$P(T \le t) = P(y_1 \le t,\, y_2 \le t,\, \dots,\, y_N \le t) = \prod_{i=1}^{N} P(y_i \le t)$$

essendo i campioni reciprocamente indipendenti.

Per una variabile uniforme $y_i \sim \mathcal{U}(0, b)$, la CDF marginale $F_y(t)$ vale:

$$F_y(t) = \begin{cases} 0 & \text{se } t < 0 \\ \frac{t}{b} & \text{se } 0 \le t < b \\ 1 & \text{se } t \ge b \end{cases}$$

Elevando alla potenza N-esima:

$$F_T(t) = [F_y(t)]^N = \begin{cases} 0 & \text{se } t < 0 \\ \left(\frac{t}{b}\right)^N & \text{se } 0 \le t < b \\ 1 & \text{se } t \ge b \end{cases}$$

2. Calcolo della Densità di Probabilità (PDF) di T

Derivando la CDF rispetto a t nell'intervallo di continuità $0 \le t \le b$:

$$f_T(t) = \frac{dF_T(t)}{dt} = \frac{d}{dt}\left(\frac{t^N}{b^N}\right) = \begin{cases} \frac{Nt^{N-1}}{b^N} & \text{se } 0 \le t \le b \\ 0 & \text{altrove} \end{cases}$$

3. Dimostrazione Analitica tramite il Teorema Fondamentale del Calcolo Integrale

Esprimiamo la condizione di aspettazione nulla $E_b[g(T)] = 0$:

$$E_b\left[g(T)\right] = \int_{-\infty}^{+\infty} g(t) f_T(t)\, dt = \int_0^b g(t) \frac{N t^{N-1}}{b^N}\, dt = 0 \quad \forall b > 0$$

Portiamo i fattori deterministici indipendenti dalla variabile di integrazione t all'esterno dell'integrale:

$$\frac{N}{b^N} \int_0^b g(t) t^{N-1}\, dt = 0 \quad \forall b > 0$$

Poiché per ipotesi $b > 0$ e $N \ge 1$, il pre-fattore $\frac{N}{b^N} \neq 0$. Possiamo quindi moltiplicare ambo i membri per $\frac{b^N}{N}$, ottenendo:

$$\Phi(b) \triangleq \int_0^b g(t) t^{N-1}\, dt = 0 \quad \forall b > 0$$

La funzione integrale $\Phi(b)$ è **identicamente nulla per qualsiasi valore dell'estremo superiore di integrazione** b. Di conseguenza, anche la sua derivata prima rispetto a b deve annullarsi identicamente su tutto il semiasse positivo:

$$\frac{d\Phi(b)}{db} = 0 \quad \forall b > 0$$

Applicando il **Teorema Fondamentale del Calcolo Integrale** (regola di derivazione di un integrale rispetto all'estremo superiore):

$$\frac{d}{db}\left[\int_0^b g(t)t^{N-1}\,dt\right] = g(b)b^{N-1} = 0 \quad \forall b > 0$$

Poiché l'uguaglianza deve valere per qualsiasi $b > 0$, ed essendo $b^{N-1} > 0$ strettamente positivo su tutto il dominio, l'unica soluzione ammissibile per soddisfare l'equazione è:

$$g(b) = 0 \quad \forall b > 0$$

L'unica funzione con aspettazione uniformemente nulla è la funzione identicamente nulla. Resta rigorosamente dimostrato che **la statistica sufficiente $T = \max_i y_i$ è una Statistica Sufficiente Completa (SSC)** per il parametro b.

2.3 Costruzione dello Stimatore $\hat{b}_{MVU}$ e Calcolo delle Prestazioni

Avendo accertato che $T = \max y_i$ è una Statistica Sufficiente Completa, possiamo applicare la **procedura diretta** di Lehmann-Scheffé: è sufficiente trovare una funzione $g(T)$ tale che $E[g(T)] = b$.

1. Calcolo del Momento Primo di T

Calcoliamo il valore atteso della statistica T integrando sulla sua PDF:

$$E[T] = \int_0^b t f_T(t)\,dt = \int_0^b t\left(\frac{Nt^{N-1}}{b^N}\right)dt = \frac{N}{b^N}\int_0^b t^N\,dt$$

Risolvendo l'integrale immediato:

$$E[T] = \frac{N}{b^N}\left[\frac{t^{N+1}}{N+1}\right]_0^b = \frac{N}{b^N}\frac{b^{N+1}}{N+1} = \frac{N}{N+1}b$$

Osservazione sul Bias: La statistica grezza $T = \max y_i$ ha un valore atteso strettamente inferiore al parametro vero: $E[T] = \frac{N}{N+1}b < b$. Ciò è coerente dal punto di vista fisico: il massimo di un campione finito di osservazioni casuali estratte in $[0, b]$ si collocherà quasi certamente all'interno dell'intervallo, risultando sistematicamente polarizzato per difetto.

2. Correzione della Polarizzazione e Formulazione dell'MVU

Per ottenere uno stimatore non polarizzato, applichiamo il fattore di correzione deterministico moltiplicando per il reciproco $\frac{N+1}{N}$:

$$E\left[\frac{N+1}{N}T\right] = \frac{N+1}{N}E[T] = \frac{N+1}{N}\left(\frac{N}{N+1}b\right) = b$$

Per il **Teorema di Lehmann-Scheffé**, essendo funzione della Statistica Sufficiente Completa ed essendo non polarizzato, questo stimatore coincide in modo unico con lo stimatore MVU:

$$\hat{b}_{MVU} = \frac{N+1}{N}T = \frac{N+1}{N}\max_{i=1,\dots,N} y_i$$

3. Calcolo del Momento Secondo e della Varianza

Calcoliamo il momento generico di ordine k della statistica T:

$$E[T^k] = \int_0^b t^k \frac{N t^{N-1}}{b^N}\, dt = \frac{N}{b^N}\left[\frac{t^{N+k}}{N+k}\right]_0^b = \frac{N}{N+k}b^k$$

Ponendo $k=2$ per ricavare il momento secondo:

$$E[T^2] = \frac{N}{N+2}b^2$$

La varianza dello stimatore $\hat{b}_{MVU} = \frac{N+1}{N}T$ si ottiene estraendo la costante al quadrato:

$$\mathrm{Var}[\hat{b}_{MVU}] = \left(\frac{N+1}{N}\right)^2 \mathrm{Var}[T] = \left(\frac{N+1}{N}\right)^2 \left(E[T^2] - (E[T])^2\right)$$

In alternativa, sviluppando direttamente $E[(\hat{b}_{MVU})^2] - (E[\hat{b}_{MVU}])^2$:

$$\mathrm{Var}[\hat{b}_{MVU}] = \left(\frac{N+1}{N}\right)^2 E[T^2] - b^2 = \frac{(N+1)^2}{N^2}\left(\frac{N}{N+2}b^2\right) - b^2$$

Semplificando il fattore N a numeratore e denominatore:

$$\mathrm{Var}[\hat{b}_{MVU}] = b^2\left[\frac{(N+1)^2}{N(N+2)} - 1\right]$$

Sviluppando i polinomi algebrici a numeratore:

$$\frac{(N+1)^2 - N(N+2)}{N(N+2)} = \frac{(N^2+2N+1) - (N^2+2N)}{N(N+2)} = \frac{1}{N(N+2)}$$

Otteniamo l'espressione analitica esatta della varianza dell'MVU:

$$\mathrm{Var}[\hat{b}_{MVU}] = \frac{b^2}{N(N+2)}$$

4. Proprietà di Consistenza e Decadimento Asintotico

Dall'analisi della varianza emergono due proprietà fondamentali3739:

1. **Consistenza in Media Quadratica:**

$$\lim_{N \to \infty} \mathrm{Var}[\hat{b}_{MVU}] = \lim_{N \to \infty} \frac{b^2}{N(N+2)} = 0$$

   Poiché il bias è identicamente nullo e la varianza decade a zero al crescere del numero di osservazioni, lo stimatore $\hat{b}_{MVU}$ è **consistente** e converge in probabilità al valore vero b.
2. **Velocità di Convergenza Super-Lineare ($1/N^2$):** A differenza dei problemi classici regolari (come la stima della media gaussiana o la media campionaria), in cui la varianza decade linearmente come $\mathcal{O}(1/N)$, in questo problema a supporto variabile la varianza dell'MVU decade asintoticamente con legge **quadratica**:

$$\mathrm{Var}[\hat{b}_{MVU}] \approx \frac{b^2}{N^2} = \mathcal{O}\left(\frac{1}{N^2}\right)$$

   Questa elevata velocità di convergenza è una conseguenza diretta della discontinuità del gradino alle frontiere del supporto, che concentra l'informazione statistica sul singolo valore estremo $\max y_i$.

Blocco 3: Invarianza Affine dell'MVU, Confronto delle Prestazioni e Modello Lineare Gaussiano

3.1 Teorema di Invarianza: Stimatore ML vs Stimatore MVU

Una delle questioni concettuali più importanti nella teoria della stima riguarda il comportamento degli stimatori ottimi quando il parametro d'interesse non è direttamente x, bensì una sua trasformazione deterministica $v = g(x)$.

L'Invarianza Universale dello Stimatore ML

Lo **Stimatore di Massima Verosimiglianza (ML)** soddisfa la proprietà di invarianza per **qualsiasi funzione** $g(\cdot)$, sia essa lineare o non lineare, invertibile o non invertibile:

$$\hat{v}_{ML} = g(\hat{x}_{ML})$$

Questo discende direttamente dalla definizione di verosimiglianza indotta: il punto che massimizza la funzione rispetto a x massimizza automaticamente la funzione riparametrizzata rispetto a $g(x)$.

Il Limite dell'Invarianza per lo Stimatore MVU

Al contrario dell'ML, lo **Stimatore MVU non soddisfa l'invarianza per trasformazioni generiche**. Se applichiamo una funzione non lineare $g(\cdot)$ allo stimatore ottimo $\hat{x}_{MVU}$,

l'operatore valore atteso non commuta con la non-linearità:

$$E\left[g(\hat{x}_{MVU})\right] \neq g\left(E[\hat{x}_{MVU}]\right) = g(x)$$

Lo stimatore trasformato $g(\hat{x}_{MVU})$ diviene **polarizzato (biased)**; perdendo la correttezza, cessa immediatamente di appartenere alla classe degli stimatori non polarizzati e non può più essere considerato l'MVU del parametro v.

Teorema di Invarianza Affine dell'MVU

Lo stimatore MVU gode della proprietà di invarianza **esclusivamente rispetto alla classe delle trasformazioni affini** (trasformazioni lineari con eventuale traslazione costante).

Enunciato del Teorema:

Sia $\hat{\mathbf{x}}_{MVU}$ lo stimatore MVU per il parametro vettoriale $\mathbf{x}$, con matrice di covarianza minima $C_{\hat{\mathbf{x}}}$. Sia $\mathbf{v} = g(\mathbf{x})$ una **trasformazione affine**:

$$\mathbf{v} = A\mathbf{x} + \mathbf{b}$$

dove A è una matrice nota di costanti deterministiche e $\mathbf{b}$ è un vettore noto di traslazione.

Allora lo stimatore MVU del parametro trasformato $\mathbf{v}$ è dato esattamente dalla medesima trasformazione affine applicata all'MVU di partenza:

$$\hat{\mathbf{v}}_{MVU} = A\hat{\mathbf{x}}_{MVU} + \mathbf{b}$$

Dimostrazione:

1. **Conservazione della Correttezza (Non Polarizzazione):** Sfruttando la linearità del valore atteso:

   $$E[\hat{\mathbf{v}}_{MVU}] = E[A\hat{\mathbf{x}}_{MVU} + \mathbf{b}] = AE[\hat{\mathbf{x}}_{MVU}] + \mathbf{b} = A\mathbf{x} + \mathbf{b} = \mathbf{v}$$

   Lo stimatore trasformato è rigorosamente non polarizzato.
2. **Conservazione della Minima Varianza:** La matrice di covarianza di una trasformazione affine dipende unicamente dalla componente moltiplicativa A:

   $$C_{\hat{\mathbf{v}}} = \mathrm{Cov}[A\hat{\mathbf{x}}_{MVU} + \mathbf{b}] = A\, C_{\hat{\mathbf{x}}_{MVU}} A^T$$

   Poiché per il Teorema di Lehmann-Scheffé $C_{\hat{\mathbf{x}}_{MVU}}$ è la minima matrice di covarianza possibile (in senso di Loewner) tra tutti gli stimatori non polarizzati di $\mathbf{x}$, anche la combinazione lineare $AC_{\hat{\mathbf{x}}_{MVU}}A^T$ risulterà minima rispetto a qualsiasi altro stimatore concorrente. Di conseguenza, $\hat{\mathbf{v}}_{MVU}$ è l'MVU di $\mathbf{v}$.

3.2 Stima della Media dell'Uniforme $\mu = b/2$ e Confronto con la Media Campionaria

Applichiamo il Teorema di Invarianza Affine al problema affrontato nel Blocco 2: un campione di N osservazioni i.i.d. estratte da una variabile uniforme $y_i \sim \mathcal{U}(0, b)$. Supponiamo che l'obiettivo non sia stimare l'estremo superiore b, bensì la **media teorica** della popolazione:

$$\mu \triangleq E[y_i] = \frac{0+b}{2} = \frac{b}{2}$$

1. Costruzione dell'MVU per Invarianza Affine

La relazione tra il parametro secondario μ e il parametro primario b è una trasformazione scalare affine (con $A = 1/2$ e $b_0 = 0$):

$$\mu = g(b) = \frac{1}{2}b$$

Avendo derivato nel Blocco 2 lo stimatore ottimo $\hat{b}_{MVU} = \frac{N+1}{N}\max_i y_i$, applichiamo direttamente la proprietà di invarianza affine:

$$\hat{\mu}_{MVU} = \frac{1}{2}\hat{b}_{MVU} = \frac{1}{2}\left(\frac{N+1}{N}\max_{i=1,\dots,N} y_i\right) = \frac{N+1}{2N}\max_{i=1,\dots,N} y_i$$

Calcoliamo le prestazioni di $\hat{\mu}_{MVU}$:

- **Valore Atteso:**

$$E[\hat{\mu}_{MVU}] = \frac{1}{2}E[\hat{b}_{MVU}] = \frac{b}{2} = \mu \quad (\text{stimatore non polarizzato})$$

- **Varianza Esatta:** Sfruttando la varianza di $\hat{b}_{MVU}$ ricavata in precedenza, $\mathrm{Var}[\hat{b}_{MVU}] = \frac{b^2}{N(N+2)}$:

$$\mathrm{Var}[\hat{\mu}_{MVU}] = \left(\frac{1}{2}\right)^2 \mathrm{Var}[\hat{b}_{MVU}] = \frac{1}{4}\frac{b^2}{N(N+2)} = \frac{b^2}{4N(N+2)}$$

---

2. Confronto delle Prestazioni con la Media Campionaria ($\bar{y}$)

Uno stimatore naturale e intuitivo per la media di una qualsiasi popolazione è la **media campionaria**:

$$\bar{y} \triangleq \frac{1}{N}\sum_{i=1}^{N} y_i$$

Valutiamo le proprietà statistiche della media campionaria per la distribuzione uniforme:

- **Valore Atteso:**

$$E[\bar{y}] = \frac{1}{N}\sum_{i=1}^{N} E[y_i] = \frac{1}{N}\left(N\frac{b}{2}\right) = \frac{b}{2} = \mu \quad (\text{non polarizzato})$$

- **Varianza:** Ricordando che la varianza teorica di una variabile uniforme su intervallo di ampiezza b vale $\sigma_y^2 = \frac{b^2}{12}$:

$$\mathrm{Var}[\bar{y}] = \mathrm{Var}\left[\frac{1}{N}\sum_{i=1}^{N} y_i\right] = \frac{1}{N^2}\sum_{i=1}^{N}\mathrm{Var}[y_i] = \frac{1}{N^2}\left(N\frac{b^2}{12}\right) = \frac{b^2}{12N}$$

Entrambi gli stimatori sono non polarizzati e hanno media pari a $\mu = b/2$. Confrontiamo ora le due varianze calcolando il loro rapporto:

$$\frac{\mathrm{Var}[\hat{\mu}_{MVU}]}{\mathrm{Var}[\bar{y}]} = \frac{\frac{b^2}{4N(N+2)}}{\frac{b^2}{12N}} = \frac{12N}{4N(N+2)} = \frac{3}{N+2}$$

Analisi Comparativa dei Risultati:

- **Per $N = 1$:** Il rapporto vale $\frac{3}{1+2} = 1$. I due stimatori coincidono identicamente ($\hat{\mu}_{MVU} = \bar{y} = y_1/2$) e forniscono la stessa varianza.
- **Per $N = 2$:** Il rapporto vale $\frac{3}{2+2} = \frac{3}{4} = 0.75$. Lo stimatore MVU presenta già il 25% **di varianza in meno** rispetto alla media campionaria.
- **Per $N \to \infty$:**

$$\lim_{N\to\infty} \frac{\mathrm{Var}[\hat{\mu}_{MVU}]}{\mathrm{Var}[\bar{y}]} = \lim_{N\to\infty} \frac{3}{N+2} = 0$$

  La varianza dell'MVU decade con legge quadratica $\mathcal{O}(1/N^2)$, mentre la varianza della media campionaria decade solo linearmente con $\mathcal{O}(1/N)$.

Conclusione concettuale: Sebbene per variabili gaussiane la media campionaria sia l'MVU, per distribuzioni uniformi essa è uno stimatore **fortemente sub-ottimo**. L'informazione sui confini del supporto uniforme risiede quasi interamente nell'estremo d'ordine $\max y_i$, rendendo $\hat{\mu}_{MVU}$ immensamente più efficiente per campioni ampi.

3.3 Il Modello Lineare Gaussiano e la Coincidenza ML-MVU

Il Teorema di Coincidenza tra ML ed MVU

Il docente formalizza un importante teorema generale che stabilisce un ponte fondamentale tra la teoria di Lehmann-Scheffé e la Stima di Massima Verosimiglianza:

Teorema: Se per un dato problema di stima esiste una Statistica Sufficiente Completa $T_c(\mathbf{y})$, e lo stimatore di Massima Verosimiglianza $\hat{\mathbf{x}}_{ML}$ è **non polarizzato al finito** (ossia $E[\hat{\mathbf{x}}_{ML}] = \mathbf{x}$ per ogni dimensione N), allora lo stimatore ML **coincide rigorosamente con lo stimatore MVU**:

$$\hat{\mathbf{x}}_{ML} = \hat{\mathbf{x}}_{MVU}$$

Dimostrazione:

Per il Teorema di Fattorizzazione di Neyman-Fisher, la log-verosimiglianza si decompone come $\ln f(\mathbf{y}|\mathbf{x}) = \ln g(T_c(\mathbf{y}), \mathbf{x}) + \ln h(\mathbf{y})$. Poiché la massimizzazione rispetto a $\mathbf{x}$ coinvolge unicamente il fattore $g(T_c(\mathbf{y}), \mathbf{x})$, lo stimatore $\hat{\mathbf{x}}_{ML}$ è necessariamente espresso come una funzione deterministica della Statistica Sufficiente Completa: $\hat{\mathbf{x}}_{ML} = g(T_c(\mathbf{y}))$. Essendo per ipotesi $E[\hat{\mathbf{x}}_{ML}] = \mathbf{x}$, per il Teorema di Lehmann-Scheffé esiste una e una sola funzione di T_c non polarizzata, che coincide con l'MVU. Di conseguenza, $\hat{\mathbf{x}}_{ML} \equiv \hat{\mathbf{x}}_{MVU}$.

Applicazione al Modello Lineare Gaussiano

Consideriamo il modello lineare multivariato rispetto alle osservazioni:

$$\mathbf{y} = H\mathbf{x} + \mathbf{w}$$

dove:

- $\mathbf{y} \in \mathbb{R}^N$ è il vettore delle osservazioni.
- $H \in \mathbb{R}^{N \times M}$ è la matrice di osservazione deterministica nota, con $N \geq M$ e a rango pieno per colonna ($\text{Rank}(H) = M$).
- $\mathbf{x} \in \mathbb{R}^M$ è il vettore dei parametri deterministici incogniti da stimare.
- $\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma^2 I_N)$ è rumore bianco gaussiano multivariato con varianza σ^2 nota.

1. Sviluppo della PDF e Identificazione della SSC

La funzione di densità di probabilità condizionata è una gaussiana multivariata:

$$f(\mathbf{y}|\mathbf{x}) = \left(\frac{1}{\sqrt{2\pi\sigma^2}} \right)^N \exp\left(-\frac{1}{2\sigma^2} \|\mathbf{y} - H\mathbf{x}\|^2 \right)$$

Espandiamo la norma quadra a esponente tramite il prodotto scalare:

$$[|\mathbf{y} - H\mathbf{x}|^2 = (\mathbf{y} - H\mathbf{x})^T(\mathbf{y} - H\mathbf{x}) = \mathbf{y}^T\mathbf{y} - 2\mathbf{y}^T H\mathbf{x} + \mathbf{x}^T H^T H\mathbf{x} = |\mathbf{y}|^2 + |H\mathbf{x}|^2 - 2(H^T\mathbf{y})^T\mathbf{x}]$$

Sostituendo all'esponente e separando i fattori moltiplicativi:

$$f(\mathbf{y}|\mathbf{x}) = \underbrace{\left(\frac{1}{\sqrt{2\pi\sigma^2}}\right)^N \exp\left(-\frac{\|H\mathbf{x}\|^2}{2\sigma^2}\right)}_{c(\mathbf{x})} \cdot \underbrace{\exp\left(-\frac{\|\mathbf{y}\|^2}{2\sigma^2}\right)}_{h(\mathbf{y})} \cdot \exp\left(\frac{1}{\sigma^2}(H^T\mathbf{y})^T\mathbf{x}\right)$$

La PDF appartiene alla Famiglia Esponenziale K-PEC regolare. Il termine di accoppiamento parametro-dati mostra che l'interazione con le osservazioni avviene unicamente tramite il vettore:

$$T_c(\mathbf{y}) = H^T\mathbf{y}$$

che costituisce la **Statistica Sufficiente Completa (SSC)** per il vettore $\mathbf{x}$.

2. Costruzione Diretta dell'MVU tramite Lehmann-Scheffé

Calcoliamo il valore atteso della statistica T_c:

$$E[T_c(\mathbf{y})] = E[H^T\mathbf{y}] = H^T E[\mathbf{y}] = H^T(H\mathbf{x}) = (H^T H)\mathbf{x}$$

Poiché la matrice H ha rango pieno per colonna ($N \geq M$), la matrice di Gram $H^T H \in \mathbb{R}^{M\times M}$ è simmetrica, strettamente definita positiva e quindi **invertibile**.

Per costruire una funzione non polarizzata $g(T_c)$, moltiplichiamo a sinistra per l'inversa $(H^T H)^{-1}$:

$$g(T_c) \triangleq (H^T H)^{-1} T_c(\mathbf{y}) = (H^T H)^{-1} H^T\mathbf{y}$$

Verifichiamo la correttezza del valore atteso:

$$E[g(T_c)] = E\left[(H^T H)^{-1} H^T\mathbf{y}\right] = (H^T H)^{-1}(H^T H)\mathbf{x} = \mathbf{x}$$

Essendo $g(T_c)$ una funzione della SSC con valore atteso identicamente pari a $\mathbf{x}$, per il Teorema di Lehmann-Scheffé essa è **l'unico stimatore non polarizzato funzione della SSC** e coincide con l'MVU:

$$\hat{\mathbf{x}}_{MVU} = (H^T H)^{-1} H^T\mathbf{y} = H^+\mathbf{y}$$

dove $H^+ \triangleq (H^T H)^{-1} H^T$ è la **Pseudoinversa di Moore-Penrose**. Lo stimatore MVU coincide esattamente con lo stimatore di Massima Verosimiglianza ($\hat{\mathbf{x}}_{MVU} \equiv \hat{\mathbf{x}}_{ML}$) derivato per minimizzazione dei minimi quadrati.

3. Matrice di Covarianza dello Stimatore Lineare Ottimo

Definiamo la matrice operatore di stima $A \triangleq (H^T H)^{-1} H^T$, tale per cui $\hat{\mathbf{x}}_{MVU} = A\mathbf{y}$. Calcoliamo la matrice di covarianza $C_{\hat{\mathbf{x}}_{MVU}}$ applicando la propagazione delle trasformazioni lineari per vettori aleatori:

$$C_{\hat{\mathbf{x}}_{MVU}} = \mathrm{Cov}[A\mathbf{y}] = A\,\mathrm{Cov}[\mathbf{y}]\,A^T$$

Poiché le osservazioni hanno covarianza sferica $\mathrm{Cov}[\mathbf{y}] = \sigma^2 I_N$:

$$C_{\hat{\mathbf{x}}_{MVU}} = A(\sigma^2 I_N)A^T = \sigma^2 AA^T$$

Sviluppiamo il prodotto matriciale AA^T:

$$AA^T = \left((H^T H)^{-1} H^T\right)\left((H^T H)^{-1} H^T\right)^T = (H^T H)^{-1} H^T H (H^T H)^{-1}$$

Semplificando il prodotto centrale $(H^T H)^{-1}(H^T H) = I_M$:

$$AA^T = (H^T H)^{-1}$$

Otteniamo l'espressione analitica esatta della matrice di covarianza dell'MVU:

$$C_{\hat{\mathbf{x}}_{MVU}} = \sigma^2 (H^T H)^{-1}$$

4. Stima del Segnale Trasformato $\mathbf{v} = H\mathbf{x}$

Se l'obiettivo del sistema è stimare il segnale noiseless trasmesso $\mathbf{v} = H\mathbf{x}$, trattandosi di una trasformazione puramente lineare (e quindi affine con $\mathbf{b} = \mathbf{0}$), applichiamo il principio di invarianza affine dell'MVU:

$$\hat{\mathbf{v}}_{MVU} = H\hat{\mathbf{x}}_{MVU} = H(H^T H)^{-1} H^T \mathbf{y} = P_H \mathbf{y}$$

dove $P_H \triangleq H(H^T H)^{-1} H^T$ è l'**Operatore di Proiezione Ortogonale** che proietta ortogonalmente le misurazioni rumorose $\mathbf{y}$ sul sottospazio generato dalle colonne di H.