ELSD 12

2026-10-30

BLOCCO 1: Stima ai Minimi Quadrati Ordinari (LS) e Principio di Ortogonalità

1.1 Inquadramento Teorico e Filosofia Non-Bayesiana

Nelle teorie tradizionali della stima ottima (come la stima a Minima Varianza Non Distorta — **MVU** — o la stima di Massima Verosimiglianza — **ML**), il calcolo e l'ottimizzazione dello stimatore richiedono la conoscenza precisa delle proprietà statistiche dei dati:

- **MVU**: richiede la conoscenza o la ricerca di una statistica sufficiente e completa (Teorema di Lehmann-Scheffé) oppure il calcolo del limite inferiore di Cramér-Rao (CRLB).
- **ML**: richiede la conoscenza esplicita della funzione di densità di probabilità (PDF) condizionata $f_{\underline{Y}|\underline{X}}(\underline{y}|\underline{x})$ o della massa di probabilità (PMF).

Tuttavia, in moltissimi contesti operativi dell'ingegneria e dell'elaborazione dei segnali, **non si dispone di alcuna caratterizzazione statistica a priori** né del parametro incognito $\underline{x}$, né del disturbo $\underline{n}$, né delle osservazioni $\underline{y}$.

In questi contesti si ricorre allo **stimatore dei Minimi Quadrati (Least Squares — LS)**. Lo stimatore LS è un approccio di tipo **deterministico e geometrico**: prescinde totalmente dalla descrizione probabilistica dei dati e cerca semplicemente il vettore di parametri che rende la risposta modellata del sistema il più vicina possibile alle misurazioni reali.

1.2 Definizione Formale dello Stimatore LS

Consideriamo il modello generale di misura rappresentato dallo schema a blocco:

$$\underline{x} \longrightarrow \Big[\text{SISTEMA / OSSERVATORE}\Big] \longrightarrow \underline{v}(\underline{x}) \longrightarrow \underline{y}$$

dove:

- $\underline{x} \in \mathbb{R}^M$ è il vettore dei parametri incogniti da stimare8.
- $\underline{v}(\underline{x}) \in \mathbb{R}^N$ è la trasformazione nota (lineare o non lineare) che descrive la risposta ideale del sistema associata allo stato $\underline{x}$.
- $\underline{y} \in \mathbb{R}^N$ è il vettore delle osservazioni o misurazioni reali ($N \geq M$).

Criterio di Ottimizzazione LS

Lo stimatore dei Minimi Quadrati individua il valore $\underline{\hat{x}}_{LS}$ che minimizza la distanza Euclidea al quadrato (L_2^2) tra il vettore misurato $\underline{y}$ e la risposta modellata del sistema $\underline{v}(\underline{x})$:

$$\underline{\hat{x}}_{LS} \triangleq \arg\min_{\underline{x}} \|\underline{y} - \underline{v}(\underline{x})\|^2 = \arg\min_{\underline{x}} (\underline{y} - \underline{v}(\underline{x}))^T (\underline{y} - \underline{v}(\underline{x}))$$

Proprietà di Invarianza dello Stimatore LS

Se l'obiettivo primario non è stimare lo stato interno $\underline{x}$, bensì la risposta trasformata del sistema $\underline{v} = \underline{v}(\underline{x})$, lo stimatore LS gode della **proprietà di invarianza** (in modo del tutto analogo allo stimatore ML):

$$\underline{\hat{v}}_{LS} = \underline{v}(\underline{\hat{x}}_{LS})$$

Motivazione analitica: Poiché $\underline{\hat{x}}_{LS}$ è per definizione l'argomento che minimizza la norma $\|\underline{y} - \underline{v}(\underline{x})\|^2$, la stima della risposta trasformata $\underline{\hat{v}}_{LS}$ coincide direttamente con la valutazione della funzione $\underline{v}(\cdot)$ in corrispondenza del punto di minimo $\underline{\hat{x}}_{LS}$.

1.3 Derivazione Analitica per il Modello Lineare

Ipotizziamo che la relazione tra lo stato incognito $\underline{x}$ e la risposta ideale del sistema sia strettamente **lineare**:

$$\underline{v}(\underline{x}) = \underline{\underline{H}}\,\underline{x}$$

Il vettore delle misurazioni reali $\underline{y}$ si esprime nella forma additiva:

$$\underline{y} = \underline{\underline{H}}\,\underline{x} + \underline{n}$$

dove:

- $\underline{\underline{H}} \in \mathbb{R}^{N \times M}$ è la **matrice di osservazione** (o matrice di modello) nota, supposta a rango colonna pieno: $\mathrm{rank}(\underline{\underline{H}}) = M$ (con $N \geq M$).
- $\underline{n} \in \mathbb{R}^N$ è il vettore del rumore/disturbo additivo di misura.

Sviluppo della Funzione di Costo Quadratica

Definiamo la funzione obiettivo $J(\underline{x})$ da minimizzare:

$$J(\underline{x}) \triangleq \|\underline{y} - \underline{\underline{H}}\,\underline{x}\|^2 = (\underline{y} - \underline{\underline{H}}\,\underline{x})^T (\underline{y} - \underline{\underline{H}}\,\underline{x})$$

Sviluppiamo il prodotto trasposto applicando la proprietà distributiva:

$$J(\underline{x}) = \underline{y}^T \underline{y} - \underline{y}^T \underline{\underline{H}}\,\underline{x} - \underline{x}^T \underline{\underline{H}}^T \underline{y} + \underline{x}^T \underline{\underline{H}}^T \underline{\underline{H}}\,\underline{x}$$

Poiché il termine $\underline{y}^T\underline{\underline{H}}\underline{x}$ è uno scalare, esso coincide con la propria trasposta: $(\underline{y}^T\underline{\underline{H}}\underline{x})^T = \underline{x}^T\underline{\underline{H}}^T\underline{y}$. Di conseguenza, i due termini misti si sommano:

$$J(\underline{x}) = \underline{y}^T\underline{y} - 2\underline{x}^T\underline{\underline{H}}^T\underline{y} + \underline{x}^T\underline{\underline{H}}^T\underline{\underline{H}}\underline{x}$$

Minimizzazione tramite Gradiente Vettoriale

La funzione $J(\underline{x})$ è una forma quadratica strettamente convessa rispetto a $\underline{x}$ (essendo $\underline{\underline{H}}^T\underline{\underline{H}}$ definita positiva)14. Il punto di minimo globale si determina calcolando il gradiente vettoriale $\nabla_{\underline{x}}J(\underline{x})$ ed eguagliandolo al vettore nullo $\underline{0}$:

$$\nabla_{\underline{x}}J(\underline{x}) = \nabla_{\underline{x}}\left(\underline{y}^T\underline{y} - 2\underline{x}^T\underline{\underline{H}}^T\underline{y} + \underline{x}^T\underline{\underline{H}}^T\underline{\underline{H}}\underline{x}\right) = \underline{0}$$

Applicando le regole di derivazione matriciale:

1. $\nabla_{\underline{x}}(\underline{y}^T\underline{y}) = \underline{0}$ (termine indipendente da $\underline{x}$).
2. $\nabla_{\underline{x}}(-2\underline{x}^T\underline{\underline{H}}^T\underline{y}) = -2\underline{\underline{H}}^T\underline{y}$.
3. $\nabla_{\underline{x}}(\underline{x}^T\underline{\underline{H}}^T\underline{\underline{H}}\underline{x}) = 2\underline{\underline{H}}^T\underline{\underline{H}}\underline{x}$.

Sostituendo i gradienti parziali si ottengono le **Equazioni Normali**713:

$$-2\underline{\underline{H}}^T\underline{y} + 2\underline{\underline{H}}^T\underline{\underline{H}}\underline{\hat{x}}_{LS} = \underline{0} \implies \underline{\underline{H}}^T\underline{\underline{H}}\underline{\hat{x}}_{LS} = \underline{\underline{H}}^T\underline{y}$$

Essendo $\underline{\underline{H}}$ a rango pieno colonna, la matrice quadrata $\underline{\underline{H}}^T\underline{\underline{H}} \in \mathbb{R}^{M\times M}$ è invertibile. Moltiplicando a sinistra per la sua inversa $(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}$, ricaviamo la **soluzione in forma chiusa dello stimatore LS**713:

$$\underline{\hat{x}}_{LS} = (\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underline{\underline{H}}^T\underline{y}$$

Per la proprietà di invarianza, la stima del vettore del segnale $\underline{\hat{v}}_{LS}$ è data da:

$$\underline{\hat{v}}_{LS} = \underline{\underline{H}}\underline{\hat{x}}_{LS} = \underline{\underline{H}}(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underline{\underline{H}}^T\underline{y}$$

1.4 Interpretazione Geometrica e Principio di Ortogonalità

Definiamo il **vettore di errore/residuo di stima** $\underline{e}$ come la differenza tra le osservazioni reali e il segnale stimato:

$$\underline{e} \triangleq \underline{y} - \underline{\hat{v}}_{LS} = \underline{y} - \underline{\underline{H}}\underline{\hat{x}}_{LS}$$

Riscriviamo la condizione di azzeramento del gradiente vista nelle equazioni normali719:

$$\underline{\underline{H}}^T(\underline{y} - \underline{\underline{H}}\underline{\hat{x}}_{LS}) = \underline{0} \iff \underline{\underline{H}}^T\underline{e} = \underline{0}$$

Poiché la matrice $\underline{\underline{H}}^T$ ha come righe le colonne $\underline{h}_1, \underline{h}_2, \ldots, \underline{h}_M$ della matrice $\underline{\underline{H}}$, la condizione $\underline{\underline{H}}^T\underline{e} = \underline{0}$ equivale a imporre che il prodotto scalare tra ciascuna colonna di $\underline{\underline{H}}$ e il vettore residuo $\underline{e}$ sia identicamente nullo:

$$\underline{h}_j^T\underline{e} = 0, \quad \forall j = 1, 2, \ldots, M$$

Teorema (Principio di Ortogonalità)

Lo stimatore dei minimi quadrati $\underline{\hat{x}}_{LS}$ minimizza la norma al quadrato dell'errore residuo se e solo se il vettore di errore $\underline{e} = \underline{y} - \underline{\underline{H}}\underline{\hat{x}}_{LS}$ è **ortogonale allo spazio vettoriale generato dalle colonne di** $\underline{\underline{H}}$ ($\mathrm{span}(\underline{\underline{H}})$):

$$\underline{e} \perp \mathrm{span}(\underline{\underline{H}}) \iff \underline{e} \in \mathrm{span}(\underline{\underline{H}})^{\perp}$$

Significato Geometrico:

- Il vettore delle osservazioni $\underline{y} \in \mathbb{R}^N$ non appartiene in generale allo spazio sotteso dalle colonne di $\underline{\underline{H}}$ a causa della presenza del disturbo $\underline{n}$.
- Il segnale stimato $\underline{\hat{v}}_{LS} = \underline{\underline{H}}\underline{\hat{x}}_{LS}$ rappresenta la **proiezione ortogonale** del vettore osservato $\underline{y}$ sul sottospazio $\mathrm{span}(\underline{\underline{H}})$.
- Tale proiezione individua il punto appartenente a $\mathrm{span}(\underline{\underline{H}})$ che presenta la **distanza minima** Euclidea dal punto misurato $\underline{y}$.

La Matrice di Proiezione Ortogonale

Possiamo esplicitare la relazione tra il vettore osservato $\underline{y}$ e la stima del segnale $\underline{\hat{v}}_{LS}$ definendo la **matrice di proiezione ortogonale** $\underline{\underline{P}}_{\underline{\underline{H}}} \in \mathbb{R}^{N \times N}$:

$$\underline{\hat{v}}_{LS} = \underline{\underline{P}}_{\underline{\underline{H}}}\underline{y}, \qquad \text{dove } \underline{\underline{P}}_{\underline{\underline{H}}} \triangleq \underline{\underline{H}}(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underline{\underline{H}}^T$$

Proprietà Fondamentali della Matrice di Proiezione $\underline{\underline{P}}_{\underline{\underline{H}}}$:

1. **Simmetria**:

$$\underline{\underline{P}}_{\underline{\underline{H}}}^T = \left(\underline{\underline{H}}(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underline{\underline{H}}^T\right)^T = \underline{\underline{H}}\left((\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\right)^T\underline{\underline{H}}^T = \underline{\underline{H}}(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underline{\underline{H}}^T = \underline{\underline{P}}_{\underline{\underline{H}}}$$

2. **Idempotenza** (proiettare due volte un vettore dà lo stesso risultato della prima proiezione):

$$\underline{\underline{P}}_{\underline{\underline{H}}}^2 = \left(\underline{\underline{H}}(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underline{\underline{H}}^T\right)\left(\underline{\underline{H}}(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underline{\underline{H}}^T\right) = \underline{\underline{H}}(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}\underbrace{(\underline{\underline{H}}^T\underline{\underline{H}})(\underline{\underline{H}}^T\underline{\underline{H}})^{-1}}_{\underline{\underline{I}}_M}\underline{\underline{H}}^T = \underline{\underline{P}}_{\underline{\underline{H}}}$$

3. **Matrice di Proiezione sul Complemento Ortogonale**: Il vettore di errore residuo $\underline{e}$ si ottiene applicando la matrice complementare $\underline{\underline{P}}_{\underline{\underline{H}}}^{\perp} \triangleq \underline{\underline{I}}_N - \underline{\underline{P}}_{\underline{\underline{H}}}$:

$$\underline{e} = \underline{y} - \underline{\hat{v}}_{LS} = (\underline{\underline{I}}_N - \underline{\underline{P}}_{\underline{\underline{H}}})\underline{y}$$

4. **Decomposizione Ortogonale dello Spazio**: Qualsiasi vettore di osservazione $\underline{y}$ viene decomposto in modo unico nella somma di due componenti mutuamente ortogonali:

$$\underline{y} = \underbrace{\underline{\underline{P}}_{\underline{\underline{H}}}\underline{y}}_{\in \mathrm{span}(\underline{\underline{H}})} + \underbrace{(\underline{\underline{I}}_N - \underline{\underline{P}}_{\underline{\underline{H}}})\underline{y}}_{\in \mathrm{span}(\underline{\underline{H}})^{\perp}}$$

BLOCCO 2: Minimi Quadrati Pesati (WLS), Equivalenza ML e Filtro di Sbiancamento

2.1 Motivazione e Definizione Formale dei Minimi Quadrati Pesati (WLS)

Nel criterio dei Minimi Quadrati Ordinari (LS)1, tutte le componenti del vettore di errore residuo $\underline{y} - \underline{v}(\underline{x})$ contribuiscono con lo stesso peso unitario alla minimizzazione della somma dei quadrati.

Nelle applicazioni ingegneristiche reali, tuttavia, le diverse componenti del vettore delle osservazioni $\underline{y}$ presentano spesso livelli di affidabilità o intensità di disturbo fortemente eterogenei:

- Alcuni sensori o canali di misura possono essere soggetti a interferenze locali particolarmente elevate.
- Alcune misurazioni possono essere state effettuate con strumenti caratterizzati da precisione inferiore.

Per incorporare questa informazione a priori sull'affidabilità relativa delle misurazioni **senza dover conoscere la PDF complessa del rumore**, si introduce lo **stimatore dei Minimi Quadrati Pesati (Weighted Least Squares — WLS)**.

Criterio di Ottimizzazione WLS

Lo stimatore WLS determina il valore $\underline{\hat{x}}_{WLS}$ che minimizza la forma quadratica pesata della distanza tra l'osservazione $\underline{y}$ e il modello $\underline{v}(\underline{x})$:

$$\underline{\hat{x}}_{WLS} \triangleq \arg\min_{\underline{x}} (\underline{y} - \underline{v}(\underline{x}))^T \underline{\underline{W}} (\underline{y} - \underline{v}(\underline{x}))$$

dove $\underline{\underline{W}} \in \mathbb{R}^{N \times N}$ è la **matrice dei pesi (weighting matrix)**, assunta simmetrica e definita positiva ($\underline{\underline{W}} = \underline{\underline{W}}^T > \underline{\underline{0}}$).

Caso Particolare: Matrice dei Pesi Diagonale

Se la matrice di peso è diagonale $\underline{\underline{W}} = \text{diag}(w_0, w_1, \ldots, w_{N-1})$ con elementi positivi $w_i > 0$, la forma quadratica si riduce alla somma pesata dei quadrati dei singoli errori residui:

$$J_{WLS}(\underline{x}) = \sum_{i=0}^{N-1} w_i \big(y_i - v_i(\underline{x})\big)^2$$

- **Interpretazione del peso w_i**:
  - Se l'i-esima osservazione y_i è caratterizzata da elevata incertezza o forte rumore, si assegna un peso **piccolo** ($w_i \ll 1$), riducendo l'impatto di y_i sulla stima finale.
  - Se l'i-esima osservazione y_i è molto precisa e affidabile, si assegna un peso **grande** ($w_i \gg 1$), facendo sì che il modello aderisca strettamente a quel dato punto di misura.
- **Riduzione a LS Ordinario**: Se $\underline{\underline{W}} = \underline{\underline{I}}$ (matrice identità), lo stimatore WLS coincide esattamente con lo stimatore LS classico: $\underline{\hat{x}}_{WLS} = \underline{\hat{x}}_{LS}$.

2.2 Derivazione Analitica per il Modello Lineare

Ipotizziamo il modello di osservazione lineare additivo211:

$$\underline{y} = \underline{\underline{H}}\underline{x} + \underline{n}$$

con $\underline{\underline{H}} \in \mathbb{R}^{N \times M}$ a rango colonna pieno ($\text{rank}(\underline{\underline{H}}) = M$, con $N \geq M$)18.

Sviluppo della Funzione di Costo Pesata $J_{WLS}(\underline{x})$

Esplicitiamo la forma quadratica pesata:

$$J_{WLS}(\underline{x}) \triangleq (\underline{y} - \underline{\underline{H}}\underline{x})^T \underline{\underline{W}} (\underline{y} - \underline{\underline{H}}\underline{x})$$

Espandiamo il prodotto sfruttando la simmetria di $\underline{\underline{W}}$ ($\underline{\underline{W}}^T = \underline{\underline{W}}$):

$$J_{WLS}(\underline{x}) = \underline{y}^T \underline{\underline{W}}\underline{y} - \underline{y}^T \underline{\underline{W}}\underline{\underline{H}}\underline{x} - \underline{x}^T \underline{\underline{H}}^T \underline{\underline{W}}\underline{y} + \underline{x}^T \underline{\underline{H}}^T \underline{\underline{W}}\underline{\underline{H}}\underline{x}$$

Poiché $\underline{y}^T \underline{\underline{W}}\underline{\underline{H}}\underline{x}$ è uno scalare, esso equivale alla sua trasposta $(\underline{y}^T \underline{\underline{W}}\underline{\underline{H}}\underline{x})^T = \underline{x}^T \underline{\underline{H}}^T \underline{\underline{W}}\underline{y}$. Di conseguenza:

$$J_{WLS}(\underline{x}) = \underline{y}^T \underline{\underline{W}} \underline{y} - 2\underline{x}^T \underline{\underline{H}}^T \underline{\underline{W}} \underline{y} + \underline{x}^T \underline{\underline{H}}^T \underline{\underline{W}} \underline{\underline{H}} \underline{x}$$

Minimizzazione tramite Gradiente Vettoriale

Calcoliamo il gradiente vettoriale $\nabla_{\underline{x}} J_{WLS}(\underline{x})$ ed eguagliamolo al vettore nullo $\underline{0}$:

$$\nabla_{\underline{x}} J_{WLS}(\underline{x}) = -2\underline{\underline{H}}^T \underline{\underline{W}} \underline{y} + 2\underline{\underline{H}}^T \underline{\underline{W}} \underline{\underline{H}} \underline{x} = \underline{0}$$

Semplificando il fattore 2 otteniamo le **Equazioni Normali Pesate**:

$$\underline{\underline{H}}^T \underline{\underline{W}} \underline{\underline{H}} \hat{\underline{x}}_{WLS} = \underline{\underline{H}}^T \underline{\underline{W}} \underline{y}$$

Poiché $\underline{\underline{H}}$ è a rango colonna pieno e $\underline{\underline{W}}$ è definita positiva, la matrice quadrata $\underline{\underline{H}}^T \underline{\underline{W}} \underline{\underline{H}} \in \mathbb{R}^{M \times M}$ è strettamente invertibile. Pre-moltiplicando per la sua inversa otteniamo la **soluzione in forma chiusa dello stimatore WLS**

$$\hat{\underline{x}}_{WLS} = (\underline{\underline{H}}^T \underline{\underline{W}} \underline{\underline{H}})^{-1} \underline{\underline{H}}^T \underline{\underline{W}} \underline{y}$$

2.3 Esempio Ingegneristico Applicativo (Sistema MIMO / Antenna Array Distribuito)

Un'applicazione diretta dello stimatore WLS si presenta nei **sistemi di comunicazione wireless MIMO (Multiple-Input Multiple-Output)** o negli **array di antenne distribuite geograficamente**.

Modellizzazione Fisica

- **Trasmittitore**: M antenne trasmettono contemporaneamente il vettore di simboli/stato $\underline{x} \in \mathbb{R}^M$.
- **Ricevitore**: N antenne in ricezione catturano il segnale vettoriale $\underline{y} \in \mathbb{R}^N$ ($N \geq M$).
- **Canale**: La matrice $\underline{\underline{H}} \in \mathbb{R}^{N \times M}$ modellizza i coefficienti di attenuazione e sfasamento del canale radio; l'elemento h_{ij} rappresenta il guadagno di canale tra la j-esima antenna in trasmissione e la i-esima antenna in ricezione.

Il Problema del Disturbo Eterogeneo

Se un'antenna ricevente i si trova posizionata vicino a una sorgente di interferenza elettromagnetica locale (es. macchinario o altro trasmettitore), la misurazione y_i sarà corrotta da un rumore additivo n_i di intensità molto superiore rispetto alle altre antenne:

$$y_i = (\underline{\underline{H}} \underline{x})_i + n_i, \qquad \mathbb{E}[n_i^2] = \sigma_i^2 \gg \sigma_j^2 \quad (j \neq i)$$

- **Approccio Ingegneristico**: Scartare completamente l'antenna i eliminerebbe anche la quota di segnale utile $(\underline{\underline{H}}\underline{x})_i$ presente su di essa.
- **Soluzione WLS**: Anziché azzerare il canale, lo stimatore WLS pesa ogni misurazione mediante $w_i = \frac{1}{\sigma_i^2}$. In questo modo, l'antenna fortemente corrotta contribuisce marginalmente alla stima, preservando l'informazione utile senza degradare la stima globale dello stato $\underline{x}$.

2.4 Equivalenza Formale tra WLS e Massima Verosimiglianza (ML) sotto Rumore Gaussiano

L'impiego della matrice di peso $\underline{\underline{W}}$ non è soltanto un'euristica geometrica, ma trova un rigoroso fondamento probabilistico quando il disturbo additivo è **gaussiano colorato / correlato**.

Modellizzazione del Rumore Gaussiano Colorato

Supponiamo che il rumore $\underline{n}$ sia distribuito secondo una gaussiana multivariata a media nulla e **matrice di covarianza nota** $\underline{\underline{C}}$:

$$\underline{n} \sim \mathcal{N}(\underline{0}, \underline{\underline{C}})$$

dove $\underline{\underline{C}} \in \mathbb{R}^{N \times N}$ è la matrice di covarianza definita positiva (eventualmente non diagonale, a indicare correlazione tra i campioni di rumore).

Il vettore osservato $\underline{y} = \underline{\underline{H}}\underline{x} + \underline{n}$ è anch'esso distribuito gaussianamente con media $\mathbb{E}[\underline{y}] = \underline{\underline{H}}\underline{x}$ e covarianza $\mathrm{Cov}(\underline{y}) = \underline{\underline{C}}$. La funzione di verosimiglianza è:

$$f_{\underline{Y}|\underline{X}}(\underline{y}|\underline{x}) = \frac{1}{(2\pi)^{N/2}\det(\underline{\underline{C}})^{1/2}} \exp\left\{-\frac{1}{2}(\underline{y} - \underline{\underline{H}}\underline{x})^T \underline{\underline{C}}^{-1}(\underline{y} - \underline{\underline{H}}\underline{x})\right\}$$

Derivazione dello Stimatore ML

Lo stimatore di Massima Verosimiglianza $\underline{\hat{x}}_{ML}$ massimizza $f_{\underline{Y}|\underline{X}}(\underline{y}|\underline{x})$ rispetto a $\underline{x}$. Poiché il pre-fattore non dipende da $\underline{x}$, massimizzare la verosimiglianza equivale a **minimizzare l'esponenziale negativo**:

$$\underline{\hat{x}}_{ML} = \arg\max_{\underline{x}} f_{\underline{Y}|\underline{X}}(\underline{y}|\underline{x}) = \arg\min_{\underline{x}} (\underline{y} - \underline{\underline{H}}\underline{x})^T \underline{\underline{C}}^{-1}(\underline{y} - \underline{\underline{H}}\underline{x})$$

Teorema: Equivalenza tra WLS e ML

Se il modello di osservazione è lineare e il rumore è gaussiano multivariata con covarianza $\underline{\underline{C}}$, lo stimatore di Massima Verosimiglianza $\underline{\hat{x}}_{ML}$ coincide **esattamente** con lo stimatore WLS ponendo la matrice di peso pari all'inversa della matrice di covarianza del rumore:

$$\underline{\underline{W}} = \underline{\underline{C}}^{-1} \implies \underline{\hat{x}}_{ML} = \underline{\hat{x}}_{WLS} = (\underline{\underline{H}}^T \underline{\underline{C}}^{-1} \underline{\underline{H}})^{-1} \underline{\underline{H}}^T \underline{\underline{C}}^{-1} \underline{y}$$

Casistica Particolare:

1. **Rumore Gaussiano Bianco incorrelato e omoschedastico** ($\underline{\underline{C}} = \sigma^2 \underline{\underline{I}}$): La matrice dei pesi diventa $\underline{\underline{W}} = \frac{1}{\sigma^2} \underline{\underline{I}}$. Lo scalare $\frac{1}{\sigma^2}$ si elide nell'espressione dello stimatore, riducendo lo stimatore ML/WLS allo **stimatore LS ordinario**:

$$\underline{\hat{x}}_{ML} = (\underline{\underline{H}}^T \underline{\underline{H}})^{-1} \underline{\underline{H}}^T \underline{y}$$

2. **Rumore Gaussiano Incorrelato ma Eteroschedastico** ($\underline{\underline{C}} = \text{diag}(\sigma_0^2, \sigma_1^2, \dots, \sigma_{N-1}^2)$): La matrice dei pesi è diagonale $\underline{\underline{W}} = \text{diag}\left(\frac{1}{\sigma_0^2}, \frac{1}{\sigma_1^2}, \dots, \frac{1}{\sigma_{N-1}^2}\right)$, confermando rigorosamente che il peso di ciascuna osservazione deve essere il **reciproco della varianza del disturbo** presente su di essa.

2.5 Dimostrazione mediante Tecnica di Sbiancamento (Whitening Filter)

Sia il rumore $\underline{n}$ colorato/correlato con matrice di covarianza piena $\underline{\underline{C}}$. Mostriamo come si possa ricavare la soluzione $\underline{\hat{x}}_{ML}$ trasformando il problema in un modello a rumore bianco tramite un **filtro di sbiancamento (whitening transformation)**.

Decomposizione Spettrale di $\underline{\underline{C}}$

La matrice di covarianza $\underline{\underline{C}}$ è simmetrica e definita positiva. Può essere diagonalizzata tramite la decomposizione in autovalori ed autovettori:

$$\underline{\underline{C}} = \underline{\underline{U}} \, \underline{\underline{\Lambda}} \, \underline{\underline{U}}^H$$

dove:

- $\underline{\underline{U}} \in \mathbb{R}^{N \times N}$ è la matrice ortogonale i cui vettori colonna sono gli autovettori di $\underline{\underline{C}}$ ($\underline{\underline{U}}^H \underline{\underline{U}} = \underline{\underline{I}}$).
- $\underline{\underline{\Lambda}} = \text{diag}(\lambda_0, \lambda_1, \dots, \lambda_{N-1})$ è la matrice diagonale degli autovalori strettamente positivi $\lambda_i > 0$.

L'inversa della covarianza si esprime come:

$$\underline{\underline{C}}^{-1} = \underline{\underline{U}} \, \underline{\underline{\Lambda}}^{-1} \, \underline{\underline{U}}^H$$

Costruzione della Matrice di Sbiancamento $\underline{\underline{T}}_w$

Definiamo l'operatore lineare di sbiancamento $\underline{\underline{T}}_w \in \mathbb{R}^{N \times N}$ come:

$$\underline{\underline{T}}_w \triangleq \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H$$

Pre-moltiplichiamo l'intero modello di osservazione $\underline{y} = \underline{\underline{H}}\underline{x} + \underline{n}$ per $\underline{\underline{T}}_w$:

$$\underline{y}_w \triangleq \underline{\underline{T}}_w \underline{y} = \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H (\underline{\underline{H}}\underline{x} + \underline{n}) = \underline{\underline{H}}_w \underline{x} + \underline{n}_w$$

dove si sono definiti:

- La **matrice di osservazione trasformata**: $\underline{\underline{H}}_w \triangleq \underline{\underline{T}}_w \underline{\underline{H}} = \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{\underline{H}}$.
- Il **vettore del rumore trasformato**: $\underline{n}_w \triangleq \underline{\underline{T}}_w \underline{n} = \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{n}$.

Verifica del Rumore Sbiancato $\underline{n}_w$

Calcoliamo la matrice di covarianza del rumore trasformato $\underline{n}_w$:

$$\mathbb{E}[\underline{n}_w \underline{n}_w^T] = \mathbb{E}\left[(\underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{n})(\underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{n})^T \right] = \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \mathbb{E}[\underline{n}\underline{n}^T] \underline{\underline{U}} \underline{\underline{\Lambda}}^{-1/2}$$

Sostituendo $\mathbb{E}[\underline{n}\underline{n}^T] = \underline{\underline{C}} = \underline{\underline{U}} \underline{\underline{\Lambda}} \underline{\underline{U}}^H$:

$$\mathbb{E}[\underline{n}_w \underline{n}_w^T] = \underline{\underline{\Lambda}}^{-1/2} \underbrace{\underline{\underline{U}}^H \underline{\underline{U}}}_{\underline{\underline{I}}} \underline{\underline{\Lambda}} \underbrace{\underline{\underline{U}}^H \underline{\underline{U}}}_{\underline{\underline{I}}} \underline{\underline{\Lambda}}^{-1/2} = \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{\Lambda}} \underline{\underline{\Lambda}}^{-1/2} = \underline{\underline{I}}$$

Il nuovo rumore $\underline{n}_w$ è un **rumore gaussiano bianco** con matrice di covarianza identica $\underline{\underline{I}}$.

Stima sul Modello Sbiancato e Teorema dell'Invertibilità

Poiché la matrice di sbiancamento $\underline{\underline{T}}_w$ è strettamente invertibile, per il **Teorema dell'Invertibilità** la nuova statistica $\underline{y}_w$ conserva integralmente l'informazione contenuta nel vettore originale $\underline{y}$ (è una statistica ugualmente informativa).

Possiamo dunque applicare lo stimatore LS ordinario sul modello equivalente $\underline{y}_w = \underline{\underline{H}}_w \underline{x} + \underline{n}_w$:

$$\underline{\hat{x}}_{ML} = (\underline{\underline{H}}_w^T \underline{\underline{H}}_w)^{-1} \underline{\underline{H}}_w^T \underline{y}_w$$

Sostituiamo le espressioni esplicite di $\underline{\underline{H}}_w$ e $\underline{y}_w$:

1. **Termine di inversione**:

$$\underline{\underline{H}}_w^T \underline{\underline{H}}_w = (\underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{\underline{H}})^T (\underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{\underline{H}}) = \underline{\underline{H}}^T \underline{\underline{U}} \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{\underline{H}} = \underline{\underline{H}}^T \underline{\underline{C}}^{-1} \underline{\underline{H}}$$

2. **Termine noto**:

$$\underline{\underline{H}}_w^T \underline{y}_w = (\underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{\underline{H}})^T (\underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{y}) = \underline{\underline{H}}^T \underline{\underline{U}} \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{\Lambda}}^{-1/2} \underline{\underline{U}}^H \underline{y} = \underline{\underline{H}}^T \underline{\underline{C}}^{-1} \underline{y}$$

Ricomponendo l'espressione otteniamo:

$$\underline{\hat{x}}_{ML} = (\underline{\underline{H}}^T \underline{\underline{C}}^{-1} \underline{\underline{H}})^{-1} \underline{\underline{H}}^T \underline{\underline{C}}^{-1} \underline{y}$$

Resta così formalmente dimostrato che lo sbiancamento del rumore conduce alla medesima struttura dello stimatore WLS con matrice dei pesi $\underline{\underline{W}} = \underline{\underline{C}}^{-1}$.

BLOCCO 3: Stima Sequenziale / Ricorsiva dei Minimi Quadrati (RLS)

3.1 Motivazione Computazionale e Limiti della Stima Batch (In Blocco)

Nelle applicazioni in tempo reale (come il tracciamento di bersagli radar, i filtri adattativi o la stima di canale nei sistemi di comunicazione), i dati giungono in sequenza temporale un campione alla volta:

$$y(1), y(2), \ldots, y(N), y(N+1), \ldots$$

Nella formulazione classica dei Minimi Quadrati Ordinari o Pesati (stima *batch* o *in blocco*), il calcolo della stima del parametro $\underline{x} \in \mathbb{R}^M$ basato sulle prime N osservazioni richiede la risoluzione dell'espressione globale13:

$$\underline{\hat{x}}_{WLS}(N) = (\underline{\underline{H}}_N^T \underline{\underline{W}}_N \underline{\underline{H}}_N)^{-1} \underline{\underline{H}}_N^T \underline{\underline{W}}_N \underline{y}_N$$

Criticità della Stima Batch:

1. **Complessità Computazionale Elevata**: Quando giunge una nuova misurazione al passo $N+1$, ricalcolare da capo la stima richiede l'inversione di una matrice di dimensione $M \times M$ ($\underline{\underline{H}}_{N+1}^T \underline{\underline{W}}_{N+1} \underline{\underline{H}}_{N+1}$), il cui costo computazionale cresce come $\mathcal{O}(M^3)$ ad ogni singolo istante di tempo.
2. **Occupazione di Memoria**: L'approccio batch richiede di memorizzare e rielaborare l'intero vettore delle osservazioni storiche $\underline{y}_N$, la cui dimensione N cresce indefinitamente nel tempo ($N \to \infty$).

Per superare queste limitazioni si introduce la **stima ricorsiva / sequenziale dei minimi quadrati (Sequential / Recursive Least Squares — RLS)**, la quale permette di aggiornare

la stima precedente al passo N incorporando unicamente la nuova informazione apportata dal dato al passo $N+1$.

3.2 Struttura Algoritmica dell'Aggiornamento Ricorsivo

L'obiettivo fondamentale dell'algoritmo RLS è esprimere il nuovo vettore di stima $\underline{\hat{x}}(N+1) \in \mathbb{R}^M$ come combinazione lineare della stima precedente $\underline{\hat{x}}(N)$ più un **termine di correzione**:

$$\underline{\hat{x}}(N+1) = \underline{\hat{x}}(N) + \underline{k}(N+1) \cdot e(N+1)$$

dove:

- $\underline{\hat{x}}(N) \in \mathbb{R}^M$ è lo stato stimato sulla base delle prime N misurazioni.
- $e(N+1) \in \mathbb{R}$ è **l'errore di innovazione (o residuo di predizione a priori)**, definito come la differenza tra la nuova misurazione reale $y(N+1)$ e la predizione del segnale effettuata dallo stato stimato al passo precedente:

  $$e(N+1) \triangleq y(N+1) - \underline{h}^T(N+1)\underline{\hat{x}}(N)$$

  con $\underline{h}^T(N+1) \in \mathbb{R}^{1\times M}$ rappresentante la nuova riga della matrice di osservazione associata all'istante $N+1$.
- $\underline{k}(N+1) \in \mathbb{R}^M$ è il **vettore di guadagno di aggiornamento (gain vector)**, che stabilisce il peso da attribuire all'errore di innovazione per correggere lo stato.

3.3 Derivazione Analitica tramite il Lemma di Inversione Matriciale

Definiamo la matrice di informazione pesata accumulated al passo N:

$$\underline{\underline{Q}}(N) \triangleq \underline{\underline{H}}_N^T \underline{\underline{W}}_N \underline{\underline{H}}_N$$

Quando si acquisisce la nuova osservazione $y(N+1)$ caratterizzata dalla riga di modello $\underline{h}^T(N+1)$ e dal peso associato $w(N+1) > 0$, la matrice di informazione al passo $N+1$ si aggiorna mediante un'aggiunta a rango:

$$\underline{\underline{Q}}(N+1) = \underline{\underline{Q}}(N) + w(N+1)\,\underline{h}(N+1)\underline{h}^T(N+1)$$

Il Lemma di Inversione Matriciale (Sherman-Morrison-Woodbury)

Per calcolare l'inversa $\underline{\underline{P}}(N+1) \triangleq \underline{\underline{Q}}^{-1}(N+1)$ evitando l'inversione diretta di matrici, si applica il **Lemma di Sherman-Morrison-Woodbury**:

$$(\underline{\underline{A}} + \underline{u}\underline{v}^T)^{-1} = \underline{\underline{A}}^{-1} - \frac{\underline{\underline{A}}^{-1}\underline{u}\underline{v}^T\underline{\underline{A}}^{-1}}{1 + \underline{v}^T\underline{\underline{A}}^{-1}\underline{u}}$$

Ponendo:

- $\underline{\underline{A}} = \underline{\underline{Q}}(N) \implies \underline{\underline{A}}^{-1} = \underline{\underline{P}}(N)$
- $\underline{u} = w(N+1)\underline{h}(N+1)$
- $\underline{v} = \underline{h}(N+1)$

si ricava la relazione ricorsiva di aggiornamento della matrice di covarianza/inversa $\underline{\underline{P}}(N+1)$:

$$\underline{\underline{P}}(N+1) = \underline{\underline{P}}(N) - \frac{w(N+1)\,\underline{\underline{P}}(N)\underline{h}(N+1)\underline{h}^T(N+1)\underline{\underline{P}}(N)}{1 + w(N+1)\,\underline{h}^T(N+1)\underline{\underline{P}}(N)\underline{h}(N+1)}$$

Calcolo del Vettore di Guadagno $\underline{k}(N+1)$

Definiamo il vettore di guadagno RLS come:

$$\underline{k}(N+1) \triangleq \frac{w(N+1)\,\underline{\underline{P}}(N)\underline{h}(N+1)}{1 + w(N+1)\,\underline{h}^T(N+1)\underline{\underline{P}}(N)\underline{h}(N+1)} = \underline{\underline{P}}(N+1)\underline{h}(N+1)w(N+1)$$

Grazie a questa posizione, l'aggiornamento dell'inversa e dello stato si sintetizzano in **tre passaggi computazionali elementari**:

1. **Calcolo dell'Errore di Innovazione**:

$$e(N+1) = y(N+1) - \underline{h}^T(N+1)\underline{\hat{x}}(N)$$

2. **Calcolo del Guadagno RLS**:

$$\underline{k}(N+1) = \frac{w(N+1)\underline{\underline{P}}(N)\underline{h}(N+1)}{1 + w(N+1)\underline{h}^T(N+1)\underline{\underline{P}}(N)\underline{h}(N+1)}$$

3. **Aggiornamento dello Stato e della Matrice $\underline{\underline{P}}$**:

$$\underline{\hat{x}}(N+1) = \underline{\hat{x}}(N) + \underline{k}(N+1)\,e(N+1)$$

$$\underline{\underline{P}}(N+1) = \left(\underline{\underline{I}}_M - \underline{k}(N+1)\underline{h}^T(N+1)\right)\underline{\underline{P}}(N)$$

3.4 Vantaggi e Connessione con il Filtro di Kalman

Vantaggi dell'Algoritmo RLS:

- **Riduzione della Complessità Computazionale**: La complessità per aggiornare la stima ad ogni istante di tempo scende da $\mathcal{O}(M^3)$ a soli $\mathcal{O}(M^2)$ **operazioni aritmetiche** (corrispondenti a prodotti matrice-vettore).
- **Memoria Finita e Bassa Latenza**: Non è più necessario conservare lo storico delle osservazioni passate; è sufficiente mantenere in memoria lo stato stimato corrente $\underline{\hat{x}}(N)$ e la matrice di dimensione contenuta $\underline{\underline{P}}(N) \in \mathbb{R}^{M \times M}$.

Connessione Teorica con il Filtro di Kalman:

L'algoritmo dei Minimi Quadrati Sequenziali (RLS) costituisce il **fondamento deterministico del Filtro di Kalman**. Quando allo schema di osservazione si aggiunge un modello di transizione di stato dinamico-stocastico ($\underline{x}(N+1) = \underline{\underline{F}}\underline{x}(N) + \underline{w}(N)$), l'aggiornamento RLS si generalizza direttamente nelle equazioni di correzione (filtering step) del Filtro di Kalman.