ELSD 13

2026-11-02

Blocco 1 - Aggiornamento Ricorsivo RLS e Stima di Canale con Segnali Pilota

1.1 Ripresa dello Stimatore WLS e Condizione di Invertibilità

Lo studio della stima dei parametri in modelli lineari si fonda sulla formulazione dello stimatore dei Minimi Quadrati Pesati (Weighted Least Squares — WLS). Dato un modello di osservazione vettoriale:

$$\underline{y} = \underline{\underline{H}}\underline{x} + \underline{n}$$

dove $\underline{y} \in \mathbb{R}^N$ è il vettore delle misurazioni, $\underline{x} \in \mathbb{R}^M$ è il vettore dei parametri incogniti da stimare, $\underline{\underline{H}} \in \mathbb{R}^{N \times M}$ è la matrice di osservazione deterministica e $\underline{n} \in \mathbb{R}^N$ rappresenta il disturbo additivo, lo stimatore WLS minimizza la forma quadratica pesata del residuo $(\underline{y} - \underline{\underline{H}}\underline{x})^T \underline{\underline{W}} (\underline{y} - \underline{\underline{H}}\underline{x})$.

La soluzione in forma chiusa dello stimatore WLS assume la forma:

$$\underline{\hat{x}}_{WLS} = \left(\underline{\underline{H}}^T \underline{\underline{W}} \underline{\underline{H}} \right)^{-1} \underline{\underline{H}}^T \underline{\underline{W}} \underline{y}$$

Per garantire l'esistenza e l'unicità della stima in blocco (*batch*), la matrice quadrata di informazione $\underline{\underline{H}}^T \underline{\underline{W}} \underline{\underline{H}} \in \mathbb{R}^{M \times M}$ deve risultare strettamente invertibile. Assumendo che la matrice dei pesi $\underline{\underline{W}}$ sia definita positiva ($\underline{\underline{W}} > 0$), l'invertibilità ammette una **condizione necessaria fondamentale sul rango**: la matrice di osservazione $\underline{\underline{H}}$ deve avere rango pieno per colonna ($\text{rank}(\underline{\underline{H}}) = M$). Di conseguenza, il numero di misurazioni disponibili N deve soddisfare il vincolo:

$$N \geq M$$

In termini fisici e ingegneristici, per stimare un vettore di M parametri incogniti occorre acquisire un numero di osservazioni indipendenti N almeno pari al numero delle incognite M. *(Si veda anche ELSD 12(Blocco 2 per la trattazione del modello WLS in blocco).*

1.2 Stima di Canale tramite Segnali Pilota e Acquisizione Sequenziale dei Dati

Nei sistemi di comunicazione digitale e di elaborazione dei segnali, un'applicazione di primario interesse risiede nella **stima di canale**. Per identificare la risposta impulsiva o i coefficienti di attenuazione del canale trasmissivo, si trasmette un **segnale pilota** (o *segnale di testing*), ossia una forma d'onda deterministica nota a priori sia al trasmettitore che al ricevitore (come una cosinusoide a frequenza nota o una sequenza di rumore pseudo-casualizzato PRN).

Reiterando la trasmissione e la misurazione del segnale pilota, i campioni ricevuti giungono in sequenza temporale un passo alla volta: $y_1, y_2, \ldots, y_N, y_{N+1}$.

All'istante iniziale in cui il numero di campioni acquisiti è esattamente pari al numero di parametri da stimare ($N = M$), la matrice di osservazione $\underline{\underline{H}}_M \in \mathbb{R}^{M \times M}$ diventa quadrata. Raggiunta la condizione limite di invertibilità $N = M$, si ricava la prima stima valida del parametro $\underline{\hat{x}}_M = d(\underline{y}_M)$.

Quando viene acquisita una nuova misurazione y_{N+1} all'istante $N+1$, il vettore delle osservazioni e la matrice di sistema si aggiornano con l'aggiunta di una nuova riga $\underline{h}_{N+1}^T \in \mathbb{R}^{1 \times M}$:

$$\underline{y}_{N+1} = \begin{bmatrix} \underline{y}_N \\ y_{N+1} \end{bmatrix}, \qquad \underline{\underline{H}}_{N+1} = \begin{bmatrix} \underline{\underline{H}}_N \\ \underline{h}_{N+1}^T \end{bmatrix}$$

Ricalcolare la stima al passo $N+1$ mediante l'approccio *batch* tradizionale richiederebbe la reinversione diretta della matrice $\underline{\underline{H}}_{N+1}^T \underline{\underline{W}}_{N+1} \underline{\underline{H}}_{N+1}$. Questa operazione comporta un costo computazionale d'ordine $\mathcal{O}(M^3)$, un'elevata allocazione di memoria proporzionale all'intero storico dei dati e una latenza inaccettabile per le applicazioni operative in tempo reale.

1.3 Derivazione dell'Algoritmo RLS mediante il Lemma di Inversione Matriciale

Per evitare il ricalcolo esplicito dell'inversa ad ogni nuovo campione di segnale pilota, si adotta la **Stima Ricorsiva dei Minimi Quadrati (Recursive Least Squares — RLS)**.

Definiamo la matrice di informazione pesata accumulata al passo N e la sua inversa:

$$\underline{\underline{Q}}(N) \triangleq \underline{\underline{H}}_N^T \underline{\underline{W}}_N \underline{\underline{H}}_N, \qquad \underline{\underline{P}}(N) \triangleq \underline{\underline{Q}}^{-1}(N) = \left(\underline{\underline{H}}_N^T \underline{\underline{W}}_N \underline{\underline{H}}_N \right)^{-1}$$

All'arrivo della nuova misurazione y_{N+1} associata alla riga di modello $\underline{h}_{N+1}^T$ e al peso $w(N+1) > 0$, la matrice di informazione al passo $N+1$ si aggiorna mediante una correzione a rango:

$$\underline{\underline{Q}}(N+1) = \underline{\underline{Q}}(N) + w(N+1) \underline{h}_{N+1} \underline{h}_{N+1}^T$$

Per determinare l'aggiornamento diretto della matrice inversa $\underline{\underline{P}}(N+1) = \underline{\underline{Q}}^{-1}(N+1)$, si applica il **Lemma di Inversione Matriciale di Sherman-Morrison-Woodbury**:

$$\left(\underline{\underline{A}} + \underline{u}\underline{v}^T \right)^{-1} = \underline{\underline{A}}^{-1} - \frac{\underline{\underline{A}}^{-1} \underline{u}\underline{v}^T \underline{\underline{A}}^{-1}}{1 + \underline{v}^T \underline{\underline{A}}^{-1} \underline{u}}$$

Identificando $\underline{\underline{A}} = \underline{\underline{Q}}(N) \implies \underline{\underline{A}}^{-1} = \underline{\underline{P}}(N)$, $\underline{u} = w(N+1)\underline{h}_{N+1}$ e $\underline{v} = \underline{h}_{N+1}$, si ottiene l'equazione ricorsiva per l'inversa $\underline{\underline{P}}(N+1)$ senza alcuna inversione di matrici:

$$\underline{\underline{P}}(N+1) = \underline{\underline{P}}(N) - \frac{w(N+1)\,\underline{\underline{P}}(N)\underline{h}_{N+1}\underline{h}_{N+1}^T\underline{\underline{P}}(N)}{1 + w(N+1)\,\underline{h}_{N+1}^T\underline{\underline{P}}(N)\underline{h}_{N+1}}$$

1.4 Struttura dell'Aggiornamento Ricorsivo e Significato Fisico dei Termini

Definendo il **vettore di guadagno di aggiornamento (Gain Vector K_N)**:

$$K_N \triangleq \frac{w(N+1)\underline{\underline{P}}(N)\underline{h}_{N+1}}{1 + w(N+1)\underline{h}_{N+1}^T\underline{\underline{P}}(N)\underline{h}_{N+1}} = \underline{\underline{P}}(N+1)\underline{h}_{N+1}w(N+1)$$

l'intero algoritmo RLS si riassume in tre passaggi computazionali che aggiornano la stima precedente $\underline{\hat{x}}_N$ incorporando l'informazione apportata dall'osservazione y_{N+1}:

1. **Calcolo dell'Errore di Innovazione (o Residuo di Predizione a Priori**)**:

   $$e(N+1) \triangleq y_{N+1} - \underline{h}_{N+1}^T\underline{\hat{x}}_N$$

   L'errore di innovazione $e(N+1)$ misura la discrepanza tra il valore reale misurato dal sensore y_{N+1} e la predizione teorica $\underline{h}_{N+1}^T\underline{\hat{x}}_N$ formulata dal sistema sulla base della stima ottenuta al passo precedente.
   - *Significato fisico*: Se la stima $\underline{\hat{x}}_N$ fosse esatta e priva di rumore, la misurazione reale coinciderebbe perfettamente con la predizione del modello, producendo un errore di innovazione identicamente nullo ($e(N+1) = 0$) e lasciando invariata la stima.
2. **Calcolo del Guadagno RLS (K_N)**: Si valuta il vettore $K_N \in \mathbb{R}^M$, che stabilisce quanto peso attribuire all'errore di innovazione per aggiornare lo stato incognito.
3. **Aggiornamento dello Stato e della Matrice dell'Inversa**:

   $$\mathbf{\underline{\hat{x}}_{N+1} = \underline{\hat{x}}_N + K_N e(N+1)}$$

   $$\underline{\underline{P}}(N+1) = \left(\underline{\underline{I}}_M - K_N\underline{h}_{N+1}^T\right)\underline{\underline{P}}(N)$$

   L'adozione della ricorsione RLS riduce la complessità computazionale da $\mathcal{O}(M^3)$ a $\mathcal{O}(M^2)$ operazioni aritmetiche per ogni campione, eliminando la necessità di conservare lo storico dei dati passati e fornendo la struttura deterministica fondamentale per i filtri di stima adattativa e per il Filtro di Kalman.

Blocco 2 - Fondamenti della Classificazione Bayesiana e Minimizzazione del Rischio Condizionato

2.1 Transizione alla Classificazione Discreta e Partizione dello Spazio degli Osservabili

A differenza dei problemi di stima continua trattati nel ELSD 12.md > Blocco 2 - Minimi Quadrati Pesati (WLS) e nel ELSD 13.md > Blocco 1 - Aggiornamento Ricorsivo RLS e Stima di Canale con Segnali Pilota, la classificazione affronta il problema in cui lo stato o parametro incognito X appartiene a un alfabeto discreto di cardinalità finita $\mathcal{X} = \{x_1, x_2, \dots, x_M\}$ (oppure a un insieme discreto di ipotesi $\mathcal{H} = \{H_1, H_2, \dots, H_M\}$).

Il compito del classificatore (o decisore) consiste nell'individuare una regola di decisione deterministica $\hat{x} = d(y)$ che elabora il vettore continuo delle osservazioni $y \in \mathbb{R}^N$ e restituisce una stima discreta dello stato reale $\hat{x} \in \mathcal{X}$. Poiché la funzione $d(y)$ mappa uno spazio continuo multidimensionale su un insieme discreto, essa induce matematicamente una **partizione dello spazio degli osservabili** $\mathcal{A}_y$ in M sottoinsiemi o regioni di decisione disgiunte $A_1, A_2, \dots, A_M$.

$$\bigcup_{m=1}^{M} A_m = \mathcal{A}_y, \qquad A_i \cap A_j = \emptyset \quad \forall i \neq j$$

Assegnare la misurazione y alla regione A_m equivale a decidere per l'ipotesi $\hat{x} = x_m$. Come discusso nel contesto Bayesiano in ELSD 1.md > Blocco 1 - Modello del Sistema e ELSD 6.md > Blocco 2 - Contesto Bayesiano vs Non-Bayesiano, l'obiettivo della progettazione non è trovare una trasformazione algebrica punto a punto, ma definire i confini delle regioni A_m per ottimizzare un opportuno criterio statistico globalmente accettabile.

2.2 Introduzione della Funzione di Costo e Formulazione del Rischio Medio Globale

Nell'impostazione Bayesiana, a ciascuna coppia costituita dallo stato reale x_m e dalla decisione presa dal sistema $\hat{x} = d(y)$ viene associata una **funzione di costo** (o funzione di perdita) $C(x_m, \hat{x})$, che quantifica la penalità economica o ingegneristica derivante da quella specifica decisione:

$$C(x_m, \hat{x}) = C(x_m, d(y))$$

Poiché sia lo stato X che l'osservazione Y sono modellati come variabili aleatorie, la bontà complessiva del classificatore si valuta calcolando il valore atteso della funzione di costo su tutte le possibili realizzazioni dei dati e degli stati, definendo il **rischio medio globale** $E[C(x, \hat{x})]$:

$$E[C(x, \hat{x})] = \int_{\mathcal{A}_y} \left[\sum_{m=1}^{M} C(x_m, d(y))\, f_{Y,X}(y, x_m) \right] dy$$

Esplicitando la densità congiunta $f_{Y,X}(y, x_m) = f_{Y|X}(y|x_m)P(X = x_m)$, l'espressione del rischio medio globale assume la forma integrata esplicita:

$$E[C(x, \hat{x})] = \sum_{m=1}^{M} P(X = x_m) \int_{\mathcal{A}_y} f_{Y|X}(y|x_m) C(x_m, d(y))\, dy$$

La minimizzazione diretta di $E[C(x, \hat{x})]$ rispetto alla funzione di decisione $d(\cdot)$ sull'intero spazio multidimensionale $\mathcal{A}_y$ risulta analiticamente complessa, in quanto richiederebbe la ricerca variazionale dell'ottimo globale contemporaneamente su tutte le regioni di decisione.

2.3 Definizione del Rischio Condizionato e Minimizzazione Punto per Punto

Per rendere la minimizzazione operativamente tracciabile e realizzabile in tempo reale all'arrivo del dato misurato y, si applica la proprietà di fattorizzazione delle aspettative tramite la regola del condizionamento.

Anziché minimizzare il rischio medio globale sull'intero spazio, valutiamo il **rischio condizionato** $E[C(x, \hat{x}) \mid Y = y]$, ossia il costo medio calcolato condizionatamente all'aver registrato la specifica realizzazione dell'osservazione $Y = y$:

$$E[C(x, \hat{x}) \mid Y = y] = \sum_{m=1}^{M} C(x_m, \hat{x}(y))\, P(X = x_m \mid Y = y)$$

dove $P(X = x_m \mid Y = y)$ rappresenta la **probabilità a posteriori** dello stato x_m dato il valore misurato y.

Poiché la densità marginale dell'osservabile $f_Y(y)$ è strettamente non negativa ($f_Y(y) \geq 0$), la relazione tra il rischio globale e il rischio condizionato è legata dall'integrale:

$$E[C(x, \hat{x})] = \int_{\mathcal{A}_y} E[C(x, \hat{x}) \mid Y = y]\, f_Y(y)\, dy$$

Questa scomposizione garantisce un principio fondamentale della teoria delle decisioni: **minimizzare il rischio condizionato** $E[C(x, \hat{x}) \mid Y = y]$ **separatamente per ciascuna osservazione** y **equivale a minimizzare il rischio medio globale** $E[C(x, \hat{x})]$ **sull'intero spazio**.

In questo modo, il problema variazionale globale viene convertito in una semplice regola di decisione algebrica punto per punto: per ogni y ricevuto, il classificatore calcola il rischio condizionato per tutte le M possibili scelte di $\hat{x}$ e seleziona il valore che rende minimo il valore atteso del costo12.

2.4 Strutturazione delle Probabilità *a Priori* e delle Verosimiglianze Condizionate

L'implementazione concreta della minimizzazione del rischio condizionato richiede la caratterizzazione probabilistica completa del sistema di osservazione. In ambiente Bayesiano, tale caratterizzazione si articola in due componenti fondamentali:

1. **Probabilità a Priori** $P(X = x_m)$: modellano la conoscenza statistica posseduta sullo stato incognito prima di effettuare qualsiasi misurazione sul canale8more*horiz. Esse soddisfano il vincolo di normalizzazione:$$\sum{m=1}^M P(X = x_m) = 1$$*
2. **Verosimiglianze Condizionate** $f_{Y|X}(y|x_m)$: descrivono il comportamento statistico del canale e del rumore di misura, fornendo la funzione di densità di probabilità dell'osservazione y nell'ipotesi che lo stato reale sia $X = x_m$.

Applicando il **Teorema di Bayes**, la probabilità *a posteriori* $P(X = x_m \mid Y = y)$ si esprime come il prodotto tra la verosimiglianza condizionata e la probabilità *a priori*, normalizzato rispetto alla densità marginale dell'osservabile $f_Y(y)$:

$$P(X = x_m \mid Y = y) = \frac{f_{Y|X}(y|x_m)\, P(X = x_m)}{f_Y(y)} = \frac{f_{Y|X}(y|x_m)\, P(X = x_m)}{\sum_{j=1}^{M} f_{Y|X}(y|x_j)\, P(X = x_j)}$$

Poiché il denominatore $f_Y(y)$ è positivo e comune a tutte le ipotesi x_m, esso non altera l'ordinamento dei costi condizionati e può essere omesso durante la minimizzazione punto per punto. Questa struttura analitica costituisce la base fondamentale per la derivazione formale del Ricevitore MAP e del Ricevitore ML sviluppati in ELSD 14.md > Blocco 1 - Classificazione Bayesiana Binaria con Costi Arbitrari e Derivazione dell'LRT.

Blocco 3 - Derivazione Formale del Ricevitore MAP e Riduzione al Criterio ML

3.1 Definizione della Funzione di Costo 0-1 (Distanza di Hamming / Costo Uniforme)

Nel contesto della classificazione Bayesiana discreta con stato incognito $X \in \mathcal{X} = \{x_1, x_2, \ldots, x_M\}$ e decisione $\hat{x} \in \mathcal{X}$, si introduce una funzione di costo $C(x, \hat{x})$ per quantificare la penalità associata alla scelta computata dal sistema.

Per problemi di classificazione di simboli o blocchi discrezionali in cui tutte le decisioni errate comportano la medesima penalità e le decisioni corrette non comportano alcun costo, si adotta la funzione di costo 0-1 (nota anche come costo uniforme o indicatore d'errore di Hamming):

$$C(x_m, \hat{x}) = 1 - \delta(x_m - \hat{x}) = \begin{cases} 0 & \text{se } \hat{x} = x_m \quad \text{(decisione corretta)} \\ 1 & \text{se } \hat{x} \neq x_m \quad \text{(decisione errata)} \end{cases}$$

dove $\delta(\cdot)$ rappresenta la delta di Kronecker (o funzione indicatrice di uguaglianza).

3.2 Formulazione del Rischio Condizionato e Minimizzazione della Probabilità d'Errore

Come introdotto in ELSD 13.md > Blocco 2 - Fondamenti della Classificazione Bayesiana e Minimizzazione del Rischio Condizionato, per guidare la regola di decisione all'arrivo del dato osservato y si valuta il rischio condizionato $E[C(x, \hat{x}) \mid Y = y]$:

$$E[C(x, \hat{x}) \mid Y = y] = \sum_{m=1}^{M} C(x_m, \hat{x}(y)) P(X = x_m \mid Y = y)$$

Sostituendo l'espressione della funzione di costo $C(x_m, \hat{x}) = 1 - \delta(x_m - \hat{x})$:

$$E[C(x, \hat{x}) \mid Y = y] = \sum_{m=1}^{M} \left[1 - \delta(x_m - \hat{x})\right] P(X = x_m \mid Y = y)$$

Scomposizione analitica della sommatoria:

$$E[C(x, \hat{x}) \mid Y = y] = \underbrace{\sum_{m=1}^{M} P(X = x_m \mid Y = y)}_{=1} - \sum_{m=1}^{M} \delta(x_m - \hat{x}) P(X = x_m \mid Y = y)$$

Poiché la somma delle probabilità *a posteriori* su tutte le M ipotesi vale identicamente 1, e l'unico termine non nullo della seconda sommatoria si ottiene per $x_m = \hat{x}$, il rischio condizionato si semplifica nella relazione fondamentale:

$$E[C(x, \hat{x}) \mid Y = y] = 1 - P(X = \hat{x} \mid Y = y)$$

Il rischio condizionato coincide esattamente con la probabilità d'errore condizionata $P_e(y) = 1 - P(X = \hat{x} \mid Y = y)$. Di conseguenza, minimizzare il rischio condizionato $E[C(x, \hat{x}) \mid Y = y]$ equivale a **massimizzare la probabilità a posteriori** $P(X = \hat{x} \mid Y = y)$ della classe stimata:

$$\min_{\hat{x}} E[C(x, \hat{x}) \mid Y = y] \iff \max_{\hat{x}} P(X = \hat{x} \mid Y = y)$$

3.3 Derivazione Analitica della Regola di Decisione Logaritmica del Ricevitore MAP

Per esprimere la regola di decisione in funzione delle probabilità del canale, si applica il Teorema di Bayes alla probabilità *a posteriori*:

$$P(X = x_m \mid Y = y) = \frac{f_{Y|X}(y \mid x_m) P(X = x_m)}{f_Y(y)}$$

Il decisore seleziona la stima $\hat{x}$ che risolve il problema di ottimizzazione45:

$$\hat{x} = \arg\max_{x_m \in \mathcal{X}} P(X = x_m \mid Y = y) = \arg\max_{x_m \in \mathcal{X}} \left[\frac{f_{Y|X}(y \mid x_m) P(X = x_m)}{f_Y(y)} \right]$$

Poiché la densità marginale dell'osservazione $f_Y(y)$ è strettamente positiva e indipendente dall'indice di ipotesi x_m, essa risulta ininfluente ai fini del confronto e viene omessa dall'operatore:

$$\hat{x} = \arg\max_{x_m \in \mathcal{X}} \left[f_{Y|X}(y \mid x_m) P(X = x_m) \right]$$

Applicando la funzione logaritmo naturale (che è strettamente crescente e conserva l'ordinamento degli argomenti per il Teorema di Invarianza)5:

$$\hat{x}_{\text{MAP}} = \arg\max_{x_m \in \mathcal{X}} \ln \left[f_{Y|X}(y \mid x_m) P(X = x_m) \right]$$

Sfruttando le proprietà dei logaritmi ($\ln(a \cdot b) = \ln a + \ln b$), si ottiene la forma canonica del **Ricevitore Maximum A Posteriori (MAP)**:

$$\hat{\mathbf{x}}_{\text{MAP}} \triangleq \arg\max_{\mathbf{x_m} \in \mathcal{X}} \left[\ln \mathbf{f_{Y|X}(y \mid x_m)} + \ln \mathbf{P(X = x_m)} \right]$$

Il Ricevitore MAP combina l'informazione estratta dalle misurazioni del canale (espressa dalla log-verosimiglianza $\ln f_{Y|X}(y \mid x_m)$) con la conoscenza *a priori* posseduta sulla sorgente (espressa dal termine $\ln P(X = x_m)$)5. *(Si veda anche ELSD 14.md > Blocco 1 - Classificazione Bayesiana Binaria con Costi Arbitrari e Derivazione dell'LRT per il collegamento con la soglia dell'LRT Bayesiano binario).*

3.4 Caso Particolare di Ipotesi Equiprobabili e Convergenza al Ricevitore Maximum Likelihood (ML)

Se non vi è alcuna conoscenza o preferenza *a priori* tra i simboli dell'alfabeto, le M ipotesi si assumono **equiprobabili**:

$$P(X = x_m) = \frac{1}{M} \quad \forall m \in \{1, 2, \ldots, M\}$$

In questo contesto, il termine logaritmico *a priori* $\ln P(X = x_m) = \ln(1/M) = -\ln M$ assume un valore costante identico per tutte le ipotesi x_m. Di conseguenza, esso non altera la posizione del massimo e scomplete dal calcolo dell'operatore $\arg\max$.

La regola di decisione si riduce alla massimizzazione della sola log-verosimiglianza, definendo il **Ricevitore Maximum Likelihood (ML)**:

$$\hat{\mathbf{x}}_{\text{ML}} \triangleq \arg\max_{\mathbf{x_m} \in \mathcal{X}} \ln \mathbf{f_{Y|X}(y \mid x_m)}$$

Sotto l'ipotesi di classi equiprobabili, la decisione MAP converge nella decisione ML: il classificatore assegna la misurazione y alla classe x_m che rende massima la probabilità condizionata di aver generato quel determinato dato di canale.