ELSD 14

2026-11-06

Blocco 1 - Classificazione Bayesiana Binaria con Costi Arbitrari e Derivazione dell'LRT

1.1 Definizione del Rischio Condizionato e Modello Decisionale Binario

Nella teoria della decisione e classificazione Bayesiana, la scelta della decisione ottima $\hat{x}$ a partire dall'osservazione y si fonda sulla minimizzazione del costo medio condizionato, noto anche come rischio condizionato $E[C(x, \hat{x})|y]$. Consideriamo uno spazio degli stati binario $\mathcal{X} = \{0, 1\}$ e uno spazio delle decisioni equivalente $\hat{\mathcal{X}} = \{0, 1\}$.

Il valore presunto o stimato dello stato $\hat{x}(y)$ viene determinato valutando il costo associato a ciascuna decisione rispetto allo stato effettivo x. In presenza di uno spazio discreto a due valori, la funzione di costo $C(x, \hat{x})$ assume quattro possibili valori discrezionali:

- $C(0, 0)$: costo associato alla decisione $\hat{x} = 0$ quando lo stato reale è $x = 0$ (corretta classificazione della classe 0);
- $C(0, 1)$: costo associato alla decisione $\hat{x} = 1$ quando lo stato reale è $x = 0$ (falso allarme / errore di tipo I);
- $C(1, 0)$: costo associato alla decisione $\hat{x} = 0$ quando lo stato reale è $x = 1$ (mancata risposta / errore di tipo II);
- $C(1, 1)$: costo associato alla decisione $\hat{x} = 1$ quando lo stato reale è $x = 1$ (corretta classificazione della classe 1).

Per una generica osservazione y, il rischio condizionato espresso come media del costo rispetto alla distribuzione *a posteriori* $P(x|y)$ vale:

$$E[C(x, \hat{x})|y] = \sum_{x \in \{0,1\}} C(x, \hat{x}) P(x|y) = C(1, \hat{x}) P(x = 1|y) + C(0, \hat{x}) P(x = 0|y)$$

1.2 Minimizzazione del Costo Medio e Regola di Decisione

Per definire la regola di decisione ottima a partire dal valore osservato y, si calcola il rischio condizionato valutando separatamente le due possibili scelte per $\hat{x}$:

1. Valutazione del rischio per la decisione $\hat{x} = 1$:

$$E[C(x, 1)|y] = C(1, 1)P(1|y) + C(0, 1)P(0|y)$$

2. Valutazione del rischio per la decisione $\hat{x} = 0$:

$$E[C(x, 0)|y] = C(1, 0)P(1|y) + C(0, 0)P(0|y)$$

La regola di decisione Bayesiana impone di scegliere l'ipotesi che minimizza il rischio condizionato. Di conseguenza, si decide per $\hat{x} = 1$ se il costo condizionato della decisione 1 risulta strettamente inferiore a quello della decisione 0, mentre si decide per $\hat{x} = 0$ nel caso opposto. L'ineguaglianza fondamentale di confronto assume la forma:

$$C(1, 1)P(1|y) + C(0, 1)P(0|y) \underset{\hat{x}=0}{\overset{\hat{x}=1}{\lesseqgtr}} C(1, 0)P(1|y) + C(0, 0)P(0|y)$$

1.3 Conversione nelle Densità Condizionate e Derivazione dell'LRT

Per esprimere il classificatore in termini di verosimiglianze $f_{Y|X}(y|x)$ e probabilità *a priori* $P(x)$, applichiamo il Teorema di Bayes alle probabilità *a posteriori*:

$$P(1|y) = \frac{f_{Y|X}(y|1)P(1)}{f_Y(y)}, \qquad P(0|y) = \frac{f_{Y|X}(y|0)P(0)}{f_Y(y)}$$

Sostituendo tali espressioni nella regola di decisione e moltiplicando ambo i membri per la densità marginale $f_Y(y) > 0$ (che risulta ininfluente ai fini del confronto in quanto strettamente positiva), otteniamo:

$$C(1, 1)f_{Y|X}(y|1)P(1) + C(0, 1)f_{Y|X}(y|0)P(0) \underset{\hat{x}=0}{\overset{\hat{x}=1}{\lesseqgtr}} C(1, 0)f_{Y|X}(y|1)P(1) + C(0, 0)f_{Y|X}(y|0)P(0)$$

Raggruppando i termini contenenti $f_{Y|X}(y|1)P(1)$ a sinistra e quelli contenenti $f_{Y|X}(y|0)P(0)$ a destra:

$$f_{Y|X}(y|1)P(1)\left[C(1, 1) - C(1, 0)\right] \underset{\hat{x}=0}{\overset{\hat{x}=1}{\lesseqgtr}} f_{Y|X}(y|0)P(0)\left[C(0, 0) - C(0, 1)\right]$$

In situazioni fisiche e ingegneristiche ragionevoli, il costo di una decisione errata è strettamente superiore al costo di una decisione corretta, ovvero $C(1, 0) > C(1, 1)$ e $C(0, 1) > C(0, 0)\$10.Pertanto, iltermine\$[C(1, 1) - C(1, 0)]$ risulta strettamente negativo. Dividendo ambo i membri per la quantità negativa $[C(1, 1) - C(1, 0)]$, il verso della disuguaglianza si inverte, isolando il Rapporto di Verosimiglianza (Likelihood Ratio) $\mathcal{L}(y)$:

$$\mathcal{L}(y) \triangleq \frac{f_{Y|X}(y|1)}{f_{Y|X}(y|0)} \underset{\hat{x}=0}{\overset{\hat{x}=1}{\gtrless}} \frac{P(0)}{P(1)} \cdot \frac{C(0,0) - C(0,1)}{C(1,1) - C(1,0)}$$

Riscrivendo il rapporto dei costi in termini di quantità positive tramite l'inversione dei segni al numeratore e al denominatore, otteniamo la forma canonica del **Likelihood Ratio Test (LRT)** Bayesiano:

$$\mathcal{L}(\mathbf{y}) = \frac{\mathbf{f_{Y|X}(y|1)}}{\mathbf{f_{Y|X}(y|0)}} \underset{\mathbf{\hat{x}=0}}{\overset{\mathbf{\hat{x}=1}}{\gtrless}} \frac{\mathbf{P(0)}}{\mathbf{P(1)}} \cdot \frac{\mathbf{C(0,1) - C(0,0)}}{\mathbf{C(1,0) - C(1,1)}} \triangleq \gamma$$

La soglia di decisione γ è determinata congiuntamente dal rapporto tra le probabilità *a priori* $\frac{P(0)}{P(1)}$ e dal rapporto tra i costi differenziali di errore e corretta classificazione.

1.4 Casi Particolari: Costo Binario (0-1 Loss), MAP e ML

La formulazione generale dell'LRT Bayesiano racchiude come casi particolari i classici criteri di decisione studiati nella teoria della stima e classificazione:

1. **Costo Binario Simmetrico (0-1 Loss / Criterio MAP)**: Se assegniamo costo nullo alle decisioni corrette e costo unitario agli errori ($C(0,0) = 0, C(1,1) = 0, C(0,1) = 1, C(1,0) = 1$), il fattore dei costi diventa:

   $$\frac{C(0,1) - C(0,0)}{C(1,0) - C(1,1)} = \frac{1-0}{1-0} = 1$$

   La soglia dell'LRT si riduce al solo rapporto tra le probabilità *a priori* $\gamma_{\text{MAP}} = \frac{P(0)}{P(1)}$, ripristinando la regola di decisione **Maximum A Posteriori (MAP)**.
2. **Ipotesi Equiprobabili (Criterio ML)**: Se oltre alla funzione di costo 0-1 loss le classi sono equiprobabili ($P(0) = P(1) = 1/2$), la soglia si annulla in scala logaritmica assumendo valore unitario $\gamma_{\text{ML}} = 1$. Il test Bayesiano coincide in questo caso con la regola di **Maximum Likelihood (ML)**.
3. **Confronto con il Criterio di Neyman-Pearson**: A differenza del test di Neyman-Pearson (frequentista), in cui la soglia viene fissata esclusivamente dall'imposizione di un vincolo sulla probabilità di falso allarme $P_{\text{FA}} \leq \alpha$, nel test Bayesiano la soglia è fissata in modo deterministico dalla conoscenza *a priori* delle classi e dai costi penalizzanti associati agli errori.

Blocco 2 - Stima Bayesiana MAP per Variabili Continue (Funzione di Costo Sferica ad Ampiezza Infinitesima)

2.1 Estensione della Stima MAP al Caso Continuo e Funzione di Costo a Sfera (Uniform Cost / Zero-One Loss)

Nella teoria della stima Bayesiana per variabili casuali continue $X \in \mathbb{R}^N$ osservate attraverso la variabile $Y \in \mathbb{R}^M$, la derivazione formale dello stimatore Maximum A Posteriori (MAP) richiede la definizione di una funzione di costo opportuna che rappresenti l'analogo continuo della funzione di costo binaria 0-1 usata nel caso discreto.

Consideriamo una funzione di costo $C(x, \hat{x})$ definita in termini di distanza euclidea tra lo stato reale x e la stima $\hat{x}$, parametrizzata da un raggio di tolleranza $\Delta > 0$:

$$C(x, \hat{x}) = \begin{cases} 0 & \text{se } \|x - \hat{x}\| \leq \Delta \\ 1 & \text{se } \|x - \hat{x}\| > \Delta \end{cases} = 1 - \mathbb{I}_{\{\|x-\hat{x}\| \leq \Delta\}}$$

Tale funzione penalizza con costo unitario tutte le stime $\hat{x}$ che cadono all'esterno dell'ipersfera di raggio Δ centrata attorno al valore vero x, mentre non assegna alcun costo (costo nullo) a qualsiasi stima contenuta entro la bolla di tolleranza di raggio Δ.

2.2 Formulazione del Rischio Condizionato e Calcolo dell'Integrale di Costo

Per determinare lo stimatore ottimo, calcoliamo il rischio condizionato (ossia il costo medio condizionato all'osservazione y) integrando la funzione di costo $C(x, \hat{x})$ rispetto alla densità di probabilità *a posteriori* $f_{X|Y}(x|y)$:

$$E[C(x, \hat{x})|y] = \int_{\mathbb{R}^N} C(x, \hat{x})\, f_{X|Y}(x|y)\, dx$$

Sostituendo la forma $C(x, \hat{x}) = 1 - \mathbb{I}_{\{\|x-\hat{x}\| \leq \Delta\}}$, l'integrale sull'intero spazio $\mathbb{R}^N$ si scompone nella differenza tra l'integrale della densità *a posteriori* (che vale 1 per la proprietà di normalizzazione della probabilità) e l'integrale di volume ristretto alla sola ipersfera di centro $\hat{x}$ e raggio Δ:

$$E[C(x, \hat{x})|y] = \int_{\mathbb{R}^N} f_{X|Y}(x|y)\, dx - \int_{\|x-\hat{x}\| \leq \Delta} f_{X|Y}(x|y)\, dx = 1 - \int_{\|x-\hat{x}\| \leq \Delta} f_{X|Y}(x|y)\, dx$$

Minimizzare il rischio condizionato $E[C(x, \hat{x})|y]$ equivale dunque a massimizzare la massa di probabilità contenuta entro l'ipersfera di tolleranza $\|\cdot - \hat{x}\| \leq \Delta$:

$$\min_{\hat{x}} E[C(x, \hat{x})|y] \iff \max_{\hat{x}} \int_{\|x-\hat{x}\| \leq \Delta} f_{X|Y}(x|y)\, dx$$

2.3 Teorema della Media Integrale nel Limite per $\Delta \to 0$ e Derivazione dello Stimatore MAP

Nel caso monodimensionale ($N = 1$), l'insieme $\{\|x - \hat{x}\| \leq \Delta\}$ rappresenta l'intervallo compatto $[\hat{x} - \Delta, \hat{x} + \Delta]$ di ampiezza 2Δ. Nel caso multidimensionale generico ($N \geq 1$),

rappresenta un'ipersfera $\mathcal{S}_\Delta(\hat{x})$ di volume $\mathrm{Vol}(\Delta) = c_N \Delta^N$, dove c_N è una costante geometrica dipendente dalla dimensione N dello spazio degli stati.

Ipotizzando che la densità di probabilità *a posteriori* $f_{X|Y}(x|y)$ sia una funzione continua nell'intorno di $\hat{x}$, possiamo applicare il Teorema della Media Integrale al dominio di integrazione compatto $\mathcal{S}_\Delta(\hat{x})$:

$$\int_{\|x-\hat{x}\| \leq \Delta} f_{X|Y}(x|y)\, dx = f_{X|Y}(\xi|y) \cdot \mathrm{Vol}(\Delta)$$

dove ξ è un punto opportuno contenuto all'interno dell'ipersfera $\|\xi - \hat{x}\| \leq \Delta$.

Sostituendo tale approssimazione nel rischio condizionato, il costo medio diventa:

$$E[C(x, \hat{x})|y] = 1 - f_{X|Y}(\xi|y) \cdot \mathrm{Vol}(\Delta)$$

Facendo tendere il raggio della sfera a zero ($\Delta \to 0$), la regione di integrazione collassa sul punto centrale $\hat{x}$, imponendo $\xi \to \hat{x}$ per continuità. Normalizzando la componente integrata rispetto al volume $\mathrm{Vol}(\Delta)$ e calcolando il limite per $\Delta \to 0$, il valore dell'integrale medio converge esattamente alla densità di probabilità puntuale *a posteriori* $f_{X|Y}(\hat{x}|y)$:

$$\lim_{\Delta \to 0} \frac{1}{\mathrm{Vol}(\Delta)} \int_{\|x-\hat{x}\| \leq \Delta} f_{X|Y}(x|y)\, dx = f_{X|Y}(\hat{x}|y)$$

Di conseguenza, per un raggio di tolleranza infinitesimo $\Delta \to 0$, minimizzare il rischio condizionato significa individuare la posizione $\hat{x}$ che massimizza il valore puntuale della PDF *a posteriori*:

$$\hat{\mathbf{x}}_{\mathrm{MAP}} \triangleq \arg\max_{\mathbf{x}} \mathbf{f_{X|Y}(x|y)}$$

Lo stimatore Maximum A Posteriori (MAP) per variabili continue coincide dunque con la **moda della distribuzione a posteriori** $f_{X|Y}(x|y)$ (ossia il punto di picco assoluto della densità condizionata).

2.4 Condizioni di Equivalenza tra Stimatore MAP e Maximum Likelihood (ML)

In virtù della regola di Bayes, la densità di probabilità *a posteriori* si esprime come:

$$f_{X|Y}(x|y) = \frac{f_{Y|X}(y|x) f_X(x)}{f_Y(y)}$$

Lo stimatore MAP risolve il problema di ottimizzazione:

$$\hat{x}_{\text{MAP}} = \arg\max_x \left[\frac{f_{Y|X}(y|x) f_X(x)}{f_Y(y)} \right] = \arg\max_x \left[f_{Y|X}(y|x) f_X(x) \right]$$

in quanto il denominatore $f_Y(y)$ è indipendente da x e non altera la posizione del massimo.

Al contrario, lo stimatore Maximum Likelihood (ML) non-bayesiano massimizza unicamente la funzione di verosimiglianza:

$$\hat{x}_{\text{ML}} \triangleq \arg\max_x f_{Y|X}(y|x)$$

Analizziamo le condizioni sotto le quali lo stimatore MAP converge allo stimatore ML:

1. **Prior Uniforme su Supporto Compatto $\mathcal{S}_X$**: Se la densità *a priori* $f_X(x)$ è uniformemente distribuita su un insieme limitato e noto $\mathcal{S}_X \subset \mathbb{R}^N$ di volume finito $\text{Vol}(\mathcal{S}_X)$, allora $f_X(x) = \frac{1}{\text{Vol}(\mathcal{S}_X)}$ è costante per ogni $x \in \mathcal{S}_X$. In tal caso, la prior scompare dall'argomento dell'operatore $\arg\max$, riducendo la stima MAP alla stima ML ristretta al supporto $\mathcal{S}_X$:

$$\hat{x}_{\text{MAP}} = \arg\max_{x \in \mathcal{S}_X} f_{Y|X}(y|x) = \hat{x}_{\text{ML}}$$

2. **Assenza di Conoscenza a Priori su Supporto Illimitato ($\mathbb{R}^N$)**: Se lo spazio degli stati è illimitato ($x \in \mathbb{R}^N$), una distribuzione perfettamente uniforme non è matematicamente definibile come densità di probabilità propria, poiché $\lim_{\text{Vol}\to\infty} \frac{1}{\text{Vol}} = 0$. Tuttavia, adottando una prior *impropria* o assumendo che la prior sia completamente piatta nell'intorno dell'osservazione dove la verosimiglianza è significativa, il fattore $f_X(x)$ non influenza la posizione del massimo, rendendo la stima MAP concettualmente equivalente alla stima ML.

Blocco 3 - Stima Bayesiana a Minimo Errore Assoluto (MAE / Costo L_1) e la Mediana a Posteriori

3.1 Formulazione della Funzione di Costo Norma L_1 (Mean Absolute Error - MAE)

Nella teoria della stima Bayesiana per vettori casuali $X = [X_1, X_2, \ldots, X_N]^T \in \mathbb{R}^N$ osservati mediante il vettore $Y \in \mathbb{R}^M$, una funzione di costo di notevole rilevanza pratica è la norma L_1 dell'errore di stima, definita come la somma dei valori assoluti dei singoli errori di ciascuna componente:

$$C(x, \hat{x}) = \|x - \hat{x}\|_1 \triangleq \sum_{i=1}^{N} |x_i - \hat{x}_i|$$

Questa funzione di costo assegna una penalità linearmente proporzionale al valore

assoluto dello scostamento tra il valore vero x_i e la stima $\hat{x}_i$. A differenza della funzione di costo quadratica (L_2), che penalizza fortemente le deviazioni di grande ampiezza tramite il quadrato dell'errore, la norma L_1 fornisce uno stimatore particolarmente robusto nei confronti di valori anomali (*outliers*) o di rumori impulsivi a coda pesante.

3.2 Disaccoppiamento per Singole Componenti e Rischio Condizionato

Il calcolo del rischio condizionato (ossia la media del costo condizionata all'osservazione y) beneficia direttamente della proprietà di linearità dell'operatore di valore atteso:

$$E[C(x, \hat{x}) \mid y] = E\left[\sum_{i=1}^{N} |x_i - \hat{x}_i| \,\middle|\, y\right] = \sum_{i=1}^{N} E\left[|x_i - \hat{x}_i| \mid y\right]$$

Minimizzare il rischio condizionato globale $E[C(x, \hat{x}) \mid y]$ equivale a minimizzare in modo del tutto indipendente ciascun addendo della sommatoria. Possiamo dunque disaccoppiare il problema vettoriale in N problemi di minimizzazione monodimensionali distinti.

Definiamo il rischio condizionato associato alla singola i-esima componente $R_i(\hat{x}_i)$:

$$R_i(\hat{x}_i) \triangleq E\left[|x_i - \hat{x}_i| \mid y\right] = \int_{-\infty}^{+\infty} |x_i - \hat{x}_i| f_{X_i|Y}(x_i \mid y)\, dx_i$$

dove $f_{X_i|Y}(x_i \mid y)$ rappresenta la densità di probabilità marginale *a posteriori* della sola componente X_i condizionata al vettore di osservazioni y.

3.3 Dimostrazione Analitica: Scissione dell'Integrale e Derivata con il Teorema Fondamentale del Calcolo Integrale

Per eliminare l'operatore di valore assoluto dall'integrando, scindiamo il dominio di integrazione $(-\infty, +\infty)$ in due sottointervalli compatti separati dal punto di stima $\hat{x}_i$:

- Nell'intervallo $(-\infty, \hat{x}_i)$, si ha $x_i < \hat{x}_i \implies |x_i - \hat{x}_i| = -(x_i - \hat{x}_i) = \hat{x}_i - x_i$;
- Nell'intervallo $(\hat{x}_i, +\infty)$, si ha $x_i \geq \hat{x}_i \implies |x_i - \hat{x}_i| = x_i - \hat{x}_i$.

Sostituendo la scissione del modulo nell'integrale del rischio condizionato $R_i(\hat{x}_i)$:

$$R_i(\hat{x}_i) = \int_{-\infty}^{\hat{x}_i} (\hat{x}_i - x_i) f_{X_i|Y}(x_i \mid y)\, dx_i + \int_{\hat{x}_i}^{+\infty} (x_i - \hat{x}_i) f_{X_i|Y}(x_i \mid y)\, dx_i$$

Espandiamo i singoli prodotti per separare i termini lineari in $\hat{x}_i$ dagli integrali pesati

rispetto a x_i:

$$R_i(\hat{x}_i) = \hat{x}_i \int_{-\infty}^{\hat{x}_i} f_{X_i|Y}(x_i \mid y)\, dx_i - \int_{-\infty}^{\hat{x}_i} x_i f_{X_i|Y}(x_i \mid y)\, dx_i + \int_{\hat{x}_i}^{+\infty} x_i f_{X_i|Y}(x_i \mid y)\, dx_i - \hat{x}_i \int_{\hat{x}_i}^{+\infty} f_{X_i|Y}(x_i \mid y)\, dx_i$$

Per individuare il valore di stima $\hat{x}_i$ che minimizza il rischio $R_i(\hat{x}_i)$, deriviamo l'espressione rispetto a $\hat{x}_i$ e azzeriamo la derivata prima. Applichiamo la regola di Leibniz per la derivazione sotto il segno di integrale e il Teorema Fondamentale del Calcolo Integrale:

1. Derivata del primo termine $\hat{x}_i \int_{-\infty}^{\hat{x}_i} f_{X_i|Y}(x_i \mid y) dx_i$ (prodotto di funzioni):

$$\frac{d}{d\hat{x}_i}\left[\hat{x}_i \int_{-\infty}^{\hat{x}_i} f_{X_i|Y}(x_i \mid y)\, dx_i\right] = \int_{-\infty}^{\hat{x}_i} f_{X_i|Y}(x_i \mid y)\, dx_i + \hat{x}_i f_{X_i|Y}(\hat{x}_i \mid y)$$

2. Derivata del secondo termine $-\int_{-\infty}^{\hat{x}_i} x_i f_{X_i|Y}(x_i \mid y) dx_i$:

$$\frac{d}{d\hat{x}_i}\left[-\int_{-\infty}^{\hat{x}_i} x_i f_{X_i|Y}(x_i \mid y)\, dx_i\right] = -\hat{x}_i f_{X_i|Y}(\hat{x}_i \mid y)$$

3. Derivata del terzo termine $\int_{\hat{x}_i}^{+\infty} x_i f_{X_i|Y}(x_i \mid y) dx_i$:

$$\frac{d}{d\hat{x}_i}\left[\int_{\hat{x}_i}^{+\infty} x_i f_{X_i|Y}(x_i \mid y)\, dx_i\right] = -\hat{x}_i f_{X_i|Y}(\hat{x}_i \mid y)$$

4. Derivata del quarto termine $-\hat{x}_i \int_{\hat{x}_i}^{+\infty} f_{X_i|Y}(x_i \mid y) dx_i$:

$$\frac{d}{d\hat{x}_i}\left[-\hat{x}_i \int_{\hat{x}_i}^{+\infty} f_{X_i|Y}(x_i \mid y)\, dx_i\right] = -\int_{\hat{x}_i}^{+\infty} f_{X_i|Y}(x_i \mid y)\, dx_i + \hat{x}_i f_{X_i|Y}(\hat{x}_i \mid y)$$

   Sommando i quattro contributi della derivata prima $\frac{dR_i(\hat{x}_i)}{d\hat{x}_i}$, i termini di bordo $\hat{x}_i f_{X_i|Y}(\hat{x}_i \mid y)$ si elidono esattamente a due a due:

$$\frac{dR_i(\hat{x}_i)}{d\hat{x}_i} = \int_{-\infty}^{\hat{x}_i} f_{X_i|Y}(x_i \mid y)\, dx_i - \int_{\hat{x}_i}^{+\infty} f_{X_i|Y}(x_i \mid y)\, dx_i$$

   Imponendo la condizione di stazionarietà $\frac{dR_i(\hat{x}_i)}{d\hat{x}_i} = 0$, otteniamo la condizione fondamentale:

$$\int_{-\infty}^{\hat{x}_i} f_{X_i|Y}(x_i \mid y)\, dx_i = \int_{\hat{x}_i}^{+\infty} f_{X_i|Y}(x_i \mid y)\, dx_i$$

   Poiché la superficie totale sottesa da una densità di probabilità vale 1, l'uguaglianza dei due integrali di coda implica che ciascun integrale deve valere esattamente 0.5 (il 50% della massa di probabilità).

Per definizione analitica, il punto $\hat{x}_i$ che divide la densità di probabilità in due aree di pari massa 0.5 è la **mediana della distribuzione a posteriori** $f_{X_i|Y}(x_i \mid y)$:

$$\hat{\mathbf{x}}_{\mathbf{i},\mathrm{MAE}} = \mathrm{mediana}\left(\mathbf{f}_{\mathbf{X_i|Y}}(\mathbf{x_i} \mid \mathbf{y})\right)$$

3.4 Proprietà di Separabilità Componente per Componente e Confronto con MAP e MMSE

La derivazione formale dello stimatore MAE rivela una proprietà teorica fondamentale e unica2:

- **Separabilità Completa**: Lo stimatore a minimo errore assoluto (L_1) è l'**unico stimatore Bayesiano** in cui la stima vettoriale coincida esattamente con l'insieme delle stime eseguite in modo isolato e indipendente sulle singole densità marginali *a posteriori* $f_{X_i|Y}(x_i \mid y)$.
- **Differenza rispetto al Criterio MAP**: Nello stimatore MAP, massimizzare la PDF congiunta vettoriale $\arg\max_x f_{X|Y}(x|y)$ produce in generale un vettore le cui componenti non coincidono con la moda delle singole PDF marginali $\arg\max_{x_i} f_{X_i|Y}(x_i|y)$, a causa delle correlazioni e delle dipendenze espresse dai termini fuori diagonale della distribuzione *a posteriori*.
- **Sintesi Ingegneristica**: Nel criterio L_1, stimare ciascuna componente separatamente calcolando la mediana marginale *a posteriori* equivale a minimizzare il rischio condizionato globale.

Blocco 4 - Introduzione alle Funzioni di Costo L_1 ed L_2 e Rinvio allo Stimatore MMSE

4.1 Panoramica delle Funzioni di Costo per la Stima Bayesiana

A completamento dell'analisi della stima Bayesiana, oltre al criterio MAP (derivato dalla funzione di costo a sfera di raggio infinitesimo $\Delta \to 0$), vengono introdotte due funzioni di costo basate su metriche di distanza vettoriale:

1. **Norma L_1 (Costo a Minimo Errore Assoluto)**:

   $$C(x, \hat{x}) = \|x - \hat{x}\|_1 = \sum_{i=1}^{N} |x_i - \hat{x}_i|$$

   Porta allo **stimatore MAE**, la cui soluzione coincide con la **mediana della distribuzione a posteriori** $f_{X_i|Y}(x_i|y)$ (sviluppato nel Blocco 3).
2. **Norma L_2 (Costo Quadratico / Minimum Mean Squared Error)**:

   $$C(x, \hat{x}) = \|x - \hat{x}\|_2 = \sqrt{\sum_{i=1}^{N} (x_i - \hat{x}_i)^2}$$

Definisce la metrica per lo **stimatore MMSE** (Minimum Mean Squared Error).

Come evidenziato a lezione, la minimizzazione del rischio condizionato basato sulla norma quadratica L_2 definisce la classe degli stimatori a minimo errore quadratico medio (MMSE).

La derivazione formale dello stimatore MMSE, il calcolo della media condizionata *a posteriori* $E[X|Y]$ e l'analisi delle sue proprietà matematiche **vengono rinviate e sviluppate nella lezione successiva** (Lezione 15).